UNIVERSIDADE ESTADUAL PAULISTA
"JÚLIO DE MESQUITA FILHO"

Programa de Pós-Graduação em Ciência da Computação

Maicon Dall'Agnol

Agrupamento e Agregação de Medidas Objetivas para Ranqueamento de Regras em Classificadores Associativos

Rio Claro – SP

2024

UNIVERSIDADE ESTADUAL PAULISTA
"Júlio de Mesquita Filho"
Instituto de Geociências e Ciências Exatas
Câmpus de Rio Claro

Maicon Dall'Agnol

Agrupamento e Agregação de Medidas Objetivas para Ranqueamento de Regras em Classificadores Associativos

Dissertação apresentada ao Instituto de Geociências e Ciências Exatas do Câmpus de Rio Claro, da Universidade Estadual Paulista "Júlio de Mesquita Filho", como parte dos requisitos para obtenção do título de Mestre em Ciência da Computação.

Orientador: Profa. Dra. Veronica Oliveira de Carvalho

Rio Claro – SP
2024

D144a

Dall'Agnol, Maicon
Agrupamento e agregação de medidas objetivas para ranqueamento de regras em classificadores associativos / Maicon Dall'Agnol. -- Rio Claro, 2024
83 p.

Dissertação (mestrado) - Universidade Estadual Paulista (Unesp), Instituto de Geociências e Ciências Exatas, Rio Claro
Orientadora: Veronica Oliveira de Carvalho

1. Ranqueamento de regras. 2. Classficadores associativos. 3. Medidas objetivas. 4. Métodos de agregação. 5. Agrupamento de medidas objetivas. I. Título.

Sistema de geração automática de fichas catalográficas da Unesp. Biblioteca do Instituto de Geociências e Ciências Exatas, Rio Claro. Dados fornecidos pelo autor(a).

Essa ficha não pode ser modificada.

UNIVERSIDADE ESTADUAL PAULISTA
"Júlio de Mesquita Filho"
Instituto de Geociências e Ciências Exatas
Câmpus de Rio Claro

Maicon Dall'Agnol

Agrupamento e Agregação de Medidas Objetivas para Ranqueamento de Regras em Classificadores Associativos

Dissertação apresentada ao Instituto de Geociências e Ciências Exatas do Câmpus de Rio Claro, da Universidade Estadual Paulista "Júlio de Mesquita Filho", como parte dos requisitos para obtenção do título de Mestre em Ciência da Computação.

Comissão Examinadora

- Profa. Dra. Veronica Oliveira de Carvalho (Orientadora)
  Departamento de Estatística, Matemática Aplicada e Computação (DEMAC)
  Universidade Estadual Paulista "Júlio De Mesquita Filho" (UNESP) – Câmpus de Rio Claro
- Prof. Dr. Daniel Carlos Guimarães Pedronette
  Departamento de Estatística, Matemática Aplicada e Computação (DEMAC)
  Universidade Estadual Paulista "Júlio De Mesquita Filho" (UNESP) – Câmpus de Rio Claro
- Prof. Dr. Guilherme Palermo Coelho
  Faculdade de Tecnologia (FT)
  Universidade de Campinas (Unicamp) – Câmpus de Limeira

Conceito: Aprovado

Rio Claro (SP), 27 de fevereiro de 2024

Dedico este trabalho ao meus pais que me apoiaram incondicionalmente, permitindo que eu chegasse aqui. Muito obrigado por tudo!

AGRADECIMENTOS

Primeiramente agradeço a minha mãe Adriana e ao meu pai Geneci por terem desde cedo me incentivado e apoiado nos estudos, assegurando um lar acolhedor e compreensivo que me permitiu trilhar este caminho, sem eles nada disto seria possível. Agradeço também ao meu irmão Jonathan, aos demais familiares, tios, avós, primos, especialmente ao meu primo Gustavo (*in memoriam*), e a todos meus amigos de longa data que também contribuíram com de alguma maneira para minha evolução pessoal. Junto a eles agradeço a minha namorada Giovanna, que nestes anos todos dando suporte, aconchego, me acalentando, permitiu que eu alcançasse meu objetivo, também a sua família, que nos últimos 9 anos possibilitaram que mesmo longe de casa eu ainda tivesse um lar onde eu pudesse recorrer sempre.

Agradeço também à Veronica que em todos estes anos me propiciou um ambiente saudável de discussão, aprendizado, pensamento crítico, sempre se preocupando na melhor forma de me capacitar, não apenas cientificamente, mas também no profissional e no pessoal, sempre aconselhando, instruindo, ajudando, sempre com muita paciência, tendo em diversos momentos compreendido minhas dificuldades e feito o possível para que fossem ultrapassadas. O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Código de Financiamento 001.

Faça o teu melhor na condição que você tem,
enquanto você não tem condições melhores para fazer melhor ainda.

Mário Sérgio Cortella

RESUMO

Em diversos problemas é interessante o uso de algoritmos inerentemente interpretáveis, uma vez que facilita o entendimento do conhecimento obtido e das predições realizadas. Dentre estes algoritmos encontram-se os classificadores associativos (CAs). Os mesmos mesclam as tarefas de associação e classificação e são, portanto, induzidos em etapas. No que se refere a etapa de ordenação, a mesma é, em geral, realizada via o uso de medidas objetivas (MOs), utilizadas, entre outros propósitos, para ranquear as regras pelo seu grau de importância. Em geral, o método CSC (Confiança, Suporte, Cardinalidade) é o utilizado para se ordenar as regras, tendo como base as MOs padrão de regras de associação. Contudo, ao longo dos anos inúmeras MOs foram propostas, visando superar limitações de algumas das medidas até então existentes. Este grande número de MOs gerou um problema secundário, uma vez que não existe uma medida que seja adequada a todas as explorações. Neste contexto, novas propostas surgiram visando modificar a etapa de ranqueamento dos CAs, seja por meio: (i) de novas medidas e/ou medidas já existentes em outros contextos, mas aplicadas nesta etapa de maneira singular; (ii) da união (agregação) de medidas existentes de maneira a usá-las simultaneamente. A estratégia (ii), adotada neste trabalho, traz a vantagem de diminuir a necessidade da escolha de uma só medida, considerando também diferentes aspectos (semântica) para a ordenação das regras. Trabalhos recentes nesta linha vêm sendo propostos, os quais têm apresentado resultados promissores. Contudo, os mesmos apresentam problemas em relação ao desempenho e/ou a interpretabilidade dos modelos gerados. Em todos eles é possível verificar uma relação inversa entre desempenho e interpretabilidade, i.e., quando o desempenho do modelo é alto, a interpretabilidade é baixa (e vice-versa). Diante do exposto, este trabalho apresenta um método de ranqueamento via agregação de MOs, denominado $AC.Rank_A$, a ser incorporado a fluxos de indução de CAs, visando a obtenção de modelos que apresentem um melhor equilíbrio entre desempenho e interpretabilidade. Para que o $AC.Rank_A$ funcione, o mesmo deve ser instanciado com um conjunto de MOs e um método de agregação. Os conjuntos de MOs explorados foram tanto extraídos da literatura quanto propostos neste trabalho. Já os métodos de agregação foram extraídos tanto de abordagens de agregação de rankings como de análise de decisão multicritérios. O método proposto foi avaliado em diversos fluxos de indução de CAs em relação a desempenho, medido via F1-Macro, e interpretabilidade, medida via tamanho do modelo. A análise foi realizada comparando-se diversos fluxos de indução quando o ranqueamento acontece via CSC (*baseline*) e via $AC.Rank_A$. Os resultados obtidos demonstram que o $AC.Rank_A$ consegue manter o desempenho dos modelos, porém com uma melhor interpretabilidade, diferentemente dos trabalhos da literatura.

Palavras-chave: classificadores associativos; medidas objetivas; agregação de medidas objetivas; ranqueamento de regras; agrupamento de medidas objetivas.

ABSTRACT

In several problems the use of inherently interpretable algorithms is interesting, as it facilitates the understanding of the obtained knowledge and the predictions made. Among these algorithms are the associative classifiers (ACs). They merge the tasks of association and classification and are, therefore, induced in stages. Regarding the ranking step, it is, in general, carried out through the use of objective measures (OMs), used, among other purposes, to rank the rules according to their level of importance. In general, the CSC (Confidence, Support, Cardinality) method is used to sort the rules, based on the standard OMs of association rules. However, over the years, many OMs have been proposed, aiming to overcome limitations of some of the previously existing measures. This large number of OMs led to a secondary problem, since there is no measure that is suitable for all explorations. In this context, new proposals have emerged aiming to modify the ACs ranking step, either through: (i) new measures and/or measures that already exist in other contexts, but applied at this step in a unique way; (ii) the union (aggregation) of existing measures in order to use them simultaneously. Strategy (ii), adopted in this work, has the advantage of reducing the need to choose a single measure, also considering different aspects (semantics) for ranking the rules. Recent works in this line have been proposed, which have shown promising results. However, they present problems in relation to the performance and/or interpretability of the generated models. In all of them it is possible to verify an inverse relationship between performance and interpretability, i.e., when model performance is high, interpretability is low (and vice versa). Considering the above, this work presents a ranking method via aggregation of OMs, named $AC.Rank_A$, to be incorporated into ACs induction flows, aiming to obtain models that present a better balance between performance and interpretability. For $AC.Rank_A$ to work, it must be instantiated with a set of OMs and an aggregation method. The sets of OMs explored were both extracted from the literature and proposed in this work. The aggregation methods were extracted from both ranking aggregation and multi-criteria decision analysis approaches. The proposed method was evaluated in several ACs induction flows in terms of performance, measured via F1-Macro, and interpretability, measured via model size. The analysis was carried out by comparing different induction flows when ranking takes place via CSC (*baseline*) and via $AC.Rank_A$. The results obtained demonstrate that $AC.Rank_A$ can maintain the performance of the models, but with better interpretability, unlike works in the literature.

Keywords: associative classifiers; objective measures; aggregation of objective measures; rules ranking; clustering of objective measures.

LISTA DE ILUSTRAÇÕES

Figura 1 – Etapas envolvidas na indução de um CA. 29
Figura 2 – Método $AC.Rank_A$ a ser incorporado a fluxos de indução de um CA. 41
Figura 3 – Dendrograma obtido após reexecução dos experimentos considerando o método proposto (Algoritmo 4). 49
Figura 4 – Relação entre desempenho e interpretabilidade tendo como base os dados da Tabela 7. 49
Figura 5 – Métodos utilizados em cada etapa de indução, os quais, em conjunto, geram os fluxos avaliados neste trabalho. 58
Figura 6 – Gráfico de diferença crítica, em relação aos valores de F1, para comparar as 8 configurações (fluxos) presentes na linha 1 da Tabela 13 ao longo dos 43 datasets. 63
Figura 7 – Gráfico de diferença crítica, em relação aos tamanhos dos modelos, para comparar as 8 configurações (fluxos) presentes na linha 1 da Tabela 13 ao longo dos 43 datasets. 63
Figura 8 – Gráfico de saída apresentado para escolha da solução desejada referente a um conjunto de dados. Fonte: Bui-Thi, Meysman e Laukens (2022). 70

LISTA DE TABELAS

Tabela 1 – Tabela de contingência de uma regra abstrata $A \Rightarrow B$. Fonte: Adaptado de Selvarangam e Kumar (2014). 19
Tabela 2 – Probabilidades utilizadas para se definir as MOs disponíveis na literatura. . . 20
Tabela 3 – Medidas objetivas utilizadas neste trabalho. 21
Tabela 4 – Abordagens de escolha de MOs. Fonte: Adaptado de Geng e Hamilton (2006). 22
Tabela 5 – Grupos de medidas propostos por Tew *et al.* (2014). 44
Tabela 6 – Grupos de MOs propostos, Adaptado de Dall'Agnol e Carvalho (2023a). . . 47
Tabela 7 – Grupos de MOs propostos após reexecução dos experimentos. 50
Tabela 8 – Tabela de alternativas e critérios. 52
Tabela 9 – Exemplo de alternativas e critérios. 52
Tabela 10 – Valores da Tabela 9 após normalização. Os maiores valores de cada coluna encontram-se em negrito e os menores em itálico. 54
Tabela 11 – Exemplo de *ranks* por critério. 55
Tabela 12 – Características dos conjuntos de dados utilizados nos experimentos. 59
Tabela 13 – Resultados de F1-Macro no conjunto Hayes-roth com $AC.Rank_A$ instanciado no grupo **[TW]** nos diversos métodos de agregação. 61
Tabela 14 – Resultados de tamanho do modelo no conjunto Hayes-roth com $AC.Rank_A$ instanciado no grupo **[TW]** nos diversos métodos de agregação. 62
Tabela 15 – Resultados referentes a análise de diferença crítica entre os métodos de ranqueamento $AC.Rank_A$ e **[CSC]** em diversos fluxos de indução (continua na próxima página). 65
Tabela 15 – Resultados referentes a análise de diferença crítica entre os métodos de ranqueamento $AC.Rank_A$ e **[CSC]** em diversos fluxos de indução (continuação). 66
Tabela 16 – Equações das medidas objetivas utilizadas neste trabalho. Adaptado de Tew *et al.* (2014). A medida marcada com "*" foi ajustada em função do trabalho original. 81

LISTA DE ABREVIATURAS E SIGLAS

$\mathcal{L}$	Tamanho do Modelo
ACCRC	Accuracy
ADD_V	Added Value
AP	Apriori
BD	Borda Mediana
BG	Borda Geométrica
BK	Bouker
BL	Borda L2
BM	Borda Média
C1	Grupo de Medidas Cluster 1
CA	*Classificação Associativa*, *Classificador Associativo*
CBA	Classification Based on Association Rules Algorithm
CF_CA	Confirm Causal
CF_CN_CA	Comfirmed Confidence Causal
CF_DES	Confirm Descriptive
CHI_SQ	Chi-Square
CLL_STR	Collective Strength
CMAR	Classification based on Multiple Class Association Rules
CNFD	Confidence
CN_CA	Confidence Causal
CON_ENT	Conditional Entropy
CORR_COE	Correlation Coefficient
COSI	Cosine
COVER	Coverage
CPAR	Classification based on Predictive Association Rules
CP_CL_SP	Complement Class Support
CSC	Confiança, Suporte, Cardinalidade
CV	Poda Coverage
Conf	Confiança
DIR	Dir
DN	Poda Dinâmica
EN	Ensemble
F1	F1-score Macro
FME	F-Measure
G1	Grupo de Medidas Grupo 1
G2	Grupo de Medidas Grupo 2
GF	Grupo de Medidas Guangfei
GIN_IN	Gini Index
GOO_KRU	Goodman Kruskal
IMP_IND	Implication Index
JME	J-Measure

KAPP	Kappa
KEEL	Knowledge Extraction based on Evolutionary Learning
KLOS	Klosgen
KME	K-Measure
KUL2	Kulczynski 2
LAC	Library for Associative Classification
LEVER	Leverage
LIFT	Lift
LOEV	Loevinger
LOG_NEC	Logical Necessity
LST_CNT	Least Contradiction
LUCS-KDD	Liverpool University Computer Science - Knowledge Discovery in Data
M1	Poda M1
MA	Métodos Agregados
MCDA	Multicriteria Decision Analysis
MO	*Medida Objetiva*
MS	Métodos Singular
MU_INF	Mutual Information
NR_MU_IN	Normalized Mutual Information
ODD_MUL	Odd Multiplier
ODD_RAT	Odds Ratio
ONE_SUP	One Way Support
O	Predição Ordinal
PIE_SHA	Piatetsky Shapiro
PREVA	Prevalence
PT_CA_DP	Putative Caausal Dependency
P	Predição Probabilistica
RAC	*Regra de Associação Classificativa*
RA	*Regra de Associação*
RECA	Recall
REL_RIS	Relative Risk
R	Predição Rank based
SPECT	Specificity
SUPP	Support
Sup	Suporte
THE_UNC	Theil Uncertainty Coefficiente
TIC	TIC
TS	Topsis
TW_SUP	Two Way Support
TW	Grupo de Medidas Tew
V	Predição Votação
WP	WPM
WS	WSM
XAI	Explainable Artificial Intelligence

SUMÁRIO

1 INTRODUÇÃO 11
1.1 Motivação e Contextualização 11
1.2 Questão de Pesquisa e Objetivo 13
1.3 Organização 14

2 FUNDAMENTOS 15
2.1 Regras de Associação 15
2.2 Medidas Objetivas 18
2.3 Classificação Associativa 22
2.3.1 Vantagens e Desvantagens 22
2.3.2 Algoritmos Tradicionais 24
2.3.3 Critérios de Avaliação 27

3 TRABALHOS RELACIONADOS 29
3.1 Etapas dos Classificadores Associativos 29
3.1.1 Extração 29
3.1.2 Ranqueamento 30
3.1.3 Poda 34
3.1.4 Predição 35
3.2 MoMAC: *Multi-objective Optimization to Combine Multiple Association Rules into an Interpretable Classification* 37

4 $AC.Rank_A$: MÉTODO DE RANQUEAMENTO VIA AGREGAÇÃO DE MOS PARA CLASSIFICADORES ASSOCIATIVOS 40
4.1 Agrupamento de Medidas Objetivas 41
4.1.1 Conjunto de MOs de Tew *et al.* (2014) e Yang e Cui (2015) 42
4.1.2 Conjunto de MOs de Dall'Agnol e Carvalho (2023a) 45
4.2 Métodos de Agregação 50
4.2.1 Análise de Decisão Multicritérios (MCDA) 51
4.2.2 Agregação de Rankings 54

5 AVALIAÇÃO EXPERIMENTAL 57
5.1 Detalhes da Configuração Experimental 58
5.2 Resultados e Discussão 60
5.3 Análise Complementar 68

6 CONCLUSÃO 72

REFERÊNCIAS 74

APÊNDICE A – EQUAÇÕES DAS MEDIDAS OBJETIVAS SELECIONADAS 81

1 Introdução

1.1 Motivação e Contextualização

Parte das técnicas tradicionais de aprendizado de máquina remontam ao século passado, seja por meio de algoritmos consolidados ou usados como base para os mais recentes. Entretanto, com o avanço da internet e a expansão na coleta de dados, tais algoritmos ganharam força e tornaram-se parte essencial de muitos negócios, o que fomentou também o desenvolvimento de novas soluções. Entre elas, as redes neurais profundas vêm se destacando nos últimos anos, o que eventualmente acaba por deixar outras em segundo plano (SOOD; ZAIANE, 2020). No entanto, há vários campos de conhecimento em que, por diversas razões, busca-se utilizar técnicas interpretáveis, ou seja, soluções em que seja possível compreender por quais razões o modelo chegou a uma determinada predição. Por exemplo, o que levou um modelo a decidir se uma ação cairia ou subiria, se um paciente possui ou não uma doença ou então se um acusado seria julgado inocente ou culpado. Mesmo com diversos métodos de XAI (Explainable Artificial Intelligence) disponíveis hoje em dia, como LIME e SHAP, há trabalhos como o de Rudin (2019) que propõem o uso de classificadores mais interpretáveis em detrimento da tentativa de criar modelos de explicação para algoritmos caixa-preta via tais métodos.

Uma das tarefas mais comuns de aprendizado de máquina é a classificação, a qual tem por objetivo atribuir uma categoria, chamada de classe, para instâncias não rotuladas. Dentre as técnicas que se destacam nesta tarefa encontra-se a classificação associativa (CA). A CA faz parte de uma família maior de algoritmos, chamada de *rule-based*, que se utiliza de regras para representar o conhecimento extraído. No caso a CA faz uso de regras de associação para gerar um classificador. Isto se dá através de um tipo especial de regra de associação conhecida como regra de associação classificativa. Uma regra de associação classificativa (RAC) é uma regra do tipo $A \Rightarrow B$ em que a parte antecedente (A) leva a um determinado consequente (B). A contém um conjunto de pares atributo-valor e B contém uma classe de um dado problema. Assim, um classificador associativo é um modelo composto por regras deste tipo a fim de classificar novas instâncias. A utilização destas regras é vantajosa, uma vez que elas são facilmente interpretáveis por especialistas que podem analisá-las e tomar decisões com auxílio computacional. Devido à sua interpretabilidade inerente, diversas áreas a tem utilizado, como a médica (BASHA, 2021), a de segurança (MOHAMMAD, 2020) e a de software (SHAO *et al.*, 2020).

Segundo Padillo, Luna e Ventura (2020) estudos recentes demonstram que a classificação associativa apresenta as seguintes vantagens sobre as abordagens de classificação interpretáveis tradicionais: (i) acurácia, os algoritmos da família são capazes de construir modelos eficientes e

precisos uma vez que a fase de treinamento é baseada em regras de associação, permitindo a descoberta de todos os relacionamentos possíveis entre os pares atributo-valor; (ii) usabilidade, ao contrário da família de árvores de decisão, os algoritmos de CA não requerem redesenhar todo o modelo quando o conjunto de regras é atualizado e ajustado; (iii) legibilidade, o modelo final de um CA é composto por um conjunto simples de regras que permite que o usuário final compreenda e interprete facilmente os resultados. No entanto, algumas vantagens como a acurácia ainda são objetos de debate. Boa parte disto se dá devido ao *trade-off* entre a interpretabilidade e a acurácia, relatado em diversos trabalhos (SHUKLA; TRIPATHI, 2012; MORI; UCHIHIRA, 2019), ainda que o mesmo venha sendo questionado, como abordado em Rudin (2019).

Tal como outras famílias de algoritmos, esforços vêm sendo realizados no sentido de popularizar ainda mais a CA por meio da implementação de pacotes, como visto em Hahsler *et al.* (2019), Padillo, Luna e Ventura (2020), e Azmi e Berrado (2020), os quais contribuem ao disponibilizar algoritmos para uso geral. O algoritmo que mais se destaca é o CBA (Classification Based on Association Rules) (LIU; HSU; MA, 1998), disponível em todas as implementações levantadas, o qual é usado, em geral, como *baseline* para comparação com novas propostas/soluções. De acordo com Filip e Kliegr (2018), o CBA é provavelmente o algoritmo mais utilizado da família.

A maior parte dos algoritmos de CA realizam a indução do modelo em três ou quatro etapas, a saber: [A] Extração, [B] Ranqueamento e/ou Poda e [C] Predição. Como será visto no Capítulo 3, esforços têm sido realizados para melhorar cada uma dessas etapas, uma vez que as mesmas influenciam diretamente a qualidade do modelo gerado. Para tanto, diversos métodos têm sido propostos.

No que se refere à etapa de ordenação (etapa [B]), a mesma é, em geral, realizada via o uso de medidas objetivas (MOs), utilizadas, entre outros propósitos, para ranquear as regras pelo seu grau de importância[1]. Uma medida objetiva (MO) avalia a força estatística, ou as características, de um determinado padrão, baseando-se unicamente nos dados (BONG *et al.*, 2014). As MOs mais conhecidas são o suporte ($P(AB)$) e a confiança ($P(B|A)$), utilizadas na extração de regras de associação. No algoritmo CBA o método CSC (Confiança, Suporte, Cardinalidade) é o utilizado para se ordenar as regras da seguinte maneira: uma regra r_i precede uma regra r_j, em uma lista ordenada, se a confiança de r_i é maior que r_j; em caso de empate, se o suporte de r_i é maior que r_j; em caso de empate, r_i foi gerada antes de r_j, também chamada de cardinalidade.

Embora o suporte e a confiança sejam as MOs mais tradicionais, ao longo dos anos mais de 60 medidas foram propostas, como visto em Tew *et al.* (2014) e Somyanonthanakul e Theeramunkong (2022), visando superar limitações de algumas das medidas até então existentes,

[1] Ranqueamento e ordenação são utilizados como sinônimos neste trabalho.

como a própria confiança (não detecta correlações positivas, negativas, nem ausência de correlação (TAN *et al.*, 2019)). Este grande número de MOs existentes gerou um problema secundário, uma vez que não existe uma MO que seja adequada a todas as explorações (SHARMA *et al.*, 2020).

Diante do exposto, novas propostas surgiram visando modificar a etapa de ranqueamento dos CAs, seja por meio: (i) de novas medidas e/ou medidas já existentes em outros contextos, mas aplicadas nesta etapa de maneira singular; (ii) da união (agregação) de medidas existentes de maneira a usá-las simultaneamente (detalhes na Seção 3.1.2). A estratégia (ii), adotada neste trabalho, traz a vantagem de diminuir a necessidade da escolha de uma só medida, considerando também diferentes aspectos (semântica) para a ordenação das regras.

Trabalhos relacionados à estratégia (ii) vêm sendo desenvolvidos, como o de Silva e Carvalho (2018), Dall'Agnol e Carvalho (2020b), Dall'Agnol e Carvalho (2020a) e Bui-Thi, Meysman e Laukens (2022), os quais têm apresentado resultados promissores. Contudo, os mesmos apresentam problemas em relação ao desempenho e/ou a interpretabilidade dos modelos gerados. Neste trabalho o desempenho dos modelos é estimado via F1-Macro. Já a interpretabilidade via tamanho do modelo, i.e., número de regras contidas no mesmo (vide Seção 2.3.3). Em todos estes trabalhos é possível verificar uma relação inversa entre desempenho e interpretabilidade, i.e., quando o desempenho do modelo é alto, a interpretabilidade é baixa. Por outro lado, quando o desempenho do modelo é baixo, a interpretabilidade é alta.

1.2 Questão de Pesquisa e Objetivo

Diante deste cenário, a questão de pesquisa levantada neste trabalho é que é possível, utilizando agregação de MOs na etapa de ranqueamento, induzir modelos de CAs que apresentem um melhor equilíbrio entre desempenho e interpretabilidade[2]. Assim, o objetivo deste trabalho é desenvolver e avaliar um método de ranqueamento via agregação de MOs que possa ser incorporado a fluxos de indução de CAs. A fim de atingir este objetivo, as seguintes atividades foram realizadas:

- Pesquisa e seleção das MOs a serem agregadas. Embora a ideia da agregação seja a de utilizar diversas MOs, fazendo com que a importância de todas elas sejam levadas em consideração, visando eliminar a seleção das mesmas, notou-se em Dall'Agnol e Carvalho (2020a) que a utilização de muitas MOs de maneira agregada não leva a melhores resultados quando aplicadas no contexto da CA. Portanto, é necessário que se defina o conjunto de MOs a serem agregadas. Como resultado, cinco conjuntos de MOs foram selecionados, dois da literatura e três resultantes de uma proposta de agrupamento de MOs desenvolvida, a qual foi publicada no artigo "Clustering the Behavior of Objective Measures in Associative

[2] Considera-se, neste trabalho, que estes critérios são analisados em relação a algum *baseline*.

Classifiers" (DALL'AGNOL; CARVALHO, 2023a). A Seção 4.1 do Capítulo 4 apresenta tais resultados.

- Pesquisa e seleção de abordagens que pudessem ser utilizadas e/ou adaptadas para se agregar um conjunto de MOs. Estudos anteriores, na mesma linha deste trabalho, já haviam utilizado Pareto (SILVA; CARVALHO, 2018; DALL'AGNOL; CARVALHO, 2020b), comitê (*ensemble*) de classificadores (DALL'AGNOL; CARVALHO, 2020a) e otimização multiobjetivo (BUI-THI; MEYSMAN; LAUKENS, 2022). Contudo, como já mencionado, as mesmas apresentam problemas. Assim, neste trabalho optou-se por utilizar análise de decisão multicritérios (MCDA) e agregação de rankings. O motivo se deve ao uso recente de métodos de MCDA no contexto de regras de associação, como o ELECTRE I (MAZOURI; ABOUNAIMA; ZENKOUAR, 2017; DAHBI *et al.*, 2020b) e o ELECTRE II (MAZOURI; ABOUNAIMA; ZENKOUAR, 2019). Parte da solução encontra-se no artigo "Ranking Rules in Associative Classifiers via Borda's Methods" (DALL'AGNOL; CARVALHO, 2023b). A Seção 4.2 do Capítulo 4 apresenta tais resultados.

- Desenvolvimento (implementação) e avaliação do método de ranqueamento via agregação de MOs proposto. Como mencionado, a ideia é que o método possa ser incorporado a fluxos de indução de CAs. Assim, o mesmo foi incorporado ao CBA, assim como a outros fluxos, visando avaliar seu desempenho e interpretabilidade. O Capítulo 5 apresenta tais resultados. Parte destes resultados encontram-se apresentados em Dall'Agnol e Carvalho (2023b).

1.3 Organização

A fim de apresentar o trabalho desenvolvido, esta dissertação encontra-se estruturada da seguinte maneira:

- Capítulo 2: apresenta os conceitos fundamentais que embasam este trabalho, a saber: regras de associação, medidas objetivas e classificação associativa;

- Capítulo 3: apresenta trabalhos relacionados a cada uma das etapas de indução de um CA, descrevendo alguns métodos utilizados na avaliação do método aqui proposto;

- Capítulos 4 e 5: apresentam, respectivamente, o método aqui proposto, denominado de $AC.Rank_A$, assim como a avaliação do mesmo;

- Capítulo 6: apresenta as conclusões e trabalhos futuros.

2 Fundamentos

Este capítulo apresenta os conceitos fundamentais que embasam este trabalho, a saber: Regras de Associação (Seção 2.1), Medidas Objetivas (Seção 2.2) e Classificação Associativa (Seção 2.3).

2.1 Regras de Associação

As regras de associação (RAs) compõem uma das maneiras mais tradicionais em aprendizado de máquina para se extrair padrões dos dados (SHARMA *et al.*, 2020). Os algoritmos desta família são utilizados para extração de um conjunto de regras que buscam representar as relações intrínsecas dos atributos e seus valores em conjuntos de dados. Elas são classificadas dentro do aprendizado de máquina como não-supervisionada, tendo um caráter exploratório, com objetivo de realizar descobertas de padrões interessantes.

As RAs são expressas via implicação lógica, tendo um formato do tipo $A \Rightarrow B$, onde o antecedente A implica no consequente B. Esta representação torna a técnica transparente e de fácil entendimento, uma vez que as relações podem ser lidas, entendidas e validadas por um especialista. Uma regra de associação é definida formalmente da maneira descrita a seguir (AGRAWAL; SRIKANT, 1994): seja D um conjunto de dados composto por um conjunto de itens $I = \{i_1, ..., i_m\}$, ordenados lexicograficamente, e por um conjunto de transações $T = \{t_1, ..., t_n\}$, na qual cada transação $t_i \in T$ é composta por um conjunto de itens (chamado *itemset*) tal que $t_i \subseteq I$. A regra de associação é uma implicação na forma $A \Rightarrow B$, em que $A \subset I$, $B \subset I$ e $A \cap B = \varnothing$. A regra $A \Rightarrow B$ ocorre no conjunto de transações T com ***confiança*** $(conf)$ e ***suporte*** (sup), definidas pelas Equações 2.1 e 2.2, em que $n(AB)$ representa a frequência com que $(A \cup B)$ ocorrem conjuntamente no conjunto de transações, $|D|$ o número de transações e $|D(A)|$ o número de transações em que A ocorre. Estas equações também são chamadas de Medidas Objetivas ou Medidas de Interesse, mais detalhes encontram-se na Seção 2.2. Assim, os algoritmos de associação visam encontrar todas as possíveis regras (correlações) que apresentem valores de suporte e confiança superiores a valores previamente estabelecidos, denominados de suporte mínimo (**sup-min**) e confiança mínima (**conf-min**).

$$\text{Suporte} = \frac{n(AB)}{|D|} = P(AB) \tag{2.1}$$

$$\text{Confiança} = \frac{n(AB)}{|D(A)|} = P(B|A) \tag{2.2}$$

O problema de obtenção de regras de associação é decomposto em dois passos (AGRAWAL; IMIELIńSKI; SWAMI, 1993):

1. Encontrar todos os *k-itemsets* (conjunto de k itens) que possuam suporte maior ou igual ao suporte mínimo especificado pelo usuário (**sup-min**). Os *itemsets* com suporte igual ou superior a **sup-min** são definidos como *itemsets* frequentes, os demais conjuntos são denominados de *itemsets* não-frequentes;

2. Utilizar todos os *k-itemsets* frequentes, com $k \geq 2$, para gerar as regras de associação.

A parte mais dispendiosa dos dois passos é a geração dos *itemsets* frequentes. Assim, a diferença entre os algoritmos se dá neste passo. Isso se deve devido ao número de *itemsets* que podem ser gerados, sendo proporcional a $2^{|I|}$, em que $|I|$ representa o número de itens distintos contidos em I. Assim, à medida que a quantidade de itens aumenta, o espaço de busca também aumenta. Neste sentido, os algoritmos buscam estratégias para encontrar os *itemsets* frequentes sem a necessidade de percorrer todo o espaço de busca.

Diversos algoritmos são encontrados na literatura para se obter os *itemsets* frequentes, por conseguinte, gerar as regras de associação, sendo o Apriori (AGRAWAL; SRIKANT, 1994) um dos mais utilizados[1]. O Algoritmo 1 apresenta o pseudocódigo do mesmo. Em um primeiro momento realiza-se a contagem de cada um dos itens distintos a fim de identificar os $1-itemsets$ frequentes, que se encontram armazenados em L_1 (linha 2). Nas linhas 3 a 12 cada um dos conjuntos de *itemsets* frequentes de tamanho k, L_k, são obtidos por meio dos *itemsets* frequentes L_{k-1} do passo anterior. Ou seja, os *2-itemsets* frequentes são gerados a partir dos *1-itemsets* frequentes, os *3-itemsets* frequentes são gerados a partir dos *2-itemsets* frequentes, e assim sucessivamente, até que não seja mais possível gerar nenhum *itemset* frequente de tamanho k. Contudo, a fim de restringir o espaço de busca, sem ter que gerar todos os *itemsets* possíveis, o algoritmo usa apenas os *itemsets* frequentes do passo anterior, e não todos os possíveis *itemsets*. Por exemplo, caso o *itemset* $\{a, b\}$ não seja frequente, nenhum dos seus superconjuntos serão frequentes. Desse modo, o espaço de busca é podado. Isso é possível devido à propriedade anti-monotônica do suporte: $\forall X, \forall Y : X \subseteq Y$, suporte$(X) \geq$ suporte(Y), i.e., o suporte de um *itemset* Y nunca excede o suporte de seus sub-*itemsets* X. Considerando o exposto, na linha 4 todos os *k-itemsets* candidatos de tamanho k são gerados a partir dos *itemsets* frequentes de tamanho $k-1$ obtidos no passo anterior (função *apriori-gen*). Na sequência, linhas 5 a 10, é necessário checar dos candidatos aqueles que são de fato frequentes. Para tanto, percorre-se o conjunto de transações, verifica-se quais candidatos a transação cobre (função subset) e incrementa-se o contador de frequência de cada candidato. Ao final, linha 11, aqueles cuja frequência é maior ou igual ao **sup-min** especificado é inserido no conjunto de saída.

[1] Diversas outras implementações encontram-se disponíveis em <http://www.philippe-fournier-viger.com/spmf/>.

Algoritmo 1 Pseudocódigo do algoritmo Apriori. Fonte: Agrawal e Srikant (1994).

Entrada: Um conjunto de dados D e um valor de suporte mínimo sup-min
Saída: Um conjunto L contendo todos os *k-itemsets* frequentes

```
1  FUNÇÃO apriori-main(D, sup-min):
2      L_1 = Conjunto dos itemsets frequentes de tamanho 1 contidos em D
3      para (k=2; L_{k-1} ≠ ∅; k++) faça
4          C_k= apriori-gen(L_{k-1}) //gera os possíveis candidatos a k-itemsets frequentes
5          para (todas as transações t ∈ T) faça
6              C_t = subset(C_k, t) //candidatos a k-itemsets frequentes contidos em t
7              para (todos os candidatos c ∈ C_t) faça
8                  c.contagem++
9              fim
10         fim
11         L_k = {c ∈ C_k | c.contagem ≥ sup-min}
12     fim
13 Fim FUNÇÃO
```

Uma vez obtidos todos os *k-itemsets* frequentes, as regras de associação podem ser geradas. Agrawal e Srikant (1994) propõem um algoritmo para tal. O Algoritmo 2 apresenta o pseudocódigo do mesmo. O algoritmo é executado para todos os *k-itemsets* frequentes, com $k \geq 2$. Para cada *itemset* frequente l, o algoritmo encontra todos os subconjuntos $\tilde{a}$ de itens não vazios e diferentes de l. Para cada subconjunto $\tilde{a} \subseteq l$, gera-se uma regra no formato $\tilde{a} \Rightarrow (l - \tilde{a})$ se a razão de $sup(l)$ por $sup(\tilde{a})$ é maior ou igual à confiança mínima especificada pelo usuário (**conf-min**). Com um conjunto de *itemsets* frequentes $\{a, b, c, d\}$ e um subconjunto de *itemsets* frequentes $\{a, b\}$, por exemplo, pode-se gerar uma regra do tipo $ab \Rightarrow cd$, desde que $conf(ab \Rightarrow cd) \geq$ **conf-min**, em que, $conf(ab \Rightarrow cd) = sup(\{a, b, c, d\})/sup(\{a, b\})$.

Algoritmo 2 Pseudocódigo para gerar as regras de associação. Fonte: Agrawal e Srikant (1994).

Entrada: Conjunto contendo todos os *k-itemsets* frequentes, com $k \geq 2$, e um valor de confiança mínima conf-min

Saída: Conjunto de regras R

para *(todo k-itemset frequente* $l_k, k \geq 2$*)* **faça**
  Chama gera_regras(l_k, l_k)
fim
//a função gera_regras gera todas as regras válidas $\tilde{a} \rightarrow (l_k - \tilde{a})$, para todo $\tilde{a} \subset a_m$
FUNÇÃO `gera_regras`(l_k*: k-itemset frequente,* a_m*: m-itemset frequente*)**:**
  A = {(m-1)-itemsets $a_{m-1} \mid a_{m-1} \subset a_m$}
  para *(todos* $a_{m-1} \in A$*)* **faça**
    $conf$ = sup(l_k)/sup(a_{m-1})
    se *(*$conf \geq$ *conf-min)* **então**
      $R = R \cup$ regra $a_{m-1} \rightarrow (l_k - a_{m-1})$, com confiança = conf e suporte = sup(l_k)
      se *(m-1 > 1)* **então**
        //gera regras com o subconjunto de a_{m-1} como antecedente
        Chama gera_regras(l_k, a_{m-1})
      fim
    fim
  fim
Fim FUNÇÃO

2.2 Medidas Objetivas

As medidas objetivas (MOs), ou medidas de interesse, estão presentes de maneira unânime nas regras de associação e, consequentemente, na classificação associativa. Duas delas já foram apresentadas na etapa de extração, o suporte e a confiança (Equações 2.1 e 2.2). Uma MO avalia a força estatística, ou as características, de um determinado padrão, baseando-se unicamente nos dados (BONG *et al.*, 2014). As MOs podem ser utilizadas de três maneiras diferentes, a saber (GENG; HAMILTON, 2006): (i) durante a extração das regras, a fim de podar o espaço de busca; (ii) para ordenar, i.e., ranquear as regras pelo seu grau de importância; (iii) para realizar o pós-processamento das regras, a fim de buscar padrões interessantes com correlações significativas.

Como visto nas Equações 2.1 e 2.2, as MOs são definidas em termos da frequência que os elementos de uma regra aparecem nos dados. Assim, para que se avalie a importância de uma regra por meio de uma MO, é necessário também que se conheça toda a tabela de contingência da regra. A Tabela 1 apresenta esta estrutura e seus possíveis valores para uma regra abstrata $A \Rightarrow B$. A representa o antecedente, B representa o consequente, $\neg A$ representa a negação do antecedente e $\neg B$ a negação do consequente. $n(X)$ representa a frequência de X e N o número de transações do conjunto de dados. Assim, tem-se que:

- $n(AB)$ = frequência com que A e B acontecem simultaneamente nas N transações do conjunto de dados;
- $n(\neg AB)$ = frequência com que $\neg A$ e B acontecem simultaneamente nas N transações do conjunto de dados;
- $n(A\neg B)$ = frequência com que A e $\neg B$ acontecem simultaneamente nas N transações do conjunto de dados;
- $n(\neg A\neg B)$ = frequência com que $\neg A$ e $\neg B$ acontecem simultaneamente nas N transações do conjunto de dados.

Tabela 1 – Tabela de contingência de uma regra abstrata $A \Rightarrow B$. Fonte: Adaptado de Selvarangam e Kumar (2014).

	B	$\neg B$	
A	n(AB)	n($A\neg B$)	n(A)
$\neg A$	n($\neg AB$)	n($\neg A\neg B$)	n($\neg A$)
	n(B)	n($\neg B$)	N

A partir da Tabela 1 é possível se definir as probabilidades de ocorrência de A, B e AB, respectivamente, $P(A)$, $P(B)$ e $P(AB)$, dividindo os elementos $n(A)$, $n(B)$ e $n(AB)$ por N. Tendo estes três valores de probabilidade é possível se obter 13 novas equações probabilísticas, as quais são utilizadas como base para se definir as MOs, como visto na Tabela 2. Nota-se que todas as equações derivam das três equações base ($P(A)$, $P(B)$, $P(AB)$), e que equações mais complexas são obtidas a partir das anteriores, como é o caso da equação No. 16, obtida a partir da equação No. 10, que por sua vez foi obtida a partir das Equações de No. 2 e No. 3. Vale mencionar que algumas destas equações já definem, por si só, algumas das MOs existentes na literatura (coluna "Medida").

Embora o suporte e a confiança sejam as MOs mais tradicionais, ao longo dos anos mais de 60 medidas foram propostas, como visto em Tew *et al.* (2014) e Somyanonthanakul e Theeramunkong (2022), visando superar limitações de algumas das medidas até então existentes, como a própria confiança (TAN *et al.*, 2019). Neste trabalho 44 destas MOs foram selecionadas e utilizadas (vide Seção 4.1), as quais encontram-se na Tabela 3, assim como suas abreviações (sigla). A partir deste ponto as MOs serão referenciadas por meio de suas siglas. As equações matemáticas relacionadas a definição das medidas encontram-se no Apêndice A.

Este grande número de MOs existentes gerou um problema secundário, uma vez que não existe uma MO que seja adequada a todas as explorações (SHARMA *et al.*, 2020). Assim, realizar a escolha de uma ou mais medidas para explorar um conjunto de regras torna-se importante dado

Tabela 2 – Probabilidades utilizadas para se definir as MOs disponíveis na literatura.

No.	**Probabilidade**	**Equação**	**Medida**
1	$P(A)$	$P(A)$	Coverage
2	$P(B)$	$P(B)$	Prevalence
3	$P(AB)$	$P(AB)$	**Suporte**
4	$P(\overline{B})$	$1 - P(B)$	1−Prevalence
5	$P(\overline{A})$	$1 - P(A)$	1−Coverage
6	$P(A\overline{B})$	$P(A) - P(AB)$	-
7	$P(\overline{A}B)$	$P(B) - P(AB)$	-
8	$P(\overline{AB})$	$1 - P(B) - P(A) + P(AB)$	-
9	$P(B\|A)$	$\frac{P(AB)}{P(A)}$	**Confiança**
10	$P(A\|B)$	$\frac{P(AB)}{P(B)}$	Recall
11	$P(B\|\overline{A})$	$\frac{P(\overline{A}B)}{P(\overline{A})}$	1−Specificity
12	$P(A\|\overline{B})$	$\frac{P(A\overline{B})}{P(\overline{B})}$	1−Complemente Class Support
13	$P(\overline{B}\|\overline{A})$	$1 - P(B\|\overline{A})$	Specificity
14	$P(\overline{A}\|\overline{B})$	$1 - P(A\|\overline{B})$	Complement Class Support
15	$P(\overline{B}\|A)$	$1 - P(B\|A)$	1−Confiança
16	$P(\overline{A}\|B)$	$1 - P(A\|B)$	1−Recall

os benefícios que se obtêm ao optar por uma ou outra MO. No entanto, fazer a escolha de qual utilizar é um problema difícil (LUNA *et al.*, 2018; SHARMA *et al.*, 2020), visto que existem diferenças significativas em relação aos objetivos (semânticas), entre outros aspectos, que as distinguem. Para tanto, diferentes maneiras foram propostas para realizar esta escolha.

Geng e Hamilton (2006) dividem as propostas de seleção em duas categorias, ranqueamento e agrupamento, conforme apresentado na Tabela 4. Cada solução é também dividida em baseada em comportamento ou baseada em propriedade. O objetivo das abordagens baseadas em ranqueamento é listar as MOs em ordem de importância de maneira que o usuário selecione as n primeiras. Já o objetivo das abordagens baseadas em agrupamento é agrupar as medidas em grupos de modo que o usuário possa selecionar uma medida representativa de cada grupo. Assim, ambas visam reduzir o espaço de busca. Tanto o ranqueamento quanto o agrupamento podem ser realizados tendo como base a similaridade das MOs em relação às propriedades que apresentam ou em relação ao comportamento delas no que se refere a ordenação por elas geradas em um dado conjunto de regras. A solução "Agrupamento" baseado em "Comportamento" é a utilizada neste trabalho para seleção dos conjuntos de MOs a serem agregadas, como será visto na Seção 4.1.

As soluções mencionadas acima têm como objetivo auxiliar o usuário a escolher

Tabela 3 – Medidas objetivas utilizadas neste trabalho.

Nome Completo	**Abreviação**
Accuracy	ACCRC
Added Value	ADD_V
Chi-Square	CHI_SQ
Collective Strength	CLL_STR
Complement Class Support	CP_CL_SP
Conditional Entropy	CON_ENT
Confidence	CNFD
Confidence Causal	CN_CA
Confirm Causal	CF_CA
Confirm Descriptive	CF_DES
Confirmed Confidence Causal	CF_CN_CA
Correlation Coefficient	CORR_COE
Cosine	COSI
Coverage	COVER
Dir	DIR
F-Measure	FME
Gini Index	GIN_IN
Goodman Kruskal	GOO_KRU
Implication Index	IMP_IND
J-Measure	JME
Kappa	KAPP
Klosgen	KLOS
K-Measure	KME
Kulczynski 2	KUL2
Least Contradiction	LST_CNT
Leverage	LEVER
Lift	LIFT
Loevinger	LOEV
Logical Necessity	LOG_NEC
Mutual Information	MU_INF
Normalized Mutual Information	NR_MU_IN
Odd Multiplier	ODD_MUL
Odds Ratio	ODD_RAT
One Way Support	ONE_SUP
Piatetsky Shapiro	PIE_SHA
Prevalence	PREVA
Putative Causal Dependency	PT_CA_DP
Recall	RECA
Relative Risk	REL_RIS
Specificity	SPECT
Support	SUPP
Theil Uncertainty Coefficiente	THE_UNC
TIC	TIC
Two Way Support	TW_SUP

Tabela 4 – Abordagens de escolha de MOs. Fonte: Adaptado de Geng e Hamilton (2006).

Abordagem	Propriedade	Comportamento
Ranqueamento	Lenca *et al.* (2004)	Tan, Kumar e Srivastava (2002)
Agrupamento	Vaillant, Lenca e Lallich (2004)	Tew *et al.* (2014)

(selecionar) as medidas a serem utilizadas para exploração das regras. Contudo, existem abordagens que seguem outra linha. Estas abordagens utilizam-se da ideia de agregar os valores de diversas medidas em um único valor, fazendo com que sejam levadas em consideração a importância de várias medidas ao mesmo tempo, eliminando, consequentemente, a necessidade de se ter uma seleção. Nesta linha pode-se citar o trabalho de Bouker *et al.* (2014), Dahbi *et al.* (2016), Dahbi *et al.* (2020a), entre outros (vide Seção 3.1.2). Esta estratégia de agregação é a utilizada neste trabalho pelo método aqui proposto (vide Capítulo 4).

2.3 Classificação Associativa

A classificação associativa é definida como uma abordagem de classificação baseada em regras de associação; assim, é possível entendê-la como um híbrido entre as duas categorias, em que se aproveita das características exploratórias das RAs com o objetivo de induzir um classificador. Para isto um tipo especial de regra de associação é utilizada, chamada de regra de associação de classe ou regra de associação classificativa (RAC). Diferente das demais regras, as RACs têm o consequente sendo exclusivamente uma classe do problema. Considerando então as RACs extraídas de um dado conjunto de dados obtém-se um modelo capaz de realizar classificações, resultando em um classificador associativo.

A classificação associativa traz consigo vantagens e desvantagens, assim como toda família de algoritmos. Além disso, ela preenche um nicho de uso específico no qual há trabalhos bem consolidados, além de uma gama de novos algoritmos e trabalhos que vêm sendo realizados nos últimos anos, buscando aperfeiçoar algoritmos conhecidos, propor soluções para problemas já conhecidos, entre outros. Assim, esta seção apresenta as vantagens e desvantagens da CA (Seção 2.3.1) e seus algoritmos mais tradicionais (Seção 2.3.2).

2.3.1 Vantagens e Desvantagens

Tratando-se de uma abordagem fortemente ligada às regras de associação, a classificação associativa traz consigo vantagens e desvantagens comuns relacionadas às RAs. Outras vantagens e desvantagens estão relacionadas às etapas da construção dos modelos pelos algoritmos, sendo elas as etapas de extração das regras, ranqueamento e/ou poda e classificação (predição).

As vantagens dos classificadores associativos geralmente citas na literatura são as

seguintes (TAN *et al.*, 2019; SPAGNUOLO, 2021):

- Interpretabilidade. Uma vantagem importante advém de os modelos extraídos serem baseados em regras de associação. Assim, os algoritmos tendem a ser interpretáveis, permitindo a validação e o entendimento de como ocorrem as classificações. Este ponto é de extrema importância em certos campos de uso, como é o caso da medicina, onde entender a classificação fornecida pelo algoritmo permite, além de validar, explicar como se chegou a determinado resultado, agregando não só ao resultado, mas também conhecimento ao entendimento do problema.

- Maior acurácia do que as árvores de decisão. Demonstrou-se na literatura, através de experimentos, vantagens da CA sob outros algoritmos tradicionais, como os de árvore de decisão (LIU; HSU; MA, 1998). Outros trabalhos expandiram os resultados demonstrando uma competitividade com algoritmos de indução de regras e probabilísticos. A CA não trata o problema de maneira gulosa. Ela utiliza um processo que busca regras em um espaço de busca mais abrangente ("completo"), permitindo a descoberta de relações mais específicas do domínio (THABTAH, 2007).

- Não é afetado por dados ausentes na extração. As regras de associação só extraem relações estatisticamente significativas.

- Boa escalabilidade em relação ao tamanho do conjunto de treinamento.

Assim como as vantagens, as desvantagens dos classificadores associativos comumente citadas (TAN *et al.*, 2019; SPAGNUOLO, 2021), são as seguintes:

- A geração das regras pode ser lenta, uma vez que depende da configuração do **sup-min**.

- Redução da escalabilidade em relação ao número de atributos, uma vez que a geração pode se tornar inviável. A depender do número de pares atributo-valor, e da configuração do **sup-min**, uma explosão combinatória pode inviabilizar o processamento. No cenário atual, conciliar modelos com baixos tempos de resposta e capazes de lidar com muitos dados é extremamente necessário. Bechini, Marcelloni e Segatori (2016) também ressaltam esse aspecto negativo referente ao caráter combinacional. Porém, vale mencionar que soluções para este problema de otimização têm sido apresentadas. Thanajiranthorn e Songram (2020) propõem um CA compacto que realiza uma extração de regras com confiança igual a 1 (100%) sem a necessidade de poda e ranqueamento das regras; contudo, os resultados tendem a piorar em cenários contendo dados desbalanceados, como consequência de um conjunto de regras reduzido. Bechini, Marcelloni e Segatori (2016) apresentam o MapReduce Associative Classifier (MRAC), uma extensão do CMAR (LI; HAN; PEI,

2001) com execução distribuída baseado no paradigma MapReduce. Tayal e Meena (2020) exploram a classificação multi-rótulo baseando-se também em MapReduce, propondo dois algoritmos como extensão ao algoritmo MCAR (THABTAH; COWLING; PENG, 2005).

Por fim, alguns autores destacam como desvantagem a dificuldade que os algoritmos de CA têm em alcançar resultados de acurácia como os algoritmos menos interpretáveis, como as redes neurais. Contudo, Rudin (2019) traz ao debate a desvantagem em classificadores em geral, apresentando uma discussão sob o aspecto desta relação inversa entre interpretabilidade e acurácia. Uma vez que CAs são tidos como mais interpretáveis, consequentemente teriam menor acurácia. Segundo Rudin (2019) isto trata-se de um mito, apresentando argumentos contrários a esta problemática e propondo o uso de classificadores mais interpretáveis em detrimento da tentativa de criar modelos de explicação para algoritmos caixa-preta via XAI (Explainable Artificial Intelligence).

2.3.2 Algoritmos Tradicionais

Na literatura de classificação associativa alguns algoritmos tornaram-se tradicionais devido aos seus usos e conceitos. Entre aqueles amplamente citados estão o CBA (LIU; HSU; MA, 1998), o CMAR (LI; HAN; PEI, 2001) e o CPAR (DEHKORDI; SHENASSA, 2006). O CBA é, em geral, utilizado como *baseline* na maior parte dos trabalhos relacionados, sendo também o primeiro algoritmo proposto nesta categoria. De acordo com Filip e Kliegr (2018), o CBA é provavelmente o algoritmo mais utilizado da família. Assim, inicialmente, apresenta-se o funcionamento dele.

A construção de um classificador associativo, via CBA, assim como na maioria dos demais algoritmos, ocorre em etapas, a saber: [A] extração de um conjunto de regras de associação classificativas (consequente das RAs contém apenas rótulos de classe); [B] geração do modelo via ranqueamento e/ou poda das regras geradas e [C] predição. Em relação ao CBA, Liu, Hsu e Ma (1998) apresentam uma adaptação do algoritmo Apriori para obtenção das regras de associação classificativas (etapa [A]). A adaptação realizada não será aqui apresentada por ser bem similar ao Apriori já explicado anteriormente. A partir do conjunto de regras de associação classificativas (RACs) obtido, o classificador via CBA é construído (etapa [B]). O Algoritmo 3 apresenta os passos necessários para a realização da construção, as quais são descritas a seguir:

Ranqueamento. A partir das RACs extraídas, armazenadas em R, ordena-as da maior para a menor de acordo com a relação $\succ$ (linha 1). Dado duas regras, r_i e r_j, $r_i \succ r_j$, ou seja, r_i tem maior precedência que r_j se:

1. a confiança de r_i for maior que a de r_j, ou

2. se as confianças forem iguais, mas o suporte de r_i for maior que o suporte de r_j, ou
3. tanto a confiança como o suporte são iguais, mas r_i foi gerada primeiro que r_j.

Este método de ranqueamento é conhecido pela sigla **CSC** (Confiança, Suporte, Cardinalidade), o qual será referenciado posteriormente como **[CSC]** (vide Capítulo 5).

Poda. Para cada regra $r \in R$, ordenadas por precedência, percorre-se o conjunto de treinamento D visando encontrar as transações $d \in D$ que são *cobertas* por r, ou seja, que satisfaçam as condições impostas por r (linha 6). Caso r classifique corretamente alguma das transações *cobertas* pela mesma, o algoritmo marca r (linha 8), de modo que r vira uma potencial candidata para o classificador (linhas 11-16). Posteriormente, todos os casos *cobertos* por r são deletados de D (linha 13) e uma classe default (majoritária) (considerando o restante de D) é associada ao classificador (linha 14). Na sequência, computa-se e armazena-se o número total de erros que o classificador atual possui (soma dos erros de cada regra em C mais os erros cometidos ao se utilizar a classe default (linha 15)). Por fim, quando não existirem mais regras r ou transações em D, o critério de parada da seleção de regras é atingido (linha 17).

Este método de poda é conhecido pela sigla **M1**, o qual será referenciado posteriormente como **[M1]** (vide Capítulo 5).

Finalização do modelo. Considerando todas as regras selecionadas, procura-se pela primeira regra que possui o menor número total de erros e descarta-se todas as regras subsequentes a esta, uma vez que não melhoram a precisão do classificador. Finalmente, a classe default do classificador atual C é associada ao fim do mesmo como uma regra padrão e o classificador é retornado (linhas 18-19). Portanto, ao final, um classificador C, dado por C = $\{r_1, r_2, r_3, ..., r_n$, classe default$\}$, é retornado, em que $r_i \in$ R e $r_i \succ r_j$.

Este método de predição será referenciado posteriormente como **[O]** (**O**rdinal prediction) (vide Capítulo 5).

Por fim, a partir do modelo obtido, para que uma nova instância seja classificada (etapa [C]) utiliza-se a classe associada à primeira regra que satisfizer as características do objeto.

Algoritmo 3 Pseudocódigo do algoritmo CBA referente à geração do modelo. Fonte: Liu, Hsu e Ma (1998).

Entrada: Conjunto de Dados D; Conjunto de Regras de Associação Classificativas R
Saída: Classificador C

```
1  R_sort = ordena(R) //ordena de acordo com a precedência ≻
2  para (cada regra r ∈ R_sort) faça
3      temp = ∅
4      r_correto = Falso
5      para (cada caso d ∈ D) faça
6          se (d satisfaz as condições de r) então
7              temp = temp ∪ d
8              r_correto = Verdadeiro
9          fim
10     fim
11     se (r_correto) então
12         C = C ∪ r //insira r no fim do classificador C
13         D = D − temp //remova todos os casos de D
14         selecione uma classe default para o classificador C corrente
15         calcule o número total de erros de C
16     fim
17 fim
18 encontre a primeira regra p em C com o menor número total de erros e descarte todas as regras
     após p em C
19 insira a classe default associada a p no final de C
```

Existem semelhanças e diferenças entre os três algoritmos de classificação associativa mais utilizados, i.e., CBA, CMAR e CPAR. Em relação às semelhanças está a estrutura de construção dos modelos. Todos eles são construídos em um processo sequencial de extração de regras, ranqueamento e/ou poda e classificação. Este processo também se faz presente em boa parte dos algoritmos de CA, sofrendo modificações, como uma segunda etapa de poda ou mesmo a ausência da mesma, assim como o uso de algoritmos distintos para se realizar a extração das regras como, por exemplo, o FP-Growth (HAN; PEI; YIN, 2000) em vez do Apriori. Portanto, a seguir, encontra-se uma explicação sucinta dos outros dois algoritmos mencionados.

CMAR. O algoritmo CMAR segue as mesmas etapas de construção do CBA. Contudo, em cada uma das etapas é empregado um método diferente. As etapas de construção são as seguintes: a geração de regras é feita adaptando-se o algoritmo FP-Growth, que busca ser mais eficiente, escalável e focado na extração de RACs. A segunda etapa é realizada com a ordenação das regras via método CSC, seguido por uma poda utilizando um teste qui-quadrado (χ^2) para checar a correlação positiva entre o antecedente e a classe. Na terceira etapa a classificação é realizada por meio de um grupo de regras que cobrem o exemplo, as quais são ponderadas por uma equação qui-quadrado.

CPAR. Os autores propõem um processo que também pode ser dividido em três etapas. Na

primeira delas é proposto o uso de uma adaptação do algoritmo FOIL (QUINLAN; CAMERON-JONES, 1993) para gerar as RACs com melhor eficiência. Na segunda etapa as k melhores regras são selecionadas utilizando uma medida de acurácia (Laplace Accuracy). A poda é realizada por meio da exclusão do restante das regras que não fazem parte do conjunto de k regras e o ranqueamento é feito por meio desta medida. Na terceira etapa é realizada a checagem das regras que podem ser aplicadas ao exemplo a fim de realizar a classificação. Havendo mais de uma classe possível a escolha é realizada por meio do valor médio da medida calculada (i.e., Laplace Accuracy).

Cada algoritmo busca abordar o problema da CA de uma maneira, buscando sempre melhorar o desempenho e/ou a interpretabilidade. Como visto, os três algoritmos buscam melhorar todas as etapas da construção. Assim, estes trabalhos se tornaram tradicionais, dando base para outros novos algoritmos propostos nos últimos anos.

2.3.3 Critérios de Avaliação

A tarefa de classificação tem por objetivo atribuir uma categoria, chamada de classe, para instâncias não rotuladas. Assim, uma vez que os modelos são obtidos, é necessário que avalie-os na métrica de desempenho em dados ainda não vistos. Para tanto, medidas de avaliação são utilizadas, como precisão, revocação e medida-F (versões micro e/ou macro e/ou macro ponderada). Além disso, a fim de garantir uma boa estimativa da medida de avaliação, assim como viabilizar a configuração dos hiperparâmetros, diferentes estratégias de validação podem ser utilizadas, como *holdout*, validação cruzada (*cross-validation*) e validação cruzada estratificada. Assim, em relação ao desempenho, este trabalho avalia o método de ranqueamento via agregação de MOs proposto, em fluxos de CAs, via F1-Macro estimada via 10-fold cross-validation estratificado. Entende-se que estes conceitos apresentam-se como definições básicas na literatura de aprendizado de máquina, e, portanto, não serão aqui detalhados. Estes termos podem ser consultados em Tan *et al.* (2019).

Contudo, um outro critério importante a ser utilizado para se avaliar modelos induzidos via algoritmos baseados em regras (*rule-based*) é a interpretabilidade. De acordo com Margot e Luta (2021), a interpretabilidade vem se tornando cada vez mais importante no contexto de tarefas preditivas, embora ainda não haja um consenso sobre esta noção. Em geral, como nota-se em Rudin (2019), Margot e Luta (2021) e Molnar (2022), é possível se obter modelos de predição interpretáveis (i) via algoritmos não interpretáveis, como redes neurais profundas, sobre os quais aplicam-se métodos de XAI, ou (ii) via algoritmos inerentemente interpretáveis, como os baseados em regras e árvores. Ainda de acordo com Margot e Luta (2021), embora algoritmos inerentemente interpretáveis pareçam fáceis de se entender, não existe uma definição matemática exata para o conceito de interpretabilidade. Assim, cada trabalho opta por avaliar este critério

por meio de uma medida distinta.

Margot e Luta (2021) propõem um *score* de interpretabilidade baseado na soma ponderada de três aspectos: previsibilidade (*predictivity*), estabilidade (*stability*) e simplicidade (*simplicity*). A simplicidade (S), definida na Equação 2.3 (adaptada de Margot e Luta (2021)), armazena a soma acumulada do "Tamanho" (*length*) de cada uma das regras contidas em um dado modelo M. O "Tamanho" é computado pelo número de itens contidos no antecedente da regra: quanto menos itens, mais geral a regra é, e, em tese, mais interpretável. Assim, a medida considera tanto a quantidade de regras contidas no modelo quanto o tamanho delas, uma vez que quanto mais regras ou regras maiores, menor a interpretabilidade do mesmo.

$$S_M = \sum_{\substack{i=1; \\ r_i \in M}}^{n} Tamanho(r_i) \tag{2.3}$$

A medida proposta (S_M) acaba por ser mais difícil de interpretar, uma vez que um alto valor pode ser obtido combinando-se, por exemplo, um alto número de regras, porém com tamanhos pequenos, ou um baixo número de regras, porém com tamanhos elevados. Assim, outros trabalhos optam por quebrá-la em duas: uma que mensure a quantidade de regras e outra o tamanho das mesmas. Uma vez que os CAs são baseados em regras de associação, é possível se definir, durante a extração das mesmas, o tamanho máximo que as RACs poderão atingir. Deste modo, a medida relacionada ao tamanho das mesmas acaba não variando muito, já que as regras são ordenadas, entre outros critérios, pela cardinalidade, das mais gerais para as mais específicas, e que o tamanho máximo considerado foi definido em 4 (vide Capítulos 4 e 5).

Diante do exposto, neste trabalho optou-se por medir a interpretabilidade por meio do número de regras contidas no modelo, como em outros trabalhos recentes no contexto de CA (MATTIEV; DAVITYAN; KAVSEK, 2023; BUI-THI; MEYSMAN; LAUKENS, 2022; MATTIEV; MEZA; KAVSEK, 2022; SOOD; ZAIANE, 2020; RAJAB, 2019; LAKKARAJU; BACH; LESKOVEC, 2016). Em todos estes trabalhos, quanto menor a quantidade de regras melhor o modelo induzido, i.e., mais interpretável ele é. Por fim, vale mencionar que a mesma é também estimada via 10-fold cross-validation estratificado. Este critério foi denominado aqui de tamanho do modelo.

3 Trabalhos Relacionados

Conforme apresentado (Seção 2.3), a maior parte dos algoritmos tradicionais de CA realizam a indução do modelo em três ou quatro etapas, a saber: [A] Extração, [B] Ranqueamento e/ou Poda e [C] Predição, conforme pode ser visto na Figura 1. As mesmas influenciam diretamente a qualidade do modelo gerado. Por exemplo, a extração de poucas regras pode levar a um modelo pouco preciso, enquanto um ranqueamento inadequado pode resultar na perda de regras importantes. Além disso, a poda pode remover boas regras do conjunto final. Em vista disso, esforços têm sido realizados para melhorar cada uma dessas etapas.

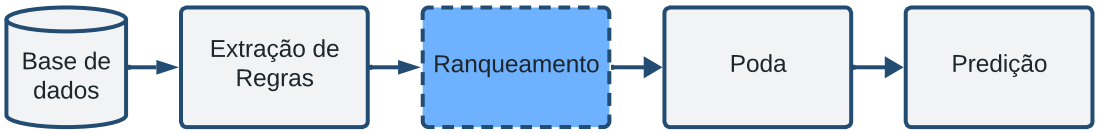


Figura 1 – Etapas envolvidas na indução de um CA.

Nota-se, na Figura 1, que cada etapa do processo de indução pode ser visto como um método independente, que em conjunto são capazes de gerar um modelo. O CBA, o CMAR e o CPAR, como descrito na Seção 2.3, podem ser vistos desta maneira. Assim, no que se refere à proposta apresentada no Capítulo 1, i.e., desenvolver e avaliar um método de ranqueamento via agregação de MOs que possa ser incorporado a fluxos de indução de CAs, nota-se, na Figura 1, que a etapa em destaque é a que deve ser modificada em tais fluxos.

Diante do exposto, este capítulo tem por objetivo apresentar, na Seção 3.1, trabalhos relacionados a cada uma das etapas apresentadas na Figura 1, i.e., métodos distintos por etapa, sendo algum deles utilizados posteriormente na avaliação do método aqui proposto (Capítulo 5). Por fim, na Seção 3.2 apresenta-se um trabalho bem correlacionado a este, do qual se utilizou alguns métodos durante a avaliação do método aqui proposto.

3.1 Etapas dos Classificadores Associativos

3.1.1 Extração

A extração das regras é frequentemente associada a dois algoritmos amplamente utilizados, o Apriori e o FP-Growth (BECHINI; MARCELLONI; SEGATORI, 2016). Contudo, novos trabalhos apresentam-se com o objetivo de trazer algoritmos com soluções melhores em diferentes tópicos. Tratando-se de performance, um tema recorrente nos trabalhos de extração, algumas

soluções visam dar uma melhor escalabilidade para os algoritmos de extração, tal como em Nguyen *et al.* (2016), em que a extração de regras é realizada impondo-se restrições nos *itemsets*, resultando em uma significativa redução no tempo de execução. Nguyen, Nguyen e Trawiński (2016) também apresentam outra implementação de extração eficiente baseada no algoritmo *QuickSort* visando a geração das melhores regras não redundantes tendo como base o algoritmo TopKRules (VIGER; WU; TSENG, 2012). A qualidade das regras extraídas também gera trabalhos com propostas de melhorias, uma vez que só nesta etapa as regras são passíveis de serem descobertas, impactando diretamente a qualidade dos CAs.

Outro aspecto amplamente discutido nesta etapa é o problema de classes desbalanceadas, uma vez que classes minoritárias têm um menor suporte, causando problemas na extração, afetando assim o classificador final. Trabalhos como Hu *et al.* (2016) propõem uma solução para a problemática de suporte mínimo baseado no CBA e em múltiplos suportes mínimos, visando diminuir o impacto de apenas um valor de suporte para todas as classes e abranger a descoberta de mais regras raras. Abdellatif, Hassine e Yahia (2019) propõem cinco novas medidas baseando-se em modificações da MO Lift visando melhorar a extração de regras também no contexto de dados desbalanceados. Mittal (2021) apresentam um processo de ranqueamento e poda ainda na fase de geração das regras a fim de diminuir o número de RACs e aumentar a acurácia. Assim, existem diversos trabalhos relacionados à extração de regras buscando melhorar a eficiência e a qualidade das mesmas por meio de diversas técnicas, como a criação de MOs, novos métodos de se buscar as regras nos dados, modificar MOs existentes, entre outros.

Neste trabalho a extração de regras foi a única etapa em que métodos distintos não foram avaliados, uma vez que comumente os métodos desta etapa estão relacionados à performance (eficiência), embora possa impactar o restante das etapas e ser a única etapa que ocorre antes do ranqueamento. No entanto, existem trabalhos recentes na literatura voltados a este aspecto.

3.1.2 Ranqueamento

A etapa de ranqueamento é de grande importância na construção de classificadores associativos, pois afeta diretamente o desempenho do classificador, já que impacta as etapas subsequentes (poda e predição) (vide Figura 1). Assim, diversos trabalhos buscam melhorar esta etapa, visando realizar uma ordenação das regras que favoreça o desempenho do modelo gerado e a interpretabilidade por meio de um conjunto de regras compacto.

No entanto, frequentemente, o ranqueamento é realizado por meio da medida de confiança, seguida pelo suporte e pela cardinalidade (CSC (vide Seção 2.3.2)). Contudo, outras propostas surgiram ao longo dos anos, seja por meio: de novas medidas e/ou medidas já existentes em outros contextos, mas aplicadas nesta etapa de maneira singular (**[MS]**[1]); da união (agregação)

[1] **M**étodo **S**ingular.

de medidas existentes de maneira a usá-las simultaneamente (**[MA]**[2]). Em geral, as soluções são baseadas em trabalhos desenvolvidos para o contexto de regras de associação, os quais são, então, adaptados para o contexto de classificadores associativos. Uma vez que a literatura para RA é vasta, apresentam-se também alguns trabalhos voltados ao contexto de RAs para que se compreenda as propostas existentes.

Em relação a utilização de novas medidas e/ou medidas já existentes de maneira singular (**[MS]**), muitos trabalhos já foram desenvolvidos no contexto de regras de associação. Cada uma das mais de 60 medidas apresentadas e utilizadas no trabalho de Tew *et al.* (2014) são exemplos de proposição de novas medidas a serem utilizadas de maneira singular, as quais já se tornaram tradicionais. Contudo, trabalhos recentes ainda continuam propondo novas medidas. Em Datta e Bose (2016), por exemplo, as regras são ordenadas a partir de uma nova medida denominada *Rank Index*, sendo o resultado derivado de uma equação envolvendo as medidas de suporte, confiança, correlação e dissociação. Datta, Mali e Roy (2018) apresentam a medida *Gravity*, a qual é composta pela compactação de outras sete MOs. Observe, nestes dois casos, como será visto mais adiante, que a medida é única e, após computada, usada de maneira singular, diferente do que acontece na agregação.

Considerando o **[MS]**, mas no contexto de CA, diversas medidas já incluídas em Tew *et al.* (2014) foram propostas com o objetivo de melhorar a CA. Lan *et al.* (2005) propõem a Dilated χ^2, uma medida que representa a interdependência estatística entre antecedente e consequente. Ainda neste trabalho, uma análise a respeito dos problemas acerca da medida confiança também foi realizada, demonstrando ser recorrente. O uso inicial da medida é testado no CBA, apresentando bons resultados e classificadores mais compactos. Em Arunasalam e Chawla (2006) a MO *Complement Class Support* é introduzida. Buscando melhorar a efetividade de um classificador associativo para dados desbalanceados, um problema recorrente na CA, a medida é formulada com o objetivo de extrair, podar ou ranquear RACs. Por outro lado, outros trabalhos utilizaram e/ou avaliaram as medidas objetivas, originalmente empregadas no contexto de regras de associação, nos CAs. Azevedo e Jorge (2007) avaliaram a medida *Conviction* contra outras 10 MOs buscando determinar uma vantagem na utilização; segundo os autores, conclui-se que ela traz vantagens frente a outras em relação ao ranqueamento. Jalali-Heravi e Zaïane (2010) apresentam um estudo sobre o impacto de 53 MOs, avaliando a aplicação delas tanto no ranqueamento apenas quanto na poda e no ranqueamento, concluindo que existem medidas que obtêm uma significativa melhoria no CA gerado, mas também que não existe apenas uma MO que se mantém ótima em todos os casos. Dharini, Jayanthi e Joyce (2019) concatenam três abordagens conhecidas em um processo de construção do CA, sendo a extração a partir de uma estrutura de árvore. Na segunda etapa, a poda ocorre antes do ranqueamento e é realizada através da medida *Jaccard* para seleção de regras fortes e, por fim, o ranqueamento é realizado

[2] **M**étodos **A**gregados.

pela medida *Principality*.

Um ponto comum nos trabalhos acima citados é o uso das MOs de maneira isolada, ou seja, a ordenação é realizada por meio de uma única medida, e as demais medidas são utilizadas apenas para desempates. Os trabalhos também discutem que o uso de apenas uma MO nem sempre é adequado para todas as situações, ou seja, para todos os conjuntos de dados (LE; LO, 2015). Outro ponto importante a destacar é que diferentes trabalhos utilizam diferentes quantidades e tipos de MOs, cabendo aos autores a decisão de explorar mais ou menos medidas.

Uma alternativa a este método é a utilização de várias medidas simultaneamente (**[MA]**). Este processo é feito por meio da agregação de MOs, na qual, utilizando-se de um operador de agregação, é realizada a junção de duas ou mais medidas. Realizar este procedimento traz a vantagem de diminuir a necessidade da escolha de uma só medida, considerando também diferentes aspectos (semântica) para a mesma regra (LE; HUYNH; GUILLET, 2009).

Tal como o item **[MS]**, trabalhos relacionados à agregação de medidas foram desenvolvidos no contexto de regras de associação. Le, Huynh e Guillet (2009) propõem o uso da Integral de Choquet para realizar a tarefa de agregar diversas MOs. Os autores citam como vantagem da agregação os múltiplos "pontos de vista" que são fornecidos pelo uso simultâneo das MOs. Ainda que não tenha sido proposto efetivamente para a etapa de ranqueamento, o trabalho apresenta um ponto de início para a discussão a respeito da agregação de MOs no contexto de regras. Bong *et al.* (2014) apresentam uma revisão sobre trabalhos que realizam agregação de MOs para aplicação em RAs, discorrendo também a respeito da seleção de MOs, explorando esta problemática a respeito de diversas MOs e sua relação com os conjuntos de regras. Bouker *et al.* (2014) propõem uma solução de ranqueamento de regras por meio da adaptação do operador *Skyline* (BORZSONY; KOSSMANN; STOCKER, 2001). A agregação das MOs é realizada pela relação de dominância de Pareto entre os valores das MOs das regras. A dominância de Pareto, neste contexto, consiste em uma formulação das relações entre as regras, na qual uma determinada regra domina outra baseando-se nos valores de suas MOs. As relações geradas entre as regras são responsáveis por criar grupos hierárquicos, em que regras pertencentes aos grupos de níveis mais baixos são dominadas por regras de grupos com níveis mais altos. Portanto, uma relação de dominância de uma regra sobre outra indica que uma determinada regra é mais significativa que a outra em uma ou mais medidas. Dahbi *et al.* (2016) também utilizam dominância de Pareto como base para ranquear as regras de duas maneiras diferentes: uma que utiliza o número de ocorrências de dominância de uma regra sobre as demais e a outra da quantidade das demais regras que a dominam. Este procedimento resulta em dois ranqueamentos, um de maneira ascendente, na qual as regras menos dominadas são ranqueadas primeiro, e a outra de maneira descendente, no qual as que mais dominam outras regras são ranqueadas primeiro. Em ambos os casos, a relação de dominância ranqueia as regras dada a importância delas considerando todas as MOs ao mesmo tempo, uma vez que leva em conta a avaliação que cada MO atribuiu para uma determinada regra.

Recentemente, outras maneiras de agregar MOs, utilizando-se de soluções da área de análise de decisão multicritérios (MCDA), foram utilizadas. Mazouri, Abounaima e Zenkouar (2017) e Dahbi *et al.* (2020b) empregam ideias semelhantes no que tange a agregação através do uso do ELECTRE I (ROGERS; BRUEN; MAYSTRE, 2000) no contexto de RAs a fim de selecionar um conjunto de regras relevantes. Contudo, nota-se que o intuito não é gerar uma ordem, uma vez que o ELECTRE I é um método de seleção. Para se obter um conjunto ordenado deve-se utilizar o ELECTRE II. Assim, Mazouri, Abounaima e Zenkouar (2019) empregam o ELECTRE II (ROGERS; BRUEN; MAYSTRE, 2000) no ranqueamento de regras utilizando o suporte, a confiança e o lift (medida 27 da Tabela 16), simultaneamente, no contexto de segurança de tráfego. Os autores destacam os motivos do uso do ELECTRE II, como o fato do método permitir que uma avaliação fraca seja compensada por outra forte como, por exemplo, uma regra que receba um valor baixo em uma MO, mas um valor alto em outra. Destaca-se também a capacidade de lidar com valores em escalas diferentes, visto que MOs podem variar em intervalos fechados pequenos como [-0,25, 0,25] ou intervalos abertos como $]-\infty,+\infty[$.

Vale mencionar que, tanto nas soluções que utilizam Pareto, como nas que utilizam MCDA, o objetivo de se agregar as MOs para se ranquear as regras vem do fato que cada medida provê um ranqueamento de acordo com sua semântica e, que, portanto, considerando todas simultaneamente, obtém-se múltiplas visões que, em conjunto, colaboram para um ranqueamento mais abrangente, não ficando restrito à visão enviesada de uma ou duas MOs (LE; HUYNH; GUILLET, 2009).

Os métodos até aqui apresentados no contexto de agregação de MOs focaram apenas no uso geral das regras e não na CA ou nas RACs. Assim, considerando o **[MA]**, mas no contexto de CA, alguns trabalhos foram realizados. Silva e Carvalho (2018) exploram o uso agregado de MOs via Pareto quando aplicadas para ranquear as regras, tendo como base o trabalho de Bouker *et al.* (2014). Neste caso, o ranqueamento proposto é avaliado na etapa de ranqueamento do CBA. Dall'Agnol e Carvalho (2020b) expandem o trabalho de Silva e Carvalho (2018) avaliando uma segunda abordagem discutida em Bouker *et al.* (2014), além de duas outras abordagens propostas em Dahbi *et al.* (2016). Os autores propõem também duas abordagens híbridas de maneira a encontrar um equilíbrio entre as soluções base anteriormente utilizadas, obtendo bons resultados quando comparados ao CBA. Já Dall'Agnol e Carvalho (2020a) realizam a agregação por meio de um comitê de classificadores, em que cada modelo do comitê é induzido utilizando-se uma medida distinta. Em Dall'Agnol e Carvalho (2023b) uma descrição dos trabalhos de Silva e Carvalho (2018) e Dall'Agnol e Carvalho (2020a) é apresentada, os quais são comparados com a proposta aqui apresentada. Por fim, Bui-Thi, Meysman e Laukens (2022) exploram a agregação de MOs na etapa de ranqueamento via uma modelagem de otimização multiobjetivo, descrita em maiores detalhes na Seção 3.2. Vale mencionar que embora estes trabalhos sejam promissores, os mesmos apresentam problemas em relação ao desempenho e/ou a interpretabilidade dos modelos

gerados. Em todos estes trabalhos é possível verificar uma relação inversa entre desempenho e interpretabilidade, i.e., quando o desempenho do modelo é alto, a interpretabilidade é baixa. Por outro lado, quando o desempenho do modelo é baixo, a interpretabilidade é alta.

3.1.3 Poda

A poda, tal como o ranqueamento, pode ser omitida a depender do fluxo de indução do modelo. Contudo, quando está presente, seu impacto é grande, sendo responsável, por exemplo, pela redução do tamanho do conjunto de regras e remoção de regras redundantes ou de baixa qualidade. Ainda que o processo de poda seja, frequentemente, realizado após o ranqueamento, de maneira a não afetar diretamente o ranqueamento em si, ainda se faz necessária a busca de trabalhos relacionados à esta etapa, pois o impacto no resultado depende também da concordância entre ambas as etapas, quando presentes. Além disso, é uma das etapas onde se encontra uma boa parcela dos trabalhos envolvendo CAs, existindo propostas com as mais diversas finalidades visando sua melhoria.

Como mencionado, a redução do número de regras é um dos focos da etapa de poda, uma vez que classificadores mais compactos são mais fáceis de serem interpretados. Azmi e Berrado (2016) apresentam uma abordagem de poda utilizando uma propriedade de seleção de variável baseada na regularização *Lasso* para podar as regras, obtendo bons resultados comparando-se ao CBA e à própria regularização *Lasso*. Mattiev e Kavšek (2021) tratam a redução de RACs por meio de um agrupamento hierárquico utilizando, para tanto, a similaridade entre elas, de modo a definir uma RAC representativa por grupo. Outro objetivo comum na poda é realizar um pós-processamento das regras extraídas a fim de selecionar as regras mais adequadas, visando elevar a qualidade final do modelo. Sivanantham *et al.* (2021) discorrem a respeito do uso de uma nova MO com a finalidade de realizar a poda em CAs no contexto de sistemas de detecção de intrusão. Mattiev e Kavsek (2020) propõem um algoritmo baseado na cobertura das regras e sua contribuição no conjunto de dados para gerar um CA mais preciso e compacto. Mais recentemente, Mattiev, Davityan e Kavsek (2023) utilizam-se do algoritmo k-modas para gerar agrupamentos de regras e eleger uma regra para cada grupo, compactando assim o classificador final. Os resultados mostram que a proposta é capaz de obter classificadores com menos regras quando comparados com outros algoritmos avaliados (CBA, CMAR, CPAR, etc.), com um menor tempo de execução, mantendo ainda a acurácia competitiva em relação aos demais.

Conforme mencionado no início deste capítulo, nota-se, na Figura 1, que cada etapa do processo de indução pode ser vista como um método independente. Assim, para avaliar o método aqui proposto, alguns métodos de poda foram selecionados para compor diferentes fluxos algorítmicos, juntamente com o método de ranqueamento em análise, a fim de avaliar seu desempenho. Assim, os métodos abaixo descritos são os utilizados, assim como os tradicionais

(CBA), nos experimentos do Capítulo 5.

[DN][3]: **Poda de Sood e Zaiane (2020)** (Poda Dinâmica). O método de poda apresentado por Sood e Zaiane (2020) foi um dos selecionados e adaptados para este trabalho. No referido trabalho um CA é induzido por meio de uma de poda iterativa, a qual funciona em conjunto com uma etapa de ranqueamento, como descrito a seguir:

- Ranqueamento: as regras do conjunto R são ranqueadas de acordo com uma medida objetiva;
- Seleção: a primeira regra r_i do conjunto R é selecionada;
- Remoção de Instâncias: todas as instâncias (transações) cobertas por r_i são removidas do conjunto de dados;
- Remoção de Regra: a regra r_i é removida do conjunto de regras R;
- Atualização das MOs: as regras remanescentes do conjunto R têm seus valores de MOs atualizados tendo como base as intâncias restantes.

O processo acima descrito é repetido até que todas as regras tenham sido processadas ou que não haja mais instâncias a serem cobertas. O processo é custoso, pois envolve o recálculo de todas as medidas objetivas utilizadas a cada iteração. No entanto, a cada iteração garante-se que a melhor regra é selecionada, dado o estado atual do conjunto de dados.

[CV][4]: **Poda de Bui-Thi, Meysman e Laukens (2022)** (Poda por Cobertura). O método de poda apresentado por Bui-Thi, Meysman e Laukens (2022) é baseado na cobertura com que as regras, já ordenadas, casam com as transações. O referido método encontra-se descrito na Seção 3.2.

3.1.4 Predição

A predição é a etapa em que se determina a classe para as instâncias não vistas. Nesta etapa há, em geral, o emprego de dois procedimentos: um pela precedência das regras, impactada diretamente pelo ranqueamento e/ou poda, denominado de "*Rule List*", e outro por meio de múltiplas regras, denominado de "*Rule Set*" (KLIEGR, 2019). No primeiro emprega-se uma única regra para se determinar a classe, a de melhor precedência que case com a instância, enquanto que no segundo um conjunto de regras é utilizado para se definir a mesma. O CBA é o mais conhecido expoente do procedimento de precedência, enquanto no segundo caso o CMAR, o qual faz uso do χ^2 de múltiplas regras para determinar a classe (vide Seção 2.3).

[3] **D**y**N**amic pruning.
[4] **Co**-**V**erage pruning.

Dentro dos dois procedimentos acima, diversas podem ser as maneiras de se realizar a predição. Como exemplos mais recentes, Li e Zaiane (2017) apresentam o algoritmo *SigDirect*, um processo completo de construção de um classificador associativo, contando com a extração de regras atraves do teste de significância de Fisher, poda de regras redundantes e proposta de três métodos de predição do tipo "*Rule Set*". Cada um dos três métodos utiliza um valor para se definir a classe, os quais podem ser computados via confiança, teste de significância de Fisher (teste exato de Fisher) e utilizando-se ambos os valores. Em Sood e Zaiane (2020), além do método de poda citado anteriormente, os autores apresentam dois métodos de predição, um baseado em *Bagging* e outro em *Boosting*. Ambos os modelos são construídos por meio de um modelo fraco, chamado *wSigDirect*. No *Bagging* a estratégia usada é a do modelo de Breiman (1996), enquanto no *Boosting* utiliza-se o Adaboost (FREUND; SCHAPIRE, 1996). Dall'Agnol e Carvalho (2020a) implementam um comitê de classificadores baseados no CBA, no qual cada classificador tem sua etapa de ranqueamento substituída pela ordenação de uma medida objetiva específica. Por meio de uma votação majoritária entre os classificadores a classe é definida. Neste caso, pode-se interpretar a solução como "*Rule Set*", uma vez que cada instância será definida por várias regras, ainda que cada classificador base tenha gerado uma classificação por precedência ("*Rule List*").

Para avaliar o método aqui proposto, assim, como na etapa de poda, alguns métodos de predição foram selecionados para compor diferentes fluxos algorítmicos, juntamente com o método de ranqueamento em análise, a fim de avaliar seu desempenho. Assim, os métodos abaixo descritos são os utilizados, assim como os tradicionais (CBA), nos experimentos do Capítulo 5.

[R][5]: **Predição de Ayyat, Lu e Thabtah (2014)** (Predição baseada em Rank). O método de predição apresentado por Ayyat, Lu e Thabtah (2014) foi um dos selecionados para este trabalho. No referido trabalho a predição acontece via "*Rule Set*", porém a mesma leva em consideração também a ordem das regras, característica do "*Rule List*". O método proposto visa (i) solucionar o problema de considerar apenas a primeira regra, acarretando no descarte de outras regras potencialmente úteis, assim como (ii) evitar de se utilizar equações matemáticas complexas para se computar o peso das regras, dificultando a interpretabilidade do processo. Para tanto, os autores propõem o seguinte processo: a classe de uma dada instância é dada pela maior soma, obtida entre duas pontuações, em uma das possíveis classes. A primeira pontuação é obtida somando-se os ranks das regras que casam com a instância a ser predita em uma dada classe. A segunda pelo número de regras de uma dada classe que casam com a instância. O algoritmo pode ser resumido da seguinte maneira:

- para cada regra r_i em R, verifica-se se r_i cobre a instância t;
- se r_i cobrir t, as seguintes operações são realizadas:

[5] **R**ank-based prediction.

  - a primeira pontuação da classe de r_i é incrementada com a posição do rank da mesma;
  - a segunda pontuação da classe de r_i é incrementada em 1;

- cada classe c que cobre t recebe uma pontuação total, dada pela soma das duas pontuações acima obtidas;
- a classe c com a maior pontuação total é a utilizada para predizer a classe de t.

[V][6]: **Predição baseada em Votação**. Este método é uma simplificação dos métodos "*Rule Set*". A maior parte dos métodos utiliza algum ponderador entre as regras para realizar a predição como, por exemplo, no CPAR, a qual é feita a partir da média de acurácia das top-k regras que cobrem a instância a ser classificada em cada uma das classes. Neste trabalho uma versão simplificada é utilizada, de maneira que a classe é selecionada por meio de um procedimento de votação majoritária simples entre as regras que cobrem a instância. Como exemplo, havendo três regras com consequentes, respectivamente, B_1, B_1 e B_2, que cubram uma instância t_i, teria-se B_1 como classe predita.

[P][7]: **Predição de Bui-Thi, Meysman e Laukens (2022)** (Predição Probabilística). O método de predição apresentado por Bui-Thi, Meysman e Laukens (2022) é baseado em probabilidades computadas tendo como base as k melhores regras que cobrem a instância a ser predita. O referido método encontra-se descrito na Seção 3.2.

3.2 MoMAC: *Multi-objective Optimization to Combine Multiple Association Rules into an Interpretable Classification*

Além dos trabalhos de Silva e Carvalho (2018), Dall'Agnol e Carvalho (2020b) e Dall'Agnol e Carvalho (2020a), já citados na Seção 3.1.2, o trabalho de Bui-Thi, Meysman e Laukens (2022) é um dos mais recentes relacionados à proposta aqui apresentada. Embora os autores apresentem um fluxo algorítmico completo, o foco do trabalho encontra-se justamente na etapa de ranqueamento por meio do uso simultâneo de múltiplos valores, os quais fornecem a base para o cálculo de todas as MOs existentes. Estes valores são as 16 probabilidades apresentadas na Tabela 2 da Seção 2.2. Assim, o ranqueamento pode ser visto como uma agregação de valores, a partir dos quais um valor é gerado para que as regras possam ser ordenadas de maneira a melhorar o desempenho e a interpretabilidade dos modelos induzidos. O algoritmo tenta, de fato, otimizar estes dois critérios. Por este motivo, optou-se por descrever as etapas do algoritmo por eles proposto, denominado MoMAC, nesta seção. Além disso, seus métodos de poda e predição foram selecionados e implementados para compor diferentes fluxos algorítmicos, como

[6] **V**oting prediction.
[7] **P**robabilistic prediction.

já mencionado anteriormente, para se avaliar o método de ranqueamento aqui proposto. Vale mencionar que os detalhes dos trabalhos de Silva e Carvalho (2018) e Dall'Agnol e Carvalho (2020a) são apresentados no artigo Dall'Agnol e Carvalho (2023b), os quais são comparados com a proposta aqui apresentada. Considerando o fluxo da Figura 1, segue abaixo a descrição de cada uma das etapas do MoMAC.

Extração. A etapa de extração, tal como neste trabalho, não é explorada, havendo apenas a menção de uma modificação no algoritmo Apriori para uma extração mais eficiente das RACs.

Ranqueamento. O método de ranqueamento por eles proposto pode ser visto como apresentado na Figura 2 (vide Capítulo 4, página 41), i.e., um método em que se é necessário especificar um conjunto de MOs e um método de agregação. O conjunto de MOs é na verdade, como já mencionado, as 16 probabilidades apresentadas na Tabela 2 da Seção 2.2, os quais fornecem a base para o cálculo das MOs. Já o método de agregação é uma rede neural de múltiplas camadas, a saber: 2 camadas escondidas, com 8 e 4 neurônios, respectivamente, e funções de ativação sigmoide. A rede recebe como entrada as 16 probabilidades e gera como saída um valor único, o qual pode ser visto como um valor agregado das mesmas. A partir deste valor aprendido, o ranqueamento das regras é realizado. Este valor é aprendido para cada problema (conjunto de dados). Por não utilizar um conjunto restrito de MOs (neste caso, as probabilidades que as geram), uma vez o peso de cada uma das probabilidades é aprendido pela rede, entendeu-se a solução como uma proposta de agregação de MOs. A proposta foi modelada como um problema de otimização multiobjetivo, já que dois critérios devem ser otimizados: desempenho e interpretabilidade. Assim, os pesos da rede são otimizados por meio de um algoritmo genético denominado NSGA-II (DEB *et al.*, 2002), que permite selecionar os melhores indivíduos considerando o erro total do modelo ou o tamanho do mesmo. No algoritmo proposto, o resultado final é dado por um conjunto de indivíduos considerados ótimos, ficando a cargo do usuário selecionar o modelo considerado como ideal.

Poda. O método de poda é baseado na cobertura com que as regras, já ordenadas, casam com as transações. A partir de um conjunto de regras ordenadas, iterações são realizadas, desempilhando-as uma a uma até não sobrar mais regras ou até a cobertura de todas as transações ser maior que o parâmetro k (*default*: $k = 3$). Assim, cada transação deve ser coberta por pelo menos k regras. Para cada regra percorre-se as transações com cobertura menor que k e incrementa-se em 1 aquelas que a regra cobre. Se a regra cobrir ao menos uma transação então a mesma é adicionada ao modelo final. As transações não cobertas ou parcialmente cobertas ($k < 3$) são utilizadas para se determinar a classe *default*; caso contrário, todas as transações são utilizadas e a classe majoritária é a considerada.

Predição. A fim de predizer a classe de uma dada instância x_i, o método de predição por eles proposto encontra todas as k primeiras regras que casam com a mesma. Seja R_k o

conjunto de regras encontrado. Para cada possível classe $l \in L$, computa-se a probabilidade da instância x_i pertencer a mesma via Equação 3.1. Nesta, divide-se um valor z_l, o qual representa o pertencimento da instância à classe l, pelo pertencimento dela em relação a todas as outras classes. Este valor é computado via Equação 3.2, o qual é dividido em duas parcelas: a primeira, em que soma-se o valor agregado ($I(.)$), aprendido na etapa de ranqueamento, associado a cada regra r_j em que a classe da mesma seja igual ao da classe corrente l; a segunda, em que soma-se $\frac{1-I(r_j)}{L-1}$ a cada regra r_j que não seja igual ao da classe corrente l. Ao final, a classe com maior probabilidade é a escolhida a ser atribuída a instância x_i.

$$P(y_i = l|x_i) = \frac{z_l}{\sum_{j=1}^{L} z_j} \tag{3.1}$$

$$z_l = \sum_{\substack{j \in R_k \\ C_j = l}} I(r_j) + \sum_{\substack{j \in R_k \\ C_j \neq l}} \frac{1 - I(r_j)}{L - 1} \tag{3.2}$$

Síntese e Resultados. Os autores propõem o trabalho em questão como um alternativa aos métodos de CA existentes, destacando a importância de métodos interpretáveis em determinados domínios. Para tanto, a solução é pensada como um problema de otimização multiobjetivo, já que se visa melhorar tanto o desempenho quanto a interpretabilidade dos modelos. Assim, um método de ranqueamento é proposto, o qual utiliza-se de um valor agregado, obtido por meio de uma rede neural, a qual é treinada, via algoritmo genético, para maximizar o desempenho do modelo e minimizar seu tamanho.

Os autores avaliaram o MoMAC comparando-o a outros algoritmos, como o CBA e o CMAR. Os resultados mostraram que o algoritmo apresenta ganhos de desempenho quando comparado aos demais. No entanto, o tamanho do modelo e o tempo de execução do algoritmo são elevados e significativamente diferentes dos demais algoritmos. Estes são pontos importantes a serem considerados. Em primeiro lugar, a parametrização do algoritmo é custosa. A otimização da rede neural, via algoritmo genético, é um processo lento e complexo, que requer a configuração de diversos hiperparâmetros. Esses hiperparâmetros, como tamanho da população, número de iterações e taxa de mutação, podem afetar significativamente o tempo de execução do algoritmo. Em segundo lugar, a interpretabilidade do modelo decai em relação aos demais algoritmos utilizados na comparação de resultados, uma vez que o tamanho do mesmo supera, em muito, o tamanho dos demais. Isso se deve possivelmente pelas escolhas realizadas pelos autores em priorizar modelos com menores perdas em acurácia no momento da seleção dos indivíduos.

4 $AC.Rank_A$: Método de Ranqueamento via Agregação de MOs para Classificadores Associativos

Este capítulo apresenta o método de ranqueamento via agregação de MOs proposto, denominado de $AC.Rank_A$. A motivação para proposição do mesmo fundamenta-se nas discussões anteriormente apresentadas nos Capítulos 2 e 3, a partir das quais é possível notar que:

- A etapa de ordenação se apresenta como uma etapa de grande importância, uma vez que influencia as demais etapas e, consequentemente, o desempenho e a interpretabilidade do modelo;
- Em geral, o método CSC (Confiança, Suporte, Cardinalidade), descrito na Seção 2.3.2, é o utilizado para se ordenar as regras, tendo como base as MOs padrão de regras de associação, i.e., o suporte e a confiança;
- Ao longo dos anos diversas MOs foram propostas, como visto em Tew *et al.* (2014) e Somyanonthanakul e Theeramunkong (2022), visando superar limitações de algumas das medidas até então existentes, como a própria confiança (Seção 2.2);
- Este grande número de MOs existentes gerou um problema secundário, uma vez que não existe uma MO que seja adequada a todas as explorações (SHARMA *et al.*, 2020);
- Neste contexto, novas propostas surgiram visando modificar a etapa de ranqueamento dos CAs, conforme descrito na Seção 3.1.2, seja por meio: **[MS]** de novas medidas e/ou medidas já existentes em outros contextos, mas aplicadas nesta etapa de maneira singular; **[MA]** da união (agregação) de medidas existentes de maneira a usá-las simultaneamente;
- A estratégia **[MA]**, adotada neste trabalho, traz a vantagem de diminuir a necessidade da escolha de uma só medida, considerando também diferentes aspectos (semântica) para a ordenação das regras;
- Trabalhos recentes nesta linha, como o de Silva e Carvalho (2018), Dall'Agnol e Carvalho (2020b), Dall'Agnol e Carvalho (2020a) e Bui-Thi, Meysman e Laukens (2022), vêm sendo propostos, os quais têm apresentado resultados promissores. Contudo, os mesmos apresentam problemas em relação ao desempenho e/ou a interpretabilidade dos modelos gerados. Em todos estes trabalhos é possível verificar uma relação inversa entre desempenho

e interpretabilidade, i.e., quando o desempenho do modelo é alto, a interpretabilidade é baixa. Por outro lado, quando o desempenho do modelo é baixo, a interpretabilidade é alta.

Diante do exposto, este trabalho tem por objetivo desenvolver e avaliar um método de ranqueamento via agregação de MOs que possa ser incorporado a fluxos de indução de CAs visando induzir modelos que apresentem um melhor equilíbrio entre desempenho e interpretabilidade. Os resultados obtidos demonstram que o método proposto consegue manter o desempenho dos modelos, porém com uma melhor interpretabilidade, diferentemente dos trabalhos da literatura. Assim, a etapa de ranqueamento, em destaque na Figura 2, é modificada de modo a incorporar o método aqui proposto. Para que o $AC.Rank_A$ funcione, o mesmo deve ser instanciado com um conjunto de MOs e um método de agregação (parâmetros *MOs* e *Met.* da figura). Os conjuntos de MOs possíveis são **[TW]**, **[GF]**, descritos na Seção 4.1.1, **[C1]**, **[G1]** e **[G2]**, descritos na Seção 4.1.2. Os métodos de agregação possíveis são **[BD]**, **[BM]**, **[BL]**, **[BG]**, descritos na Seção 4.2.1, **[TS]**, **[WS]** e **[WP]**, descritos na Seção 4.2.2.

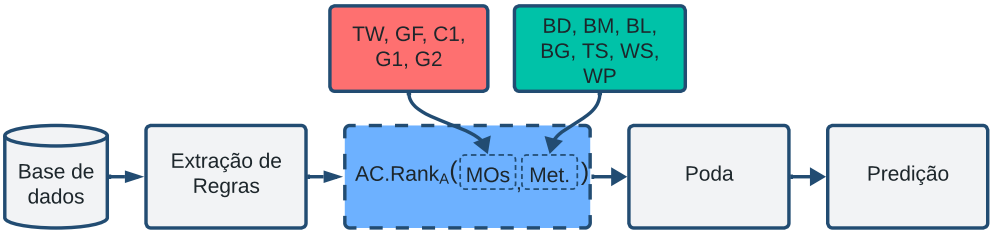


Figura 2 – Método $AC.Rank_A$ a ser incorporado a fluxos de indução de um CA.

4.1 Agrupamento de Medidas Objetivas

Embora a ideia da agregação seja a de utilizar diversas MOs, fazendo com que a importância de cada uma seja considerada ao mesmo tempo, visando eliminar a seleção das mesmas, notou-se em Dall'Agnol e Carvalho (2020a) que as medidas que compõem o conjunto impactam diretamente o resultado. Os autores sugerem estudos das MO mais apropriadas a serem agregadas neste contexto. Deste modo, um estudo foi realizado e dois trabalhos da literatura foram identificados e utilizados, os quais são brevemente descritos na Seção 4.1.1. Tendo como base estes dois trabalhos, novos conjuntos de MOs foram propostos, os quais encontram-se descritos na Seção 4.1.2. Vale mencionar que em todos os trabalhos os conjuntos de MOs são identificados via agrupamento. Grande parte dos resultados aqui apresentados encontram-se descritos na referência Dall'Agnol e Carvalho (2023a). Assim, optou-se por apresentar, nesta seção, uma visão geral do referido trabalho, uma vez que os detalhes encontram-se disponíveis na respectiva referência.

4.1.1 Conjunto de MOs de Tew *et al.* (2014) e Yang e Cui (2015)

Conforme mencionado na Seção 2.2, devido ao grande número de medidas existentes, realizar a escolha de uma ou mais medidas para explorar um conjunto de regras torna-se importante dados os benefícios que se obtêm ao optar por uma ou outra MO.

No entanto, fazer a escolha de qual utilizar é um problema difícil (LUNA *et al.*, 2018; SHARMA *et al.*, 2020), visto que existem diferenças significativas em relação aos objetivos (semânticas), entre outros aspectos, que as distinguem. Para tanto, diferentes maneiras foram propostas para realizar esta escolha, como o agrupamento, adotado neste trabalho. O foco aqui são os agrupamentos realizados tendo como base a similaridade das MOs em relação a ordenação gerada por elas em um dado conjunto de regras.

Análise de Tew *et al.* (2014). Tew *et al.* (2014) e Somyanonthanakul e Theeramunkong (2022) apresentam um estudo comportamental de um conjunto de 61 MOs quando usadas para ranquear RAs. Para tanto, os autores agrupam as MOs que apresentam comportamento similar baseando-se em como elas ranqueiam um conjunto de regras; assim, as que ordenam as regras do mesmo modo são agrupadas em um mesmo grupo. Uma vez que o agrupamento é obtido, uma medida de cada grupo pode ser explorada, reduzindo, assim, o espaço de exploração. Embora o trabalho de Somyanonthanakul e Theeramunkong (2022) tenha sido abordado em Dall'Agnol e Carvalho (2023a), uma vez que os resultados são similares aos apresentados em Tew *et al.* (2014), apenas o mesmo é aqui descrito, assim como utilizado nos experimentos do Capítulo 5.

De maneira geral, o método de agrupamento por eles proposto se dá extraindo um conjunto de regras de associação para cada conjunto de dados (110 no total) e computando-se os valores de 50 MOs para cada conjunto de regras. Os valores das MOs são então substituídos por ranks, de modo que regras que apresentam maiores valores recebam ranks menores, já que quanto maior o valor de uma dada medida em uma dada regra, mais interessante a regra é. A proposta de se trabalhar com ranks se dá pelo fato de os valores das MOs não serem comparáveis. Ao final, cada MO gera uma lista ordenada de regras, em cada conjunto de dados. Computa-se então a correlação de Spearman entre as MOs em cada conjunto de dados considerando os ranks gerados por elas. Em seguida, computa-se a matriz de distâncias entre as medidas considerando a correlação média entre as medidas em todos os conjuntos de dados. A partir da matriz de distâncias o algoritmo Complete Linkage é aplicado e os grupos obtidos, utilizando-se, para tanto, um ponto de corte de 90% de similaridade no dendrograma gerado.

Aplicando o método por eles proposto, 21 grupos de MOs são obtidos. Das 61 MOs analisadas pelos autores, apenas 50 foram utilizadas para realizar o agrupamento. As 11 medidas que ficaram de fora são matematicamente equivalentes a outras medidas e, portanto, foram removidas. Os 21 grupos por eles proposto são apresentados na Tabela 5. Assim, neste trabalho, um dos conjuntos de MOs a ser utilizado pelo método aqui proposto é o de Tew *et al.* (2014),

denominado aqui de **[TW]**. Uma vez que os grupos representam a equivalência entre as medidas em relação ao ranqueamento, o grupo de MO **[TW]** foi construído selecionando-se uma medida de cada grupo, uma vez que não há indicação de qual ou quais grupos utilizar, diferente dos métodos descritos adiante. As MOs utilizadas encontram-se em negrito na Tabela 5, a saber: Support, Prevalence, K-Measure, Least Contradiction, Confidence, TIC, Leverage, Dir, Loevinger, Odds Ratio, Added Value, Accuracy, Lift, J-Measure, Recall, Specificity, Conditional Entropy, Coverage. A escolha de uma dada medida, dentro de cada grupo, se deu em função de seu custo computacional, optando-se pelas de menor custo, assim como de sua relevância na literatura. Vale mencionar que três grupos não foram considerados, o de No. 7 e o de No. 12, por apresentarem medidas com alto custo computacional, e o de No. 21, já que, segundo os próprios autores, pode ser unido ao grupo de No. 13. Este conjunto de MOs representa, portanto, semânticas totalmente distintas quando aplicadas para se ordenar um conjunto de regras de associação, i.e., o contexto de CAs não é levado em consideração.

Análise de Yang e Cui (2015). Yang e Cui (2015) apresentam um estudo na mesma linha dos trabalhos de Tew *et al.* (2014) e Somyanonthanakul e Theeramunkong (2022), porém no contexto de classificadores associativos quando utilizados em dados desbalanceados. O objetivo é analisar o comportamento das MOs quando aplicadas aos CAs. O processo proposto pelos autores ocorre em etapas e, de maneira geral, ocorre da maneira descrita a seguir. Para cada conjunto de dados d (9 no total), k amostras são obtidas ($k = 10$), das quais s amostras são geradas ($s = 10$), cada uma contendo uma distribuição de classe $s \times 0.1$, i.e., para cada distribuição entre [0,1;1][passo=0.1], 10 amostras são geradas. Na sequência, para cada amostra d_{sk} de cada conjunto de dados (100 no total), o algoritmo CBA é executado m vezes, em que m é o número de medidas avaliadas pelos autores (55). Os autores não mencionam como o CBA é modificado para realizar tais execuções, mas supõe-se que o ranqueamento das regras é trocado por cada uma das m medidas. Ao final de cada execução, armazena-se o desempenho P obtido pelo classificador via AUC (área abaixo da curva ROC). Em seguida, para cada distribuição s, o desempenho médio P^s_m de cada medida m em todas as amostras com distribuição s é computado. Por fim, para cada distribuição s, as medidas são ordenadas por desempenho (do maior para o menor) e as top 10, i.e., as 10 primeiras melhor ranqueadas de cada distribuição, são então selecionadas. Tendo como base essas s listas, uma lista final L é obtida realizando-se a intersecção entre todas as listas anteriormente obtidas. Das 55 medidas dadas como entrada, apenas 26 são selecionadas após o processo aqui descrito. Tendo como base essas 26 medidas, os autores aplicam um algoritmo de agrupamento hierárquico e as dividem em dois grupos: as medidas mais adequadas a serem utilizadas para conjuntos de dados com distribuição menor do que 0.4 ($G_<$) e aquelas com distribuição maior do que 0.4 ($G_>$). As medidas apresentadas em cada grupo foram as seguintes[1]:

[1] No trabalho original, outras MOs são encontradas nos respectivos grupos; porém, como demonstrado em Tew *et al.* (2014), algumas delas são equivalentes (i.e., produzem os mesmos ranks) e, portanto, foram removidas.

Tabela 5 – Grupos de medidas propostos por Tew *et al.* (2014).

Grupo	Medidas
1	**Support (SUPP)**
2	**Prevalence (PREVA)**
3	**K-measure (KME)**
4	**Least Contradition (LST_CONT)**
5	**Confidence (CNFD)**, Confirm Descriptive (CF_DES), Indice Probabiliste d'Ecart d'Equilibre (IPEE)
6	**TIC**
7	Entropic Implication Intensity 1 (EII1), Entropic Implication Intensity 2 (EII2)
8	Complement Class Support (CP_CS_SP), **Leverage (LEVER)**, Confidence Causal (CN_CA), Confirmed Confidence Causal (CF_CN_CA)
9	**Directed Information Ratio (DIR)**
10	**Loevinger (LOEV)**, Odd Multiplier (ODD_MUL)
11	**Odds Ratio (ODD_RAT)**
12	Dilated Chi-square (D_x^2)
13	Confirm Causal (CF_CA), Intensity of Implication (IIM), Putative Causal Dependency (PT_CA_DP), Klösgen (KLO), **Added Value (ADD_V)**, 1-Way Support (ONE_SUP)
14	Kulczynski 2 (KUL2), Goodman–Kruskal (GOO_KRU), **Accuracy (ACCRC)**, Cosine (COSI), F-measure (FME)
15	**Lift (LIFT)**, Piatetsky-Shapiro (PIE_SHA), 2-way Support (TW_SUP), Collective Strength (CLL_STR), Kappa (KAPP), Interestingness Weighting Dependency (IWD), Correlation Coefficient (CORR_COE)
16	Theil Uncertainty Coefficient (THE_UNC), Mutual Information (MU_INF), Chi-square (CHI_SQ), **J-measure (JME)**, Gini Index (GIN_IN), Normalized Mutual Information (NR_MU_IN)
17	**Recall (RECA)**
18	**Specificity (SPECT)**, Relative Risk (REL_RIS), Logical Necessity (LOG_NEC)
19	**Conditional Entropy (CON_ENT)**
20	**Coverage (COVER)**
21	Implication Index (IMP_IND)

- $G_<$: Correlation Coeficient, Collective Strength, Kappa, Piatetsky-Shapiro, Putative Causal Dependency, Zhang, Intensity of Implication, Confirm Causal, Goodman–Kruskal, Entropic Implication Intensity 1, Implication Index, Levarage, Added Value
- $G_>$: Odd Multiplier, Complement Class Support, Conviction, Yule-Q, Sebag–Schoenauer, Yule-Y, Odds Ratio, Confirm Causal, Confirmed Confidence Causal, Example and Counterexample Rate, Ganascia, J-Measure, Confidence

Segundo as análises, o grupo $G_<$ desempenha bem em dados extremamente desbalanceados e a maioria tem um desempenho ruim em dados balanceados; por outro lado, o grupo $G_>$ desemprenha bem em dados levemente desbalanceados e ficam melhores quando usados em dados mais balanceados. Assim, neste trabalho, o outro conjunto de MOs a ser utilizado pelo método aqui proposto é o $G_>$, denominado aqui de **[GF]**. Este conjunto de MOs representa, portanto, as medidas mais apropriadas, segundo os autores, para se ranquear um conjunto de regras no contexto de CAs em relação a etapa de ordenação.

4.1.2 Conjunto de MOs de Dall'Agnol e Carvalho (2023a)

Conforme visto na Seção 4.1.1, um dos conjuntos de MOs selecionados foi proposto para o contexto de RAs (**[TW]**), enquanto o outro foi proposto especificamente para o contexto de CAs (**[GF]**), o qual apresenta algumas limitações, a saber: (i) utilização do algoritmo CBA para geração das regras, o qual não se mostra viável ao contexto de dados desbalanceados; (ii) embora os autores tenham encontrado dois grandes grupos de medidas ($G_<$, $G_>$), medidas equivalentes, i.e., medidas que sempre ranqueiam as regras da mesma maneira, aparecem em grupos distintos, ou nem aparecem, apresentando, portanto, inconsistências nos resultados; (iii) o agrupamento foi realizado ao longo de todas as distribuições, embora tivesse sido mais apropriado agrupar os resultados por distribuição, uma vez que o desempenho das medidas variam ao longo das distribuições. Maiores detalhes podem ser vistos em Dall'Agnol e Carvalho (2023a). Uma vez que o trabalho de Yang e Cui (2015) apresenta limitações e o de Tew *et al.* (2014) é voltado para o contexto de RAs, propõe-se um novo agrupamento de MOs no contexto de CAs, o qual é aqui apresentado. Detalhes específicos encontram-se no artigo Dall'Agnol e Carvalho (2023a).

Assim com em Yang e Cui (2015), o agrupamento aqui proposto também visa agrupar as MOs de acordo com seu desempenho quando aplicadas em CAs. Contudo, a proposta é voltada para conjuntos de dados balanceados ou levemente desbalanceados, uma vez que existem algoritmos específicos para os casos desbalanceados, como o CBA2, não considerados neste trabalho. Para tanto, utilizou-se uma versão modificada do algoritmo CBA (Seção 2.3), denominado de CBA', em que todas as etapas de extração do modelo são iguais ao CBA, com exceção da ordenação. Neste caso, dada uma medida m, uma regra r_i precede uma regra r_j, em uma lista ordenada, se o valor de m em r_i é maior que r_j; em caso de empate, r_i deve ter

sido gerada antes de r_j. Desta maneira, é possível avaliar o quanto cada medida influencia o desemprenho final do classificador.

O processo, apresentado no Algoritmo 4, divide-se em etapas e, de maneira geral, funciona da maneira descrita a seguir. Para cada conjunto de dados d, uma validação cruzada estratificada de 10-folds é realizada (SCV_{10}) (linha 2). Em cada fold f, o CBA' é aplicado em cada medida m considerada (linhas 3 a 7). Na sequência, computa-se o desempenho médio P_m^d de cada medida m em cada conjunto de dados d ao longo de todos os folds (linhas 8 a 10). A medida de desempenho utilizada é a F1-Macro, uma vez a medida fornece um equilíbrio entre precisão e o revocação, duas importantes medidas na tarefa de classificação. Em seguida, o coeficiente de correlação de Pearson é computado entre todos os pares de medidas, ao longo de todos os conjuntos, a fim de se obter uma matriz de distâncias (linhas 12 a 17). Tendo como base a matriz gerada, o agrupamento é obtido utilizando-se o algoritmo Complete Linkage, como nos demais trabalhos (linha 18). Para obtenção dos grupos utilizou-se um ponto de corte de 90% de similaridade no dendrograma gerado. Este processo garante que as MOs a serem agrupadas terão que apresentar um desempenho médio similar ao longo de diversos conjuntos de dados e em diversas rodadas de validação, tornando o processo mais robusto.

Algoritmo 4 Método de agrupamento proposto (DALL'AGNOL; CARVALHO, 2023a).

Entrada: Um conjunto de conjuntos de dados D e um conjunto M de MOs
Saída: Grupo de MOs

1 **para** $(d \in D)$ **faça**
2 $F = SCV_{k=10}(d)$ // divisão de d via 10-fold cross-validation estratificado
3 **para** $(f \in F)$ **faça**
4 **para** $(m \in M)$ **faça**
5 P_m^f = F1-Macro(CBA'(m,f)) // desempenho via F1-Macro para uma MO em um f-fold
6 **fim**
7 **fim**
8 **para** $(m \in M)$ **faça**
9 P_m^d = Media(P_m^f) // Média dos F1 nos folds para cada MO no conjunto de dados
10 **fim**
11 **fim**
12 **para** $(i \in M)$ **faça**
13 **para** $(j \in M)$ **faça**
14 $S_{ij} \leftarrow Pearson(P_i^D, P_j^D)$ // correlação entre duas MOs ao longo dos conjuntos de dados
15 $Dist_{ij} \leftarrow \frac{1-S_{ij}}{2}$ // transformação ad correlação em uma medida de distância
16 **fim**
17 **fim**
18 Clusters ← HAC(Dist, Link=Complete, 0.025) // agrupamento e obtenção dos grupos

Das 61 MOs apresentadas em Tew *et al.* (2014) e Somyanonthanakul e Theeramunkong (2022), este trabalho considerou 44, uma vez que existem equivalências entre as mesmas (11)

e que algumas delas apresentam um alto custo computacional (6)[2]. Assim, as 44 medidas consideradas são as apresentadas na Tabela 3 (Seção 2.2). Após aplicação do método acima descrito, as 44 MOs foram agrupadas em 15 grupos, os quais foram ranqueados de acordo com seu desempenho médio. Os grupos podem ser vistos na Tabela 6, os quais encontram-se ordenados de acordo com seus desempenhos médios ($F1_\mu$), i.e., por meio da média dos valores de F1-Macro associados aos modelos induzidos por cada MO contida no grupo. Detalhes da configuração experimental, como conjuntos de dados utilizados e ajuste de hiperparâmetros, encontram-se disponíveis no artigo (DALL'AGNOL; CARVALHO, 2023a). Além disso, uma comparação dos grupos obtidos com os apresentados em Yang e Cui (2015), assim como o impacto dos grupos obtidos aplicados no método proposto por Dall'Agnol e Carvalho (2020a), são também apresentados no artigo.

Tabela 6 – Grupos de MOs propostos, Adaptado de Dall'Agnol e Carvalho (2023a).

ID	**F1$_\mu$**	**MOs**
1	0,708	ODD_MUL, CP_CL_SP, CN_CA, LOEV, ADD_V, ONE_SUP, CF_CN_CA, LIFT, CNFD, PU_CA_DP, LEVER, CF_CA, TIC, DIR, NR_MU_IN
2	0,661	KLOS, IMP_IND, ACCRC, CORR_COE, KAPP, CLL_STR
3	0,656	JME, CHI_SQ, GIN_IND, THE_UNC, GOO_KRU, MU_INF
4	0,650	CON_ENT
5	0,626	ODD_RAT
6	0,622	LST_CNT, CF_DES
7	0,619	TW_SUP, PIE_SHA
8	0,605	COSI, FME
9	0,598	KME
10	0,590	KUL2
11	0,544	REL_RIS
12	0,468	SPECT, LOG_NEC
13	0,444	PREVA
14	0,422	RECA, SUPP
15	0,346	COVER

Assim, neste trabalho, o outro conjunto de MOs a ser utilizado pelo método aqui proposto é o grupo de No. 1, denominado aqui de **[C1]**, uma vez que este grupo representa as medidas mais apropriadas para se ranquear um conjunto de regras no contexto de CAs em relação a etapa de ordenação (melhor $F1_\mu$), buscando testar se um sub-conjunto de medidas boas quando agregadas contribuem para melhoria do processo.

[2] (1) Indice Probabiliste d'Ecart d'Equilibre (IPE); (2) EII1; (3) EII2; (4) Dilated Chi-square (DQ2); (5) Intensity of Implication (IIM); (6) Interestingness Weighting Dependency (IWD).

Após a obtenção dos resultados acima apresentados, e publicação do artigo, experimentos complementares foram realizados, considerando as seguintes modificações:

- o CBA' foi modificado de modo a incorporar a medida suporte. Neste caso, dada uma medida m, uma regra r_i precede uma regra r_j, em uma lista ordenada, se o valor de m em r_i é maior que r_j; em caso de empate, se o suporte de r_i é maior que r_j; em caso de empate, r_i foi gerada antes de r_j. Como o CBA' é baseado no CBA, mantendo-se a ordenação como no mesmo, i.e., trocando-se apenas a medida confiança por m, avalia-se melhor o impacto de uma dada medida m no processo de indução em relação ao CBA original;
- visando a obtenção de grupos mais coesos, utilizou-se um ponto de corte de 99% de similaridade no dendrograma gerado;
- alguns ajustes foram realizados no pré-processamento dos conjuntos de dados.

Executando novamente os experimentos, com as alterações acima apresentadas, o dendrograma da Figura 3 foi obtido, e os respectivos grupos da Tabela 7 encontrados. Assim como na Tabela 6, os grupos encontram-se ordenados de acordo com seus desempenhos médios ($F1_\mu$), i.e., por meio da média dos valores de F1-Macro associados aos modelos induzidos por cada MO contida no grupo. Além disso, o tamanho médio dos modelos em cada grupo também é apresentado (Tam_μ), o qual é obtido pela média do tamanho dos modelos induzidos por cada MO contida no grupo. Diferentemente do dendrograma apresentado em Dall'Agnol e Carvalho (2023a), observa-se que o ponto de corte encontra-se rente à distância zero ($\frac{1-0,99}{2}$=0,005=0,5%), uma vez que o valor utilizado de similaridade foi alto (99%). Neste caso, 26 grupos foram obtidos.

Assim, neste trabalho, os dois últimos conjuntos de MOs a serem utilizados pelo método aqui proposto é o grupo de No. 1, denominado aqui de **[G1]**, e o de No. 2, denominado aqui de **[G2]**. Os dois são os que apresentam os dois maiores valores médios de F1-Macro ($F1_\mu$). Contudo, embora o Grupo-1 apresente uma pequena diferença em relação ao Grupo-2 em termos de F1, no que se refere ao tamanho, o Grupo-2 obtém uma significativa vantagem em relação ao Grupo-1, obtendo um valor médio em torno de 28% menor, um ganho significativo comparado a uma queda de apenas 0,48% em F1. Por este motivo ambos os grupos foram selecionados. Por fim, vale mencionar que o conjunto de MOs **[C1]**, obtido anteriormente em Dall'Agnol e Carvalho (2023a), corresponde a junção de **[G1]** e **[G2]**, mais os grupos grupos de No. 3, 4 e 5 da Tabela 7.

Por fim, por meio da Figura 4 é possível se visualizar a relação inversa entre desempenho e interpretabilidade, tendo como base os dados da Tabela 7. A mesma foi construída via regressão linear. O eixo x indica o ID do grupo, o qual corresponde a um valor de rank: quanto maior o desempenho médio do grupo, menor seu ID. Esta construção permite a visualização do equilíbrio entre desempenho e interpretabilidade. Associado a cada $F1_\mu$ (linha azul), tem-se seu tamanho

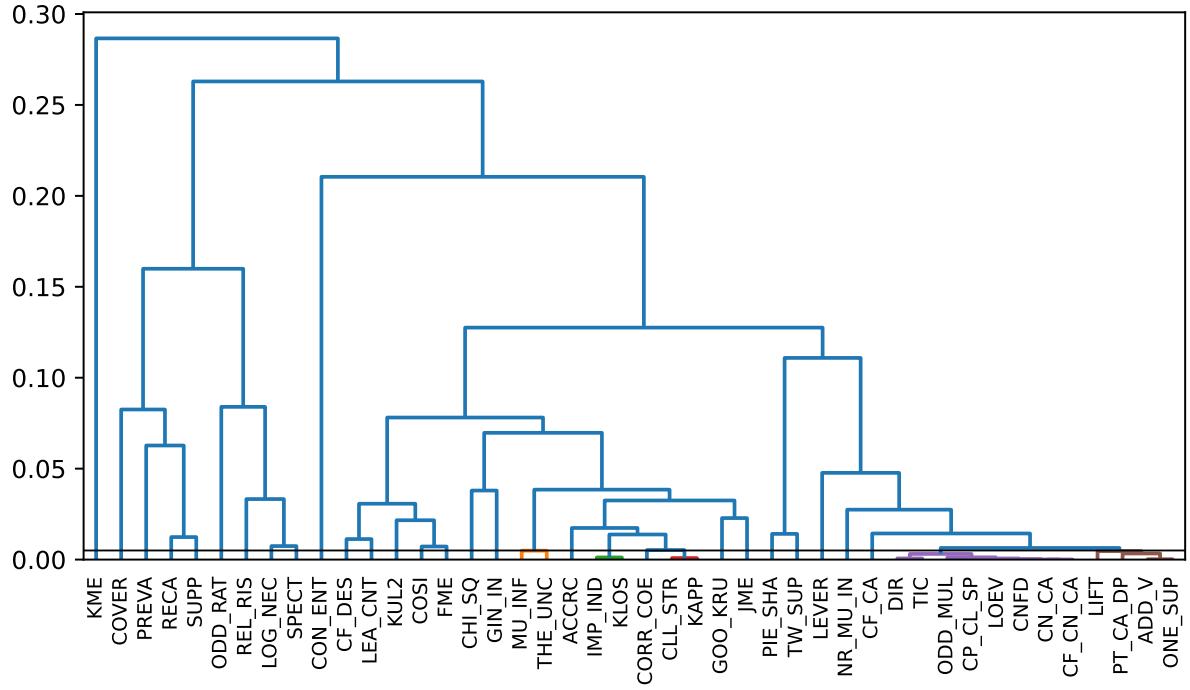


Figura 3 – Dendrograma obtido após reexecução dos experimentos considerando o método proposto (Algoritmo 4).

médio correspondente, i.e., Tam$_\mu$ (linha laranja). Nota-se que as regressões apresentam, em geral, uma tendência inversa ao que entende-se como ideal no modelo, tendo uma relação de melhorar o F1$_\mu$, e piorar o Tam$_\mu$, i.e., quanto maior o valor de F1$_\mu$ maior é o valor de Tam$_\mu$, o contrário também é válido.

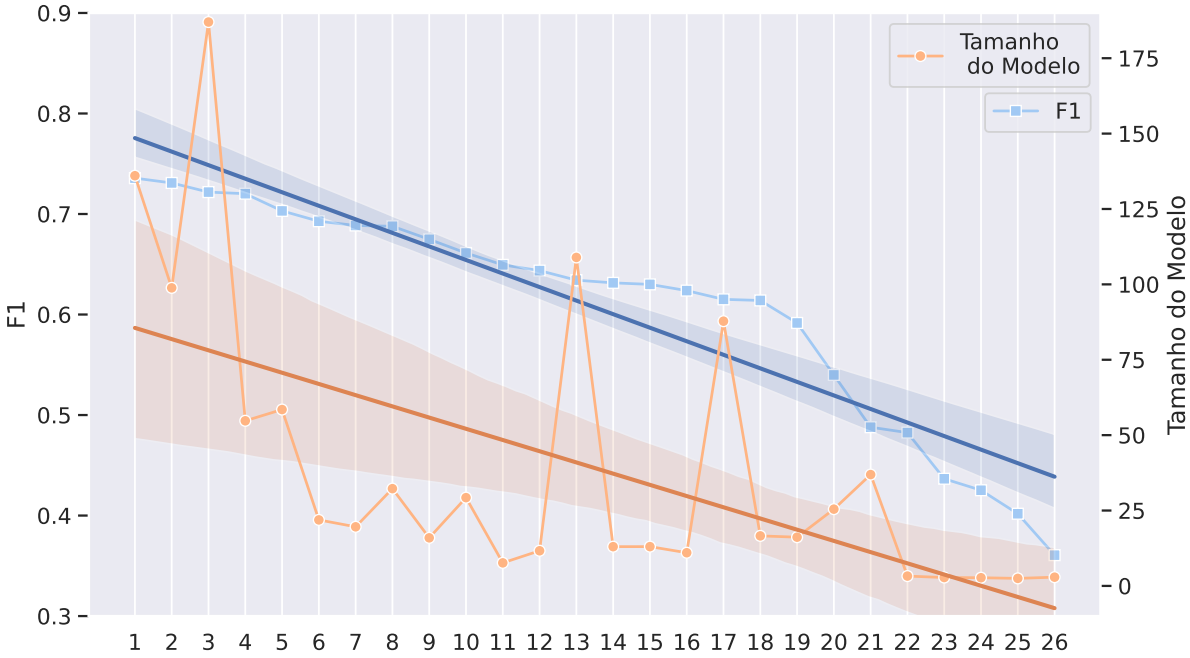


Figura 4 – Relação entre desempenho e interpretabilidade tendo como base os dados da Tabela 7.

Tabela 7 – Grupos de MOs propostos após reexecução dos experimentos.

ID	**F1$_\mu$**	**Tam$_\mu$**	**MOs**
1	0,7357	136,0328	CP_CL_SP, CNFD, CN_CA, CF_CN_CA, DIR, LOEV, ODD_MUL, TIC
2	0,7309	98,8442	ADD_V, LIFT, ONE_SUP, PT_CA_DP
3	0,7218	186,9953	LEVER
4	0,7202	54,7558	CF_CA
5	0,7031	58,486	NR_MU_IN
6	0,6928	21,8942	IMP_IND, KLOS
7	0,6886	19,6023	JME
8	0,6878	32,2581	ACCRC
9	0,6748	15,945	CLL_STR, CORR_COE, KAPP
10	0,6612	29,2744	CF_DES, LST_CNT
11	0,6494	7,6453	PIE_SHA, TW_SUP
12	0,6437	11,6581	MU_INF, THE_UNC
13	0,6342	108,9326	KME
14	0,6315	13,0163	GOO_KRU
15	0,63	13,0302	COSI, FME
16	0,6238	11,007	KUL2
17	0,6151	87,793	ODD_RAT
18	0,614	16,5953	GIN_IN
19	0,5916	16,1605	CHI_SQ
20	0,5399	25,4605	REL_RIS
21	0,4879	36,9233	CON_ENT
22	0,4825	3,2651	LOG_NEC, SPECT
23	0,4366	2,7814	RECA
24	0,4252	2,7163	SUPP
25	0,4018	*2,5*	PREVA
26	0,3606	2,9	COVER

4.2 Métodos de Agregação

Conforme já mencionado, para que o método $AC.Rank_A$ funcione é necessário que se defina também os métodos de agregação a serem utilizados. Estudos anteriores, na mesma linha deste trabalho, já haviam utilizado Pareto (SILVA; CARVALHO, 2018; DALL'AGNOL; CARVALHO, 2020b), comitê de classificadores (DALL'AGNOL; CARVALHO, 2020a) e otimização através de algoritmo genético (BUI-THI; MEYSMAN; LAUKENS, 2022). Contudo, os mesmos apresentam problemas em relação ao desempenho ou a interpretabilidade. Assim, neste trabalho optou-se por utilizar análise de decisão multicritérios (MCDA) e agregação de rankings. O motivo se deve ao uso recente de métodos de MCDA no contexto de regras de associação, como o ELECTRE I (MAZOURI; ABOUNAIMA; ZENKOUAR, 2017; DAHBI *et*

al., 2020b) e o ELECTRE II (MAZOURI; ABOUNAIMA; ZENKOUAR, 2019), como visto na Seção 3.1.2. Além disso, os referidos métodos são, naturalmente, propostos para apoiar tomadas de decisão como a proposta por este trabalho. Assim, esta seção apresenta tais métodos. Por fim, antes de se apresentar os métodos em si, é importante mencionar que:

- O método $AC.Rank_A$ é executado da mesma maneira que os métodos de agregação descritos a seguir; contudo, neste caso, as matrizes $m \times n$, apresentadas nas Tabelas 8 e 11, são matrizes de Regras x MOs, em que as medidas que as compõem são aquelas pertencentes aos conjuntos selecionados, i.e., **[TW]**, **[GF]**, **[C1]**, **[G1]** e **[G2]**;
- Todas as MOs, nos métodos de MCDA, recebem o mesmo peso no que se refere ao vetor W[3].

4.2.1 Análise de Decisão Multicritérios (MCDA)

Os métodos de Análise de Decisão Multicritérios (MCDA) foram criados para auxiliar os tomadores de decisão na escolha das melhores opções (alternativas) a partir de um conjunto de critérios, os quais podem ou não ter pesos distintos (WątTRóBSKI *et al.*, 2019). Trata-se de uma área multidisciplinar que pode ser aplicada nos mais variados campos, de negócios a pesquisa, saúde, entre outros (WątTRóBSKI *et al.*, 2019). O uso de métodos de MCDA também se encaixa na tarefa de agregação de medidas objetivas, uma vez que podem auxiliar na tomada de decisão ao se avaliar diversas regras (opções) em vários critérios conflitantes (MOs).

Devido ao grande número de métodos existentes, Wątróbski *et al.* (2019) disponibilizam um framework, disponível em <https://mcda.it/>, para apoiar a escolha dos métodos mais adequados a um dado problema. Este trabalho utilizou-se de tal framework para realizar a seleção dos métodos a serem utilizados. Para tanto, utilizou-se como opção de busca métodos que não trabalham com incerteza e que trabalham com ranqueamento (os demais critérios de busca foram deixados em aberto). Dentre os métodos sugeridos pelo framework selecionou-se o TOPSIS (HWANG; YOON, 1981), o qual é comumente citado na literatura. Além disso, os dois métodos mais básicos e clássicos de MCDA também foram considerados, a saber: o WSM (TRIANTAPHYLLOU, 2000) e o WPM (TRIANTAPHYLLOU, 2000). Os demais métodos citados anteriormente não foram abordados uma vez buscou-se métodos com maior eficiência para compor os algoritmos selecionados.

A fim de adequar os termos utilizados neste trabalho com os da literatura de MCDA, as medidas objetivas são chamadas de critérios e as regras de associação classificativas de alternativas. Assim, o objetivo é ordenar as alternativas (regras) de acordo com os critérios

[3] Uma iniciação científica, com bolsa Fapesp, foi realizada para ajustar o vetor W dinamicamente em função do conjunto de dados utilizado. Porém, os resultados obtidos não foram superiores aos aqui apresentados.

estabelecidos (medidas objetivas), de modo a priorizar, por meio das primeiras posições de um dado ranqueamento, as melhores alternativas.

Neste contexto, define-se como $A = \{A_i | i = 1, ..., m\}$ o conjunto de m alternativas, $C = \{C_j | j = 1, ..., n\}$ o conjunto dos n critérios e $W = \{W_j | j = 1, ..., n\}$ o conjunto de pesos associados aos critérios. Em geral, os dados a serem analisados são organizados em uma matriz m X n, como apresentado na Tabela 8, em que x_{ij} indica a intersecção de uma alternativa i e um critério j. A fim de auxiliar na explicação dos métodos, descritos a seguir, será utilizada a Tabela 9, a qual contém três alternativas e três critérios, além dos pesos dos respectivos critérios (linha W).

Tabela 8 – Tabela de alternativas e critérios.

	C_1	C_2	...	C_n
A_1	$x_{1,1}$	$x_{1,2}$	...	$x_{1,n}$
A_2	$x_{2,1}$	$x_{2,2}$	...	$x_{2,n}$
...	...	...	...	...
A_m	$x_{m,1}$	$x_{m,2}$	...	$x_{m,n}$

Tabela 9 – Exemplo de alternativas e critérios.

W	1	2	0,5
	C_1	C_2	C_3
A_1	0,2	0,67	0,02
A_2	0,1	0,5	0
A_3	0,2	0,33	0,10

[WS] WSM (TRIANTAPHYLLOU, 2000). Neste método o valor V_i de cada alternativa A_i é dado pelo somatório dos n critérios da alternativa A_i multiplicados pelos seus respectivos pesos, como visto na Equação 4.1.

$$V_i = \sum_{j=1}^{n} W_j * x_{ij} \tag{4.1}$$

Utilizando os valores da Tabela 9 teríamos o valor de 1,55 para a alternativa A_1 (Equação 4.2). Para as alternativas A_2 e A_3, os valores de $V_2 = 1,1$ e $V_3 = 0,91$. Considerando esses valores, as alternativas seriam ranqueadas na seguinte ordem $\{A_1, A_2, A_3\}$, tendo a alternativa A_1 preferência sobre as demais.

$$\begin{aligned} V_1 &= 1 * 0,2 + 2 * 0,67 + 0,5 * 0,02 \\ V_1 &= 1,55 \end{aligned} \tag{4.2}$$

[WP] WPM (TRIANTAPHYLLOU, 2000). Este método é semelhante ao WSM. Neste caso, o valor V_i é dado pelo produtório entre os critérios da alternativa A_i, elevados aos seus respectivos pesos, como visto na Equação 4.3.

$$V_i = \prod_{j=1}^{n} x_{ij}^{W_j} \tag{4.3}$$

Utilizando os valores da Tabela 9 teríamos o valor de 0,012 para a alternativa A_1 (Equação 4.4). Para as alternativas A_2 e A_3, os valores de $V_2 = 0$ e $V_3 = 0{,}006$. Considerando esses valores, as alternativas seriam ranqueadas na seguinte ordem $\{A_1, A_3, A_2\}$, tendo a alternativa A_1 preferência sobre as demais.

$$\begin{aligned} V_1 &= 0{,}2^1 * 0{,}67^2 * 0{,}02^{0{,}5} \\ V_1 &= 0{,}012 \end{aligned} \tag{4.4}$$

[TS] TOPSIS (HWANG; YOON, 1981). Este método é dividido em três partes. Na primeira parte os valores da matriz são normalizados dividindo-se cada valor pela raiz quadrada do somatório dos valores ao quadrado, os quais são, enfim, ponderados pelo peso do critério, conforme Equação 4.5. Na segunda parte calcula-se, para cada alternativa A_i, a distância Euclidiana de seus valores, em cada um dos critérios, em relação aos melhores (D_i^{max}) e piores (D_i^{min}) valores de cada critério, como visto nas Equações 4.6 e 4.7. Por fim, na terceira parte, obtém-se o valor V_i dividindo-se D_i^{min} pela soma entre D_i^{max} e D_i^{min}, como visto na Equação 4.8.

$$x_{ij}^{normalized} = \frac{x_{ij}}{\sqrt{\sum_{i=1}^{m} x_{ij}^2}} * W_j \tag{4.5}$$

$$D_i^{max} = \sqrt{\sum_{j=1}^{n} (x_{i,j}^{normalized} - \max\{C_j\})^2} \tag{4.6}$$

$$D_i^{min} = \sqrt{\sum_{j=1}^{n} (x_{i,j}^{normalized} - \min\{C_j\})^2} \tag{4.7}$$

$$V_i = \frac{D_i^{min}}{D_i^{max} + D_i^{min}} \tag{4.8}$$

Utilizando os valores da Tabela 9, após a primeira parte, os novos valores normalizados seriam os apresentados na Tabela 10. A Equação 4.9 apresenta o cálculo para o valor $x_{1,1}$.

Tabela 10 – Valores da Tabela 9 após normalização. Os maiores valores de cada coluna encontram-se em negrito e os menores em itálico.

W	1	2	0,5
	C_1	C_2	C_3
A_1	**0,67**	**1,49**	0,1
A_2	*0,33*	1,11	*0,0*
A_3	**0,67**	*0,73*	**0,49**

$$\begin{aligned} x_{1,1} &= \frac{0{,}2}{\sqrt{0{,}2^2 + 0{,}1^2 + 0{,}2^2}} * 1 \\ x_{1,1} &= 0{,}67 \end{aligned} \tag{4.9}$$

Na segunda parte as distâncias são calculadas. As Equações 4.10 e 4.11 apresentam os valores obtidos para a alternativa A_1.

$$\begin{aligned} D_1^{\max} &= \sqrt{(0{,}67 - 0{,}67)^2 + (1{,}49 - 1{,}49)^2 + (0{,}10 - 0{,}49)^2} \\ D_1^{\max} &= 0,39 \end{aligned} \tag{4.10}$$

$$\begin{aligned} D_1^{\min} &= \sqrt{(0{,}67 - 0{,}33)^2 + (1{,}49 - 0{,}73)^2 + (0{,}10 - 0)^2} \\ D_1^{\min} &= 0{,}83 \end{aligned} \tag{4.11}$$

Por fim, o valor de V_1 é obtido pela Equação 4.12, resultando em um valor de 0.68. Para as alternativas A_2 e A_3 teríamos os valores de $V_2 = 0{,}35$ e $V_3 = 0{,}44$. Considerando esses valores, as alternativas seriam ranqueadas na seguinte ordem $\{A_1, A_3, A_2\}$, tendo a alternativa A_1 preferência sobre as demais.

$$\begin{aligned} V_1 &= \frac{0{,}83}{0{,}39 + 0{,}83} \\ V_1 &= 0{,}68 \end{aligned} \tag{4.12}$$

4.2.2 Agregação de Rankings

Os métodos de agregação de rankings (ranking aggregation) se assemelham aos de MCDA em alguns aspectos, uma vez que têm como objetivo avaliar múltiplos critérios ao mesmo tempo. Contudo, os métodos desta família utilizam-se de *rankings* para ordenação, combinando as ordens geradas por diferentes critérios para gerar uma ordem final (DWORK; NAOR; SIVAKUMAR, 2003) e não com os valores em si como no MCDA. Assim, os métodos são mais robustos a *outliers* (LIN, 2010) e invariantes a transformações e normalizações, desde que mantida a ordem das alternativas. Por este, dentre outros motivos, desempenhou um importante papel em pesquisas

genéticas (LI; WANG; XIAO, 2017), pesquisas de publicidade, marketing e sistemas de busca na Internet (LIN, 2010). Os métodos de Borda (BORDA, 1781) são os mais tradicionais desta família, sendo amplamente utilizados pela sua simplicidade. Assim, suas quatro versões foram aqui selecionadas.

A fim de garantir uma padronização entre os métodos selecionados, tanto nos exemplos como nas explicações, a mesma nomenclatura do MCDA foi adotada. Como referência para as equações considerou-se a Tabela 8. Já para os exemplos, a Tabela 11 foi construída a partir da Tabela 9 modificando os valores da mesma para valores de *rank*. É importante mencionar que alternativas com valores iguais recebem a média dos *ranks* dos mesmos. Os *ranks* são expressos em ordem ascendente, de maneira a preservar o premissa de quanto maior o valor, melhor o *rank*.

Tabela 11 – Exemplo de *ranks* por critério.

	C_1	C_2	C_3
A_1	2,5	3	2
A_2	1	2	1
A_3	2,5	1	3

[BM] Borda Média (LIN, 2010). Neste método o valor V_i de cada alternativa A_i é dado pela média aritmética dos valores da alternativa em cada um dos critérios (Equação 4.13). Utilizando a Tabela 11, os seguintes valores seriam obtidos para cada alternativa, $\{2{,}5, 1{,}3333, 2{,}1666\}$, resultando no ranqueamento $\{A_1, A_3, A_2\}$.

$$V_i = \frac{\sum_{j=1}^{n} x_{ij}}{n} \tag{4.13}$$

[BD] Borda Mediana (LIN, 2010). Neste método o valor V_i de cada alternativa A_i é dado pela mediana dos valores da alternativa em cada um dos critérios (Equação 4.14). Este caso apresenta-se como uma solução às possíveis distorções de *ranks* muito altos ou muito baixos, tornando-se invariante a este problema, uma vez que leva em consideração apenas a posição dos valores. Para V_1, dado os valores ordenados de $\{2, 2{,}5, 3\}$, tem-se a mediana de 2,5. Tendo os valores de $V_2 = 1$ e $V_3 = 2{,}5$, o ranqueamento é dado por$\{A_1, A_3, A_2\}$.

$$V_i = \text{median}\{x_{i1}, \ldots, x_{in}\} \tag{4.14}$$

[BG] Borda Geométrica (LIN, 2010). Neste método o valor V_i de cada alternativa A_i é dado pela média geométrica, determinada pela Equação 4.15, a qual refere-se ao produtório dos valores elevado ao inverso do número de critérios. Este método se mostra interessante já que a média geométrica permite estimar um ponto central mesmo quando se trabalha com diferentes escalas. Ainda que para os métodos de Rank Agreggation o impacto da escala seja diminuído, ele

ainda está presente quando os *ranks* são gerados a partir de medidas objetivas, as quais podem apresentar escalas bem diferentes. Para A_1 tem-se $V_1 = \sqrt[3]{2{,}5 * 3 * 2} = 2{,}4662$. Os valores para V_2 e V_3 são iguais a 1,2599 e 1,9574, respectivamente, obtendo-se então o seguinte ranqueamento $\{A_1, A_3, A_2\}$.

$$V_i = \sqrt[n]{\prod_{j=1}^{n} x_{ij}} \tag{4.15}$$

[BL] Borda L2 (LIN, 2010). Neste método o valor V_i de cada alternativa A_i é dado pela Equação 4.16, chamado de Norma Euclidiana, um caso especial da **p-norm**, em que $p = 2$. Neste caso seria equivalente a distância em linha reta entre duas alternativas, enquanto para $p = 1$, equivalente ao Borda Média, a relação de soma entre as distâncias de duas alternativas, porém levando em consideração apenas uma dimensão por vez. Como exemplo, para A_1 tem-se $V_1 = \sqrt[3]{\frac{6{,}25+9+4}{3}} = 1{,}858$. Para V_2 e V_3 os valores são respectivamente 1,2599 e 1,756, resultando no ranqueamento $\{A_1, A_3, A_2\}$.

$$V_i = \sqrt[n]{\frac{\sum_{j=1}^{n} x_{ij}^2}{n}} \tag{4.16}$$

5 Avaliação Experimental

A fim de avaliar o método proposto, este capítulo apresenta os experimentos realizados, assim como os resultados e as discussões. Uma vez que o objetivo do trabalho era desenvolver e avaliar um método de ranqueamento via agregação de MOs que pudesse ser incorporado a fluxos de indução de CAs, os experimentos foram estruturados de maneira a testá-lo em conjunto com diferentes métodos de poda e predição. Deste modo, diversos fluxos foram elaborados, utilizando-se tanto a ordenação padrão do CBA, i.e., **[CSC]** (Seção 2.3.2, página 25), quanto a aqui proposta, para que uma análise do impacto da mesma pudesse ser realizada. Todos os fluxos foram elaborados tendo como base o CBA, uma vez que o mesmo é o algoritmo mais utilizado da família (FILIP; KLIEGR, 2018). Assim, este trabalho o considera como *baseline*.

A Figura 5 segue o mesmo fluxo da Figura 2, i.e., extração, ranqueamento, poda e predição, porém encontra-se instanciada com os métodos a serem explorados em cada uma das referidas etapas. Cada combinação gera um fluxo diferente a ser utilizado na indução de um modelo de CA. Assim, tem-se disponível os seguintes métodos em cada etapa:

- **Extração**: Apriori (AP) (Seção 2.1);
- **Ranqueamento**: $AC.Rank_A$ (Capítulo 4); **[CSC]** (Seção 2.3.2, página 25);
- **Poda**: **[M1]** (Seção 2.3.2, página 25); **[DN]** (Seção 3.1.3, página 35); **[CV]** (Seção 3.1.3, página 35);
- **Predição**: **[O]** (Seção 2.3.2, página 25); **[V]** (Seção 3.1.4, página 37); **[R]** (Seção 3.1.4; página 36); **[P]** (Seção 3.1.4, página 37).

Cada fluxo é executado sequencialmente, em que a saída do método de uma etapa é utilizada como entrada no método da etapa seguinte. Vale destacar que embora as caixas "Conjunto de MOs" e "Métodos de Agregação", pertencentes ao método $AC.Rank_A$, tenham sido dispostas sequencialmente, apenas para indicar as possíveis combinações, a execução das mesmas ocorre simultaneamente. Por fim, vale mencionar que os métodos destacados em laranja na Figura 5 são os utilizados no CBA; assim, a combinação **[CSC]+[M1]+[O]** se refere a execução do mesmo.

Considerando os fluxos possíveis, obtém-se ao todo 432 possibilidades: 420 relacionadas a ordenação $AC.Rank_A$ e 12 a ordenação **[CSC]**. Cada uma delas induz um modelo distinto, o qual é avaliado em termos de desempenho (F1-Macro) e interpretabilidade (tamanho do modelo) (vide Seção 2.3.3). Os 432 fluxos foram explorados em 43 conjuntos de dados, totalizando ao

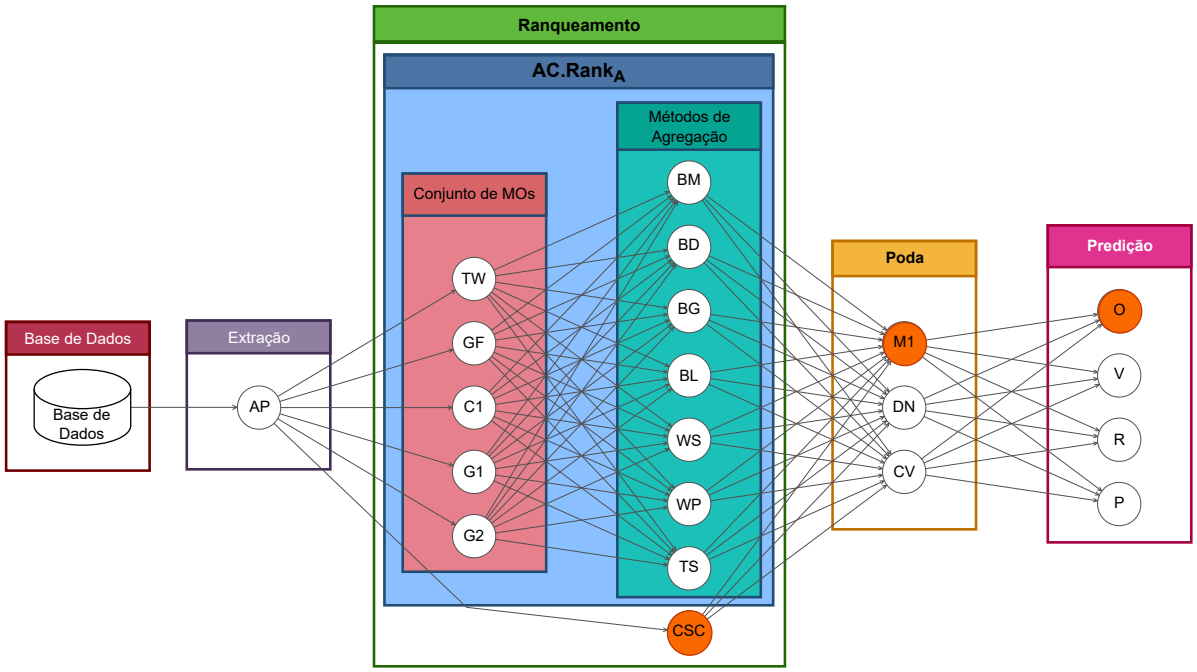


Figura 5 – Métodos utilizados em cada etapa de indução, os quais, em conjunto, geram os fluxos avaliados neste trabalho.

todo 185.760 experimentos (432*43*10), já que as medidas foram estimadas, em cada conjunto, via 10-*fold cross-validation* estratificado. Deste modo, este capítulo apresenta na Seção 5.1 detalhes mais específicos sobre a configuração experimental. Já na Seção 5.2 os resultados são apresentados e discutidos. Por fim, na Seção 5.3 uma análise complementar, em relação aos trabalhos da literatura, é realizada.

5.1 Detalhes da Configuração Experimental

Embora os métodos a serem utilizados em cada uma das etapas já tenham sido apresentados, assim como na Figura 5, é necessário que alguns detalhes, relacionados a execução dos experimentos, sejam aqui descritos.

Conjuntos de Dados. 43 conjuntos de dados, disponíveis no repositório da ferramenta KEEL[1], foram utilizados. O repositório disponibiliza 76 conjuntos ao todo (seção "Standard classification data sets"). Contudo, destes, apenas aqueles com distribuição balanceada, ou parcialmente balanceada, foram selecionados, i.e., aqueles com proporções de até 1:2,5 entre as classes minoritária e majoritária. O motivo se deve ao fato dos algoritmos aqui utilizados não se proporem a lidar com a questão de desbalanceamento entre classes. A Tabela 12 apresenta os conjuntos selecionados. Os conjuntos apresentam características diversas como, por exemplo, número de instâncias (transações) variando de 150 até 20.000, somatório de valores únicos

[1] <https://sci2s.ugr.es/keel/datasets.php>.

Tabela 12 – Características dos conjuntos de dados utilizados nos experimentos.

Conj. de Dados	**Transações**	**N.º Atributos**	**Itens Únicos**	**N.º Classes**	**I.R.**	**Suporte (%)**
Australian	690	14	37	2	1,25	4,4122
Banana	5300	2	12	2	1,23	0,021
Bands	365	19	44	2	1,7	16,4378
Breast	277	9	41	2	2,42	0,8022
Bupa	345	6	12	2	1,38	0,3221
Chess	3196	36	73	2	1,09	36,8377
Contraceptive	1473	9	28	3	1,89	0,611
Crx	653	15	53	2	1,21	4,7304
German	1000	20	74	2	2,33	7,6889
Hayes-roth	160	4	15	3	2,1	0,6944
Heart	270	13	33	2	1,25	3,3333
Housevotes	232	16	32	2	1,15	7,6629
Ionosphere	351	33	125	2	1,79	0,5697
Iris	150	4	11	3	1	0,7407
Led7digit	500	6	13	10	1,55	0,2222
Letter	20000	16	128	26	1,11	0,9872
Magic	19020	10	73	2	1,84	0,6812
Mammographic	830	5	24	2	1,06	0,1339
Marketing	6876	13	75	9	2,49	1,3089
Monk-2	432	6	17	2	1,12	0,2572
Movement libras	360	90	243	15	1,05	5,9259
Mushroom	5644	21	97	2	1,62	11,5363
Optdigits	5620	62	298	10	1,03	9,8754
Penbased	10992	16	162	10	1,09	0,9613
Phoneme	5404	5	30	2	2,41	0,0206
Pima	768	8	19	2	1,87	0,1447
Ring	7400	20	156	2	1,02	4,3799
Saheart	462	9	19	2	1,89	0,2405
Satimage	6435	36	440	6	2,45	1,4331
Segment	2310	18	171	7	1	3,3526
Sonar	208	59	120	2	1,14	2,8311
Spambase	4597	57	158	2	1,54	2,4944
Splice	3190	60	283	3	2,16	3,8384
Tae	151	5	10	3	1,06	0,7358
Texture	5500	40	470	11	1	1,497
Tic-tac-toe	958	9	27	2	1,89	0,9279
Titanic	2201	2	4	2	2,1	4,3671
Twonorm	7400	20	126	2	1	1,3514
Vehicle	846	18	72	4	1,1	6,4485
Vowel	990	12	44	11	1	2,1437
Wdbc	569	30	92	2	1,68	21,6171
Wine	178	13	36	3	1,48	3,4953
Wisconsin	683	9	89	2	1,86	0,488

para cada atributo (itens únicos), a coluna I.R., *Imbalanced Ratio*, apresentando a taxa de desbalanceamento dos conjuntos ($I.R. = \frac{\#Maj}{\#Min}$), entre outras características.

Pré-processamento. Todos os conjuntos de dados utilizados foram pré-processados. Atributos numéricos foram discretizados, tanto os reais quanto os inteiros contendo mais de dez valores únicos. Vale mencionar que a fim de evitar *data leakage*, a discretização foi realizada somente nos *folds* utilizados como treinamento em uma dada execução da validação cruzada. Em outras palavras, as transformações foram realizadas somente no conjunto de treinamento e aplicadas, posteriormente, no conjunto de teste. O algoritmo de discretização utilizado foi o proposto por Fayyad e Irani (1993). Após a discretização, atributos que apresentassem valores únicos eram excluídos.

Extração de Regras. Diferentemente das demais etapas, a etapa de extração foi a única que utilizou apenas um algoritmo, neste caso, o Apriori. Para que o mesmo seja executado e as regras extraídas, como visto na Seção 2.1, é necessário a setagem do suporte mínimo (**sup-min**) e da confiança mínima (**conf-min**). A fim de evitar interferências nos resultados apresentados optou-se por zerar o valor de conf-min, extraindo-se, portanto, todas as possíveis regras dentro do sup-min especificado. A fim de evitar uma explosão combinatória no número de regras, o sup-min foi setado de maneira a não gerar conjuntos acima de dez mil regras. Os valores médios de sup-min, utilizados para cada conjunto de dados, encontram-se na Tabela 12 (coluna "Suporte %"). Além disso, como já comentado na Seção 2.3.3, definiu-se que o tamanho máximo do *itemset* seria igual a 5 itens, tal como frequentemente utilizado (valor *default*), o que implica em regras com no máximo 4 itens no antecedente, exceto nos conjuntos *Ionosphere*, *Spambase*, *Texture* e *Satimage*, em que o tamanho foi configurado em 3 itens, visto que qualquer extração com 4 ou 5 itens acarretava no aparecimento de mais de 10 mil regras.

Critério de Avaliação. Como já mencionado na Seção 2.3.3, as medidas consideradas foram a F1-Macro, no quesito desempenho, e o tamanho do modelo $\mathcal{L}$, no quesito interpretabilidade, ambas estimadas via 10-fold cross-validation estratificado. A fim de comparar os resultados obtidos, testes estatísticos foram realizados, utilizando-se para tanto o teste de Friedman com $\alpha = 0{,}05$ e o teste post-hoc de Nemenyi, juntamente com os diagramas de diferença crítica (CD). A escolha dos mesmos foi baseada em Demsar (2006).

5.2 Resultados e Discussão

Os resultados foram organizados e analisados de modo a verificar o impacto do método de ordenação $AC.Rank_A$, em relação ao **[CSC]** (*baseline*), em diversos fluxos de indução de CAs. A fim de melhor compreender como a análise foi realizada, considere as Tabelas 13 e 14. A primeira apresenta os resultados de F1 e a segunda de tamanho do modelo, ambas referentes

ao conjunto Hayes-roth com $AC.Rank_A$ instanciado com o grupo de MOs **[TW]** nos diversos métodos de agregação. Cada linha contém o resultado de 8 fluxos distintos. A linha 1, por exemplo, está associada aos seguintes fluxos:

- **[CSC]+[M1]+[O]**;
- **[TW+BD]+[M1]+[O]**;
- **[TW+BG]+[M1]+[O]**;
- **[TW+BL]+[M1]+[O]**;
- **[TW+BM]+[M1]+[O]**;
- **[TW+TS]+[M1]+[O]**;
- **[TW+WP]+[M1]+[O]**;
- **[TW+WS]+[M1]+[O]**.

Tabela 13 – Resultados de F1-Macro no conjunto Hayes-roth com $AC.Rank_A$ instanciado no grupo **[TW]** nos diversos métodos de agregação.

Poda	**Pred**	**Ranqueamento**							
		[CSC]	**[TW]**						
			[BD]	**[BG]**	**[BL]**	**[BM]**	**[TS]**	**[WP]**	**[WS]**
[M1]	**[O]**	0,7936	0,8298	0,8752	0,8695	0,8854	0,8752	0,8752	0,8854
	[P]	0,7936	0,7173	0,7227	0,7215	0,7345	0,7278	0,7227	0,7345
	[R]	0,7936	0,8182	0,7914	0,8152	0,7981	0,7914	0,7914	0,7981
	[V]	0,7623	0,7549	0,6912	0,7029	0,7063	0,6842	0,6912	0,7063
[CV]	**[O]**	0,7963	0,8459	0,8802	0,8905	0,8905	0,8802	0,8802	0,8905
	[P]	0,8331	0,8234	0,8136	0,8332	0,8176	0,8136	0,8136	0,8176
	[R]	0,8372	0,8367	0,822	0,8322	0,8323	0,8111	0,822	0,8323
	[V]	0,7526	0,7449	0,7036	0,7769	0,7179	0,7033	0,7036	0,7179
[DN]	**[O]**	0,7874	0,6467	0,8524	0,8334	0,837	0,8366	0,8524	0,837
	[P]	0,655	0,5262	0,6419	0,5618	0,623	0,5857	0,6419	0,623
	[R]	0,764	0,6515	0,8233	0,8334	0,8245	0,8005	0,8233	0,8245
	[V]	0,7021	0,5952	0,7313	0,6688	0,6989	0,6963	0,7313	0,6989

Note que em todos eles a poda é instanciada via método **[M1]** e a predição via **[O]**. O que muda entre os fluxos é a etapa de ranqueamento, a qual é instanciada tanto pelo **[CSC]** quanto pelo $AC.Rank_A$ em todos os possíveis métodos de agregação e grupo de MOs **[TW]**. Já na linha 2, por exemplo, todos os fluxos tem a poda fixada em **[M1]** e a predição em **[P]**, com os ranqueamentos variando como na linha 1. A coluna em verde apresenta os valores de F1

Tabela 14 – Resultados de tamanho do modelo no conjunto Hayes-roth com $AC.Rank_A$ instanciado no grupo **[TW]** nos diversos métodos de agregação.

Poda	**Pred**	**Ranqueamento**							
		[CSC]	**[TW]**						
			[BD]	**[BG]**	**[BL]**	**[BM]**	**[TS]**	**[WP]**	**[WS]**
[M1]	**[O]**	28,5	26,8	23,3	21,7	23,6	22,1	23,3	23,6
	[P3]	28,5	26,8	23,3	21,7	23,6	22,1	23,3	23,6
	[R]	28,5	26,8	23,3	21,7	23,6	22,1	23,3	23,6
	[V]	28,5	26,8	23,3	21,7	23,6	22,1	23,3	23,6
[CV]	**[O]**	131,1	123,8	71,3	69,3	70	67,1	71,3	70
	[P3]	131,1	123,8	71,3	69,3	70	67,1	71,3	70
	[R]	131,1	123,8	71,3	69,3	70	67,1	71,3	70
	[V]	131,1	123,8	71,3	69,3	70	67,1	71,3	70
[DN]	**[O]**	31,1	26,2	15,4	20	16,9	15,9	15,4	16,9
	[P3]	31,1	26,2	15,4	20	16,9	15,9	15,4	16,9
	[R]	31,1	26,2	15,4	20	16,9	15,9	15,4	16,9
	[V]	31,1	26,2	15,4	20	16,9	15,9	15,4	16,9

obtidos quando os fluxos utilizam em sua etapa de ranqueamento o **[CSC]**. Já as colunas em azul o método $AC.Rank_A$ instanciado via métodos de agregação MCDA e grupo de MOs **[TW]**. Por fim, as colunas em amarelo o método $AC.Rank_A$ instanciado via métodos de agregação de rankings e grupo de MOs **[TW]**.

Analisando a primeira linha da Tabela 13, nota-se que o CBA, combinação **[CSC]+[M1]+[O]**, pode ser comparado a um CBA', em que todas as etapas são iguais ao CBA, com exceção a etapa de ranqueamento, substituída pelo $AC.Rank_A$. Neste caso, observa-se que em todas as combinações em que o $AC.Rank_A$ é utilizado, o mesmo apresenta melhores valores de F1, obtendo-se ganhos de até 11% (de 0,7936 (79,36%) em **[CSC]+[M1]+[O]** para 0,8854 (88,54%) em **[TW+BM]+[M1]+[O]** e **[TW+WS]+[M1]+[O]**). Os resultados obtidos em todos os 432 fluxos explorados, tanto em termos de F1 quanto de tamanho do modelo, encontram-se disponíveis em <https://bit.ly/resultados-experimentos-defesa>.

Diante do exposto, é possível verificar se fluxos que utilizam como método de ranqueamento o $AC.Rank_A$ são melhores ou não em relação aqueles que utilizam o método padrão do CBA (**[CSC]**), tanto em relação ao desempenho (F1) quanto em relação a interpretabilidade (tamanho do modelo). A verificação é feita agrupando-se os resultados por grupo de MOs, como na Tabela 13. Para tanto, testes estatísticos são realizados (Friedman com teste post-hoc de Nemenyi (vide Seção 5.1)). Os testes são aplicados a cada fluxo em que se fixa o método de poda e predição e varia-se o método de ranqueamento. O objetivo é verificar se existem diferenças significativas em relação ao F1 e ao tamanho do modelo entre os os métodos de ranqueamentos

avaliados. Utilizando-se novamente a Tabela 13, testes são aplicados às configurações (fluxos) presentes em cada linha da tabela ao longos dos 43 conjuntos de dados utilizados. Considerando a linha 1 como exemplo, o teste de Friedman é aplicado então às 8 configurações acima listadas (*bullets*) ao longo dos 43 datasets, i.e., o teste é aplicado sobre uma matriz 43x8. O nível de significância utilizado foi de 5%. Nos casos em que a hipótese nula é rejeitada, i.e., não existe diferença entre os ranqueamentos, o teste post-hoc de Nemenyi é aplicado, gerando-se também o gráfico de diferença crítica, como apresentado na Figura 6. Este é o gráfico obtido, após a aplicação dos referidos testes, para as configurações presentes na linha 1 da Tabela 13 ao longo dos 43 datasets em relação aos valores de F1. O mesmo procedimento é também realizado, nas mesmas condições, em relação ao tamanho do modelo, seguindo a Tabela 14. A Figura 7 apresenta o gráfico resultante.

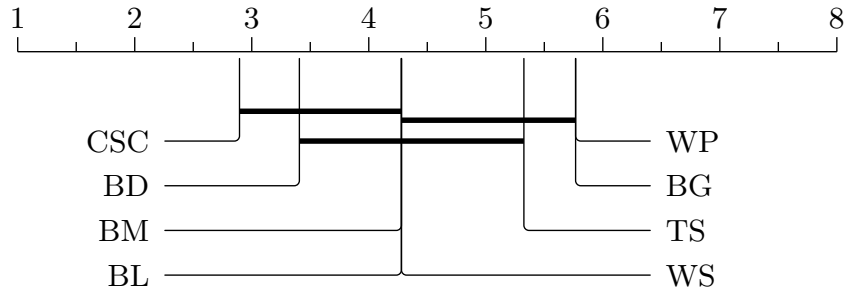


Figura 6 – Gráfico de diferença crítica, em relação aos valores de F1, para comparar as 8 configurações (fluxos) presentes na linha 1 da Tabela 13 ao longo dos 43 datasets.

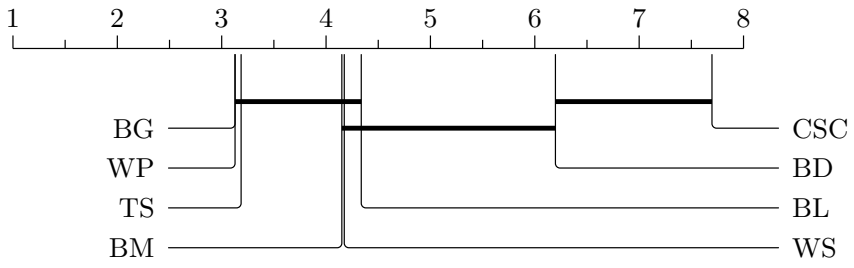


Figura 7 – Gráfico de diferença crítica, em relação aos tamanhos dos modelos, para comparar as 8 configurações (fluxos) presentes na linha 1 da Tabela 13 ao longo dos 43 datasets.

Nos gráficos de diferença crítica as linhas que saem do eixo enumerado indicam o rank médio da respectiva configuração. As linhas que encontram-se conectadas por uma barra correspondem as configurações que não apresentam diferença crítica entre si. A análise realizada, por exemplo, na Figura 6, indica que a configuração referente ao método **[CSC]** apresenta aproximadamente 2,9 de rank médio, não apresentando diferença em relação aos métodos **[BD]**, **[BM]**, **[BL]** e **[WS]**. Assim, analisando os gráficos das Figuras 6 e 7 simultaneamente, uma vez que busca-se um equilíbrio entre F1 e tamanho do modelo, i.e, desempenho e interpretabilidade, é possível notar que:

- Em relação ao F1 (Figura 6), embora o **[CSC]** apareça na primeira posição, destacando-se com o menor rank médio, o mesmo não apresenta diferença estatística significativa em relação ao $AC.Rank_A$ instanciado com os métodos **[BD]**, **[BM]**, **[BL]** e **[WS]** no Grupo **[TW]**;

- Já em relação ao tamanho do modelo (Figura 7), o **[CSC]** aparece na última posição, destacando-se com o maior rank médio, apresentando diferença estatística significativa em relação ao $AC.Rank_A$ instanciado com os métodos **[BG]**, **[WP]**, **[TS]**, **[BM]**, **[WS]** e **[BL]** no Grupo **[TW]**;

- Assim, considerando-se ambos os critérios simultaneamente, nota-se que o $AC.Rank_A$, instanciado com os métodos **[BM]**, **[BL]** e **[WS]**, mantém o desempenho dos modelos em relação ao **[CSC]**, porém com uma melhor interpretabilidade.

Esta metodologia de análise foi utilizada em todas as demais combinações, a fim de comparar o ranqueamento **[CSC]** (*baseline*) com o $AC.Rank_A$. Como o número de gráficos de diferença crítica gerados é grande, visando facilitar a análise, a Tabela 15 foi construída a partir dos mesmos. Na primeira coluna encontra-se o grupo de medidas utilizado para se instanciar o $AC.Rank_A$, na segunda o método de poda, na terceira o método de predição e nas demais colunas o método de agregação utilizado para se instanciar o $AC.Rank_A$. Cada célula da tabela expressa a existência ou não de uma diferença crítica entre o ranqueamento **[CSC]** e o $AC.Rank_A$, em ambos o critérios analisados, em uma dada configuração. O primeiro valor da célula se refere a existência de diferença em relação ao F1 e o segundo em relação ao tamanho do modelo. A indicação da existência ou não de uma diferença estatística é representada por três símbolos distintos, a saber: ≡ para os casos em que não há diferença; ▲ para os casos em que há diferença e ela é positiva para o ranqueamento $AC.Rank_A$; ▼ para os casos em que há diferença e ela é negativa para o ranqueamento $AC.Rank_A$, i.e., ela é positiva para o ranqueamento **[CSC]**.

A fim de exemplificar, considere os gráficos de diferença crítica das Figuras 6 e 7, referentes aos dados da primeira linha da Tabela 13, os quais correspondem as análises da primeira linha da tabela aqui apresentada (Tabela 15). Como observado anteriormente, os métodos **[BD]**, **[BL]**, **[BM]** e **[WS]**, no grupo de medidas **[TW]**, não apresentaram diferenças estatística em relação ao **[CSC]** no que se refere ao F1; portanto, nesta tabela, todos eles têm um ≡ na primeira posição de suas respectivas células. Por outro lado, **[BG]**, **[TS]** e **[WP]**, por terem apresentado diferença negativa em relação ao **[CSC]** em relação ao F1 têm um ▼ na primeira posição de suas respectivas células. Já no que se refere ao critério tamanho do modelo, **[BG]**, **[BL]**, **[BM]**, **[TS]**, **[WP]** e **[WS]**, por terem apresentado diferença positiva em relação ao **[CSC]** têm um ▲ na segunda posição de suas respectivas células. Já **[BD]** apresenta um ≡, por não ter apresentado diferença em relação ao **[CSC]**.

Tabela 15 – Resultados referentes a análise de diferença crítica entre os métodos de ranqueamento $AC.Rank_A$ e **[CSC]** em diversos fluxos de indução (continua na próxima página).

MOs	Poda	Pred	Método de Agregação													
			BD		BG		BL		BM		TS		WP		WS	
			F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$
TW	M1	O	≡	≡	▼	▲	≡	▲	≡	▲	▼	▲	▼	▲	≡	▲
		V	≡	≡	▼	▲	≡	▲	≡	▲	▼	▲	▼	▲	≡	▲
		R	≡	≡	▼	▲	≡	▲	≡	▲	▼	▲	▼	▲	≡	▲
		P	≡	≡	▼	▲	▼	▲	≡	▲	▼	▲	▼	▲	≡	▲
	CV	O	≡	≡	▼	▲	≡	▲	▼	▲	▼	▲	▼	▲	▼	▲
		V	≡	≡	▼	▲	≡	▲	≡	▲	▼	▲	▼	▲	≡	▲
		R	≡	≡	≡	▲	≡	▲	≡	▲	▼	▲	≡	▲	≡	▲
		P	≡	≡	▼	▲	≡	▲	≡	▲	▼	▲	▼	▲	≡	▲
	DN	O	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		V	≡	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲
		R	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		P	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲
GF	M1	O	≡	≡	≡	▲	≡	▲	≡	≡	≡	▲	≡	▲	≡	≡
		V	≡	≡	≡	▲	≡	▲	≡	≡	≡	▲	≡	▲	≡	≡
		R	≡	≡	≡	▲	≡	▲	≡	≡	≡	▲	≡	▲	≡	≡
		P	≡	≡	≡	▲	≡	▲	≡	≡	≡	▲	≡	▲	≡	≡
	CV	O	≡	≡	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	≡
		V	≡	≡	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	≡
		R	≡	≡	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	≡
		P	≡	≡	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	≡
	DN	O	▲	≡	≡	▲	▲	▲	▲	▲	≡	▲	≡	▲	▲	▲
		V	≡	≡	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		R	≡	≡	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		P	▼	≡	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲
C1	M1	O	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		V	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		R	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		P	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
	CV	O	≡	≡	≡	▼	≡	≡	≡	≡	≡	▼	≡	▼	≡	≡
		V	▲	≡	≡	▼	≡	≡	≡	≡	≡	▼	≡	▼	≡	≡
		R	≡	≡	≡	▼	≡	≡	≡	≡	≡	▼	≡	▼	≡	≡
		P	≡	≡	≡	▼	≡	≡	≡	≡	≡	▼	≡	▼	≡	≡
	DN	O	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		V	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		R	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		P	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡

Tabela 15 – Resultados referentes a análise de diferença crítica entre os métodos de ranqueamento $AC.Rank_A$ e **[CSC]** em diversos fluxos de indução (continuação).

MOs	Poda	Pred.	Resultados													
			BD		BG		BL		BM		TS		WP		WS	
			F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$	F1	$\mathcal{L}$
G1	M1	O	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼
		V	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼
		R	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼
		P	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼
	CV	O	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼
		V	≡	≡	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼
		R	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼
		P	≡	≡	≡	▼	▲	▼	≡	▼	≡	▼	≡	▼	≡	▼
	DN	O	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		V	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		R	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
		P	▼	▲	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡	▼	≡
G2	M1	O	≡	≡	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		V	≡	≡	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		R	≡	≡	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		P	≡	≡	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
	CV	O	≡	▼	≡	≡	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡
		V	≡	▼	≡	≡	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡
		R	≡	▼	≡	≡	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡
		P	≡	▼	≡	≡	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡
	DN	O	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		V	▼	▲	≡	▲	▼	▲	▼	▲	▼	▲	≡	▲	▼	▲
		R	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲	≡	▲
		P	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲

Por fim, alguns resultados foram destacados na Tabela 15. Células em que há diferença estatística positiva para ambos os critérios foram destacadas em verde escuro (▲ e ▲). Células em que há diferença estatística positiva em pelo menos um dos critérios, desde que o outro não apresente diferença, foram destacadas em verde claro ((≡ e ▲) e (▲ e ≡)). Ambos indicam resultados favoráveis ao ranqueamento $AC.Rank_A$ em relação ao **[CSC]**, uma vez que melhoram ambos os critérios ou apenas um, desde que o outro se mantenha, garantindo um equilíbrio entre os dois. Por outro lado, células em que há diferença estatística negativa para ambos os critérios foram destacadas em vermelho escuro (▼ e ▼). Células em que há diferença estatística negativa em pelo menos um dos critérios, desde que o outro não apresente diferença, foram destacadas em vermelho claro ((≡ e ▼) e (▼ e ≡)). Ambos indicam resultados desfavoráveis ao ranqueamento $AC.Rank_A$ em relação ao **[CSC]**, uma vez que pioram ambos os critérios ou apenas um, desde que o outro se mantenha. Os demais casos, que representam comportamentos inversamente proporcionais, foram destacados em azul claro ((▲ e ▼), (▼ e ▲)). Note, em relação ao exemplo anteriormente utilizado (primeira linha), que três instâncias do $AC.Rank_A$ apresentam destaque em verde em relação ao **[CSC]**.

Diante do exposto, analisando a Tabela 15, tem-se que:

- Em relação ao grupo de MOs utilizadas para se instanciar o $AC.Rank_A$, nota-se que os conjuntos **[TW]**, **[GF]** e **[G2]** foram os que obtiveram os resultados mais satisfatórios (células verde), porém com diferenças entre si:
  - O grupo **[TW]** apresenta bom resultado em 45,24% (38 de 84 células) das configurações (células verde). Contudo, o mesmo exibe a mesma proporção quando os critérios de avaliação apresentam uma relação inversa, i.e., 45,24% (38) de células azul, tendo os modelos um menor F1 (▼) e um melhor tamanho (▲) em relação ao **[CSC]**. Assim, na média, o mesmo não se apresenta como uma boa opção, já que não se garante, na maioria dos casos, um resultado pelo menos igual ao do **[CSC]**;
  - Já o grupo **[GF]** apresenta bom resultado em 47,62% (40) das configurações (células verde claro). Além disso, em 3,57% (3) das configurações o mesmo apresenta melhor resultado em relação a ambos os critérios avaliados (células verde escuro). Por fim, o mesmo mantém o mesmo desempenho em relação ao **[CSC]** em 40,48% (34) das configurações (células amarelas). Assim, o mesmo se apresenta como uma boa opção, já que é possível melhorar ou manter os resultados em mais de 90% das vezes;
  - Já o grupo **[G2]** fica entre o **[GF]** e o **[TW]**. O mesmo apresenta bom resultado em 52,38% (44) das configurações (células verde). Contudo, embora o grupo mantenha o mesmo desempenho em relação ao **[CSC]** em 28,57% (24) das configurações (células amarela), o mesmo apresenta uma ocorrência de 14,29% (12) quando se trata da relação inversa entre os critérios de avaliação (células azul). Entretanto, estes casos

ocorrem apenas nos fluxos em que a poda **[DN]** é utilizada. Assim, desconsiderando os fluxos relacionados a poda **[DN]** (28), o mesmo se apresenta com resultados semelhantes ao **[GF]**: 50% de células verde (28/56) e 42,86% de células amarela (24/56).

Considerando o exposto, tem-se que o grupo **[GF]** é o mais adequado para se instanciar o $AC.Rank_A$. Vale mencionar que os grupos **[C1]** e **[G1]** não obtiveram bons resultados: **[C1]** apresenta resultados praticamente semelhantes ao **[CSC]** (77,58% de células amarela (65)), com alguns resultados inferiores ao mesmo (20,24% de células vermelho claro (17)); **[G1]** apresenta, em mais da metade das configurações, resultados inferiores ao **[CSC]**.

- Em relação aos métodos de agregação utilizados para se instanciar o $AC.Rank_A$, nota-se que:
  - Quando combinados com o grupo **[TW]**, **[BL]**, **[BM]** e **[WS]** se destacam, todos eles cobrindo 75% das configurações (9 de 12 células);
  - Quando combinados com o grupo **[GF]**, **[BL]** e **[TS]** se destacam, ambos cobrindo 91,67% das configurações (11/12);
  - Quando combinados com os grupos **[C1]** e **[G1]**, **[BD]** se destaca cobrindo, respectivamente, 16,67% (2/12) e 25% (3/12) das configurações;
  - Quando combinados com o grupo **[G2]**, **[BL]** se destaca cobrindo 83,33% das configurações (10/12);

  Considerando o exposto, tem-se que o método que mais se destaca é o **[BL]**.

Considerando a discussão acima apresentada, tem-se, portanto, que a melhor instância do $AC.Rank_A$ é a que combina **[GF]+[BL]**, devendo, portanto, ser a utilizada na execução do mesmo.

5.3 Análise Complementar

Conforme mencionado ao longo do texto, os trabalhos mais relacionados ao trabalho aqui apresentado são o de Silva e Carvalho (2018), Dall'Agnol e Carvalho (2020a) e Bui-Thi, Meysman e Laukens (2022). Assim, esta seção tem por objetivo discutir alguns aspectos relacionados aos mesmos quando comparados aos resultados aqui apresentados.

Desempenho e Interpretabilidade. Em relação aos dois critérios de avaliação utilizados, pode-se mencionar que:

- Em Dall'Agnol e Carvalho (2023b) os métodos propostos em Silva e Carvalho (2018) (**[BK]**) e Dall'Agnol e Carvalho (2020a) (**[EN]**) foram apresentados e comparados com o método $AC.Rank_A$ quando instanciado com os grupos **[TW]** e **[GF]** e combinados com os métodos **[BD]**, **[BG]**, **[BL]** e **[BM]**. Vale mencionar que a análise foi realizada em apenas um dos fluxos aqui explorados (os com poda **[M1]** e predição **[O]**). Foi possível observar que, em termos de F1, as configurações referentes ao grupo **[GF]**, em combinação com os métodos de Borda, se sobressaíram em relação aos dois trabalhos da literatura, i.e., **[BK]** e **[EN]**, considerando o rank médio. Contudo, as mesmas não apresentaram diferença estatística significativa em relação ao CBA. Entretanto, a instância **[GF+BL]** de $AC.Rank_A$ aparece, em geral, como a melhor ou uma das melhores configurações. Assim, em média, melhores resultados são obtidos com a mesma e, nos piores os casos, serão iguais ao CBA, como visto na seção anterior.

  Já em relação ao tamanho do modelo, o método **[EN]**, por si só, já apresenta problemas de interpretabilidade. Devido ao fato da solução ser um comitê de classificadores, entender como se chegou a determinada predição se torna difícil. Além disso, uma vez que a solução contém muitos modelos existem diversas maneiras de se calcular o número total de regras (soma das regras nos modelos, média das regras nos modelos, etc.). Assim, em Dall'Agnol e Carvalho (2023b), o método **[EN]** nem foi considerado na análise em relação a este critério. Por outro lado, o método **[BK]** se mostrou o mais compacto de todos as configurações exploradas. Contudo, o mesmo apresenta uma relação inversa entre desempenho e interpretabilidade, já que o mesmo fica entre os piores métodos em termos de F1. Além disso, **[BK]** apresenta, com diferença estatística significativa, um tempo de execução maior em relação aos demais métodos, como será visto logo abaixo. Em relação ao $AC.Rank_A$, a instância que se destacou foi a **[TG+BL]**, apresentado um equilíbrio entre F1 e tamanho (mantém F1 e diminui $\mathcal{L}$).

  Assim, pôde-se observar em Dall'Agnol e Carvalho (2023b) que o $AC.Rank_A$ se sobressai em relação aos métodos **[BK]** e **[EN]** quando se visa um melhor equilíbrio entre desempenho e interpretabilidade. Optou-se, a fim de deixar o texto mais enxuto, por apresentar aqui apenas as conclusões obtidas, já que os detalhes encontram-se disponíveis no artigo.

- Já em relação ao trabalho de Bui-Thi, Meysman e Laukens (2022), vale mencionar que a ideia era executá-lo nos mesmos conjuntos de dados aqui utilizados e incluí-lo na análise comparativa. Assim, inicialmente baixou-se a implementação do método do GitHub[2] e tentou-se obter os mesmos resultados reportados no artigo. Contudo, a saída do método, por ser baseado em algoritmo genético, é uma coleção de indivíduos, sendo necessário se optar por uma solução (indivíduo) em específico. Para tanto, um gráfico, como o apresentado

[2] <https://github.com/banhdzui/MoMAC-v1>.

na Figura 8 é apresentado ao usuário, de modo que ele selecione a solução desejada. Nesta figura, 25 soluções candidatas são apresentadas para um dos conjuntos de dados avaliados no trabalho. Cada uma visa otimizar Acurácia e $\mathcal{L}$: no eixo x encontra-se o erro (1-Acurácia) obtido pela solução e no eixo y o tamanho do modelo ($\mathcal{L}$). Neste caso os autores sugerem tanto a solução 3 quanto a 20, uma vez que equilibram erro e $\mathcal{L}$. No entanto, esta escolha não foi trivial em testes realizados em outros conjuntos de dados. Assim, não era possível saber a solução por eles escolhida para que as análises, assim como os testes estatísticos, fossem realizados. Portanto, optou-se por realizar uma discussão tendo como base os resultados por eles apresentado no artigo.

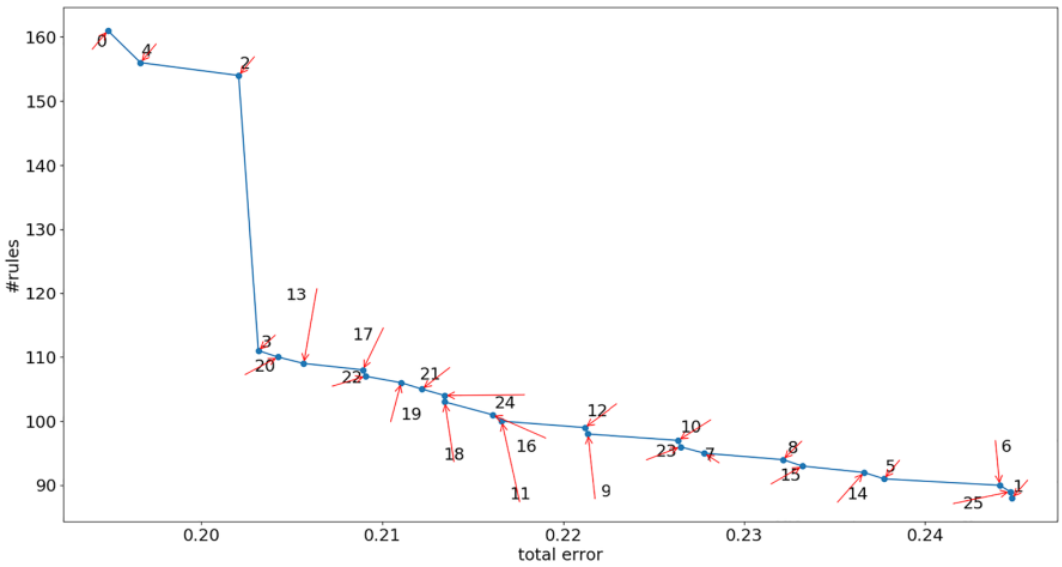


Figura 8 – Gráfico de saída apresentado para escolha da solução desejada referente a um conjunto de dados. Fonte: Bui-Thi, Meysman e Laukens (2022).

Em relação ao desempenho, computado via F1-Micro, os autores comparam o método por eles proposto (**[MoMAC]**) com diversos outros algoritmos, incluindo o CBA e o CMAR. Em relação a estes algoritmos o **[MoMAC]** se apresenta superior; já em relação a outros algoritmos o mesmo não apresenta diferença estatística significativa (os autores usaram Friedman com Bonferroni-Dunn). Contudo, vale mencionar que os ranks médios obtidos para as configurações exploradas são próximos e, a depender da solução (indivíduo) escolhida, os resultados dos testes estatísticos podem mudar (pequenas diferenças de valores alteram os ranks).

Já em relação ao tamanho do modelo, o **[MoMAC]** apresenta modelos bem maiores do que o CBA e de que outros algoritmos explorados. Assim, mesmo modelando-se a solução por meio de um problema de otimização, o **[MoMAC]** apresenta uma relação inversa entre desempenho e interpretabilidade. Por fim, vale mencionar que o usuário deve especificar o erro máximo que o modelo pode cometer, assim como o número máximo de regras

que podem estar contidas nos modelos finais. São várias as escolhas que interferem nos resultados apresentados.

Tempo de Execução. Um outro critério não abordado neste trabalho se refere ao tempo de execução dos métodos. Este critério foi apresentado em Dall'Agnol e Carvalho (2023b). Em relação a este aspecto, nota-se que:

- Em Dall'Agnol e Carvalho (2023b) apresentam-se os tempos de execução dos métodos **[BK]** e **[EN]**, assim como do método $AC.Rank_A$ quando instanciado com os grupos **[TW]** e **[GF]** e combinados com os métodos **[BD]**, **[BG]**, **[BL]** e **[BM]**. Para efeitos de comparação, o tempo médio de execução do $AC.Rank_A$ ficou em torno de 3,2 segundos e do CBA em torno de 3 segundos. Já o método **[BK]** apresenta valores entre 41 e 63 segundos e **[EN]** entre 6 e 10 segundos, a depender do conjunto de MOs utilizado. Assim, o $AC.Rank_A$ se mostra competitivo não apenas em termos de desempenho e interpretabilidade, mas também em termos de tempo de execução.
- Bui-Thi, Meysman e Laukens (2022) também exploram esta questão. Por ser uma solução baseada em redes neurais e algoritmo genético, o mesmo é, em geral, bem mais lento que quase todos os algoritmos utilizados na análise comparativa, inclusive em relação ao CBA e ao CMAR (**[MoMAC]** só não perde para um dos algoritmos selecionados).

Considerações finais. Considerando a discussão acima apresentada, é possível concluir que o $AC.Rank_A$ é o método que melhor mantém o equilíbrio entre desempenho e interpretabilidade, além de ter um tempo de execução competitivo com o CBA. Os métodos da literatura apresentam uma relação inversa entre desempenho e interpretabilidade, além de serem mais custosos de serem executados.

6 Conclusão

Este trabalho apresentou um método de ranqueamento via agregação de MOs, denominado $AC.Rank_A$, a ser incorporado a fluxos de indução de CAs, visando a indução de modelos que apresentem um melhor equilíbrio entre desempenho e interpretabilidade. Estudos anteriores, na mesma linha deste trabalho, já haviam utilizado Pareto (SILVA; CARVALHO, 2018; DALL'AGNOL; CARVALHO, 2020b), comitê de classificadores (DALL'AGNOL; CARVALHO, 2020a) e otimização multiobjetivo (BUI-THI; MEYSMAN; LAUKENS, 2022). Contudo, em todos eles um desequilíbrio entre desempenho e interpretabilidade foi verificado, existindo uma relação inversa entre eles. Assim, neste trabalho optou-se por utilizar análise de decisão multicritérios (MCDA) e agregação de rankings, tendo como base trabalhos de agregação de MOs no contexto de regras de associação (MAZOURI; ABOUNAIMA; ZENKOUAR, 2017; MAZOURI; ABOUNAIMA; ZENKOUAR, 2019; DAHBI *et al.*, 2020b).

Para que o $AC.Rank_A$ funcione, o mesmo deve ser instanciado com um conjunto de MOs e um método de agregação. Os conjuntos de MOs explorados foram os extraídos da literatura e os propostos neste trabalho, a saber: **[TW]** e **[GF]**, extraídos da literatura, **[C1]**, **[G1]** e **[G2]**, propostos neste trabalho. Os conjuntos propostos foram obtidos a partir da análise do comportamento de 44 MOs quando aplicadas na etapa de ordenação dos CAs. Para tanto as medidas foram agrupadas via Complete Linkage e os grupos extraídos analisados via F1-Macro. Os métodos de agregação selecionados foram o **[BD]**, **[BM]**, **[BL]** e **[BG]**, referentes a família de agregação de rankings, assim como **[TS]**, **[WS]** e **[WP]**, referentes a família MCDA.

O método proposto foi avaliado em diversos fluxos de indução de CAs em relação a desempenho, medido via F1-Macro, e interpretabilidade, medida via tamanho do modelo. Ambos os critérios foram estimados via 10-fold cross-validation estratificado. Os experimentos foram executados em 43 conjuntos de dados. O método de ranqueamento utilizado como baseline foi o do CBA, i.e., **[CSC]**. A análise foi toda baseada em testes estatísticos, comparando-se os diversos fluxos quando o ranqueamento acontece via **[CSC]** e via $AC.Rank_A$.

Em relação aos resultados obtidos, pôde-se observar que:

- O método $AC.Rank_A$, em comparação com os trabalhos da literatura, é o que melhor mantém o equilíbrio entre desempenho e interpretabilidade, além de ter um tempo de execução competitivo com o CBA;
- Fica evidente, em diversos experimentos, a relação inversa entre desempenho e interpretabilidade, sendo possível observar em diversas configurações uma melhora no tamanho do

modelo e uma piora no desempenho (e vice-versa), como as configurações relacionadas ao grupo de MOs **[TW]**;

- A melhor instância do $AC.Rank_A$ é a que combina **[GF]+[BL]**, devendo, portanto, ser a utilizada na execução do mesmo. Essa combinação garante um bom desempenho e uma boa interpretabilidade em relação ao ranqueamento **[CSC]**, já que é possível se melhorar ou manter os resultados em mais de 90% das vezes. Em outras palavras, é possível se melhorar a interpretabilidade sem perdas consideráveis em desempenho. Supõe-se que o grupo **[GF]** tenha se saído melhor por ter sido extraído de conjuntos com as mais diversas distribuições (IR) e, que, de certa maneira, contribuiu para a ordenação das regras nas mais diversas classes;

- Em relação aos grupos de MOs propostos, **[G1]** acabou apresentando resultados inferiores ao **[GF]**. Por outro lado, **[G2]** apresentou resultados próximos ao **[GF]**, porém com mais configurações com relações inversamente proporcionais. Já o grupo **[C1]** faz com que os resultados obtidos sejam equivalentes ao do ranqueamento **[CSC]**. Supõe-se que os grupos **[G1]** e **[G2]** não mantiveram tão bem o equilíbrio entre F1 e $\mathcal{L}$ por terem sido selecionados apenas em função de $F1_\mu$. Um ponto a ser futuramente explorado, analisando novamente a Figura 4, é se outros grupos, que melhor equilibram F1 e $\mathcal{L}$, não se sairiam melhor;

- Entre os métodos de agregação apresentados, **[BL]**, **[BM]**, **[WS]**, **[TS]** e **[BD]** se destacam a depender do grupo de MOs utilizado; porém, **[BL]** é o que mais se destaca.

No que se refere a trabalhos futuros, pode-se mencionar:

- Um estudo mais detalhado sobre os grupos de MOs, uma vez que foi notório o impacto deste parâmetro nos resultados, sendo responsável por grandes mudanças tanto na interpretabilidade, quanto no desempenho do modelo;

- Uma análise sobre a aplicação do método aqui proposto em conjuntos de dados desbalanceados, uma vez que adaptações tenham de ser realizadas;

- Uma exploração de métodos de agregação mais recentes, não apenas no escopo de agregação de rankings e MCDA.

Por fim, vale mencionar que parte dos resultados aqui apresentados foram publicados e apresentados, como já mencionado anteriormente. As duas publicações, Dall'Agnol e Carvalho (2023a) e Dall'Agnol e Carvalho (2023b).

REFERÊNCIAS

ABDELLATIF, S.; HASSINE, M. A. B.; YAHIA, S. B. *Novel Interestingness Measures for Mining Significant Association Rules from Imbalanced Data*. [S.l.: s.n.], 2019. 172–182 p. ISBN 978-3-319-98284-7. Citado na página 30.

AGRAWAL, R.; IMIELIńSKI, T.; SWAMI, A. Mining association rules between sets of items in large databases. *SIGMOD Rec.*, Association for Computing Machinery, New York, NY, USA, v. 22, n. 2, p. 207–216, jun. 1993. ISSN 0163-5808. Citado na página 16.

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules in large databases. In: *Proceedings of the 20th International Conference on Very Large Data Bases*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1994. (Vldb '94), p. 487–499. ISBN 1558601538. Citado 4 vezes na(s) página(s) 15, 16, 17 e 18.

ARUNASALAM, B.; CHAWLA, S. CCCS: a top-down associative classifier for imbalanced class distribution. In: . [S.l.: s.n.], 2006. p. 517–522. Citado na página 31.

AYYAT, S.; LU, J.; THABTAH, F. A. Class strength prediction method for associative classification. In: . [S.l.: s.n.], 2014. Citado na página 36.

AZEVEDO, P. J.; JORGE, A. M. Comparing rule measures for predictive association rules. In: *Machine Learning: ECML 2007*. [S.l.: s.n.], 2007. p. 510–517. Citado na página 31.

AZMI, M.; BERRADO, A. Class-association rules pruning using regularization. *Proceedings of IEEE/ACS International Conference on Computer Systems and Applications, AICCSA*, v. 0, 2016. ISSN 21615330. Citado na página 34.

AZMI, M.; BERRADO, A. RCAR framework: Building a regularized class association rules model in a categorical data space. In: *Proceedings of the 13th International Conference on Intelligent Systems: Theories and Applications*. New York, NY, USA: Association for Computing Machinery, 2020. ISBN 9781450377331. Citado na página 12.

BASHA, M. S. Early prediction of cardio vascular disease by performing associative classification on medical datasets and using genetic algorithm. In: PENG, S.-L. *et al.* (Ed.). *Intelligent Computing and Innovation on Data Science*. Singapore: Springer Singapore, 2021. p. 393–402. ISBN 978-981-16-3153-5. Citado na página 11.

BECHINI, A.; MARCELLONI, F.; SEGATORI, A. A MapReduce solution for associative classification of big data. *Information Sciences*, Elsevier Inc., v. 332, p. 33–55, 2016. ISSN 00200255. Citado 2 vezes na(s) página(s) 23 e 29.

BONG, K. *et al.* Selection and aggregation of interestingness measures: A review. *Journal of Theoretical and Applied Information Technology*, v. 59, p. 146–166, 01 2014. Citado 3 vezes na(s) página(s) 12, 18 e 32.

BORDA, J.-C. de. Mémoire sur les élections au scrutin. *Histoire de l'Académie Royale des Sciences*, 1781. Citado na página 55.

BORZSONY, S.; KOSSMANN, D.; STOCKER, K. The Skyline operator. In: *Proceedings 17th International Conference on Data Engineering*. [S.l.: s.n.], 2001. p. 421–430. Citado na página 32.

BOUKER, S. *et al.* Mining undominated association rules through interestingness measures. *International Journal on Artificial Intelligence Tools*, v. 23, n. 4, 2014. ISSN 17936349. Citado 3 vezes na(s) página(s) 22, 32 e 33.

BREIMAN, L. Bagging predictors. *Machine Learning*, v. 24, p. 123–140, 1996. Citado na página 36.

BUI-THI, D.; MEYSMAN, P.; LAUKENS, K. MoMAC: Multi-objective optimization to combine multiple association rules into an interpretable classification. *Applied Intelligence*, Kluwer Academic Publishers, Usa, v. 52, n. 3, p. 3090–3102, feb 2022. ISSN 0924-669x. Citado 14 vezes na(s) página(s) ix, 13, 14, 28, 33, 35, 37, 40, 50, 68, 69, 70, 71 e 72.

DAHBI, A. *et al.* A new method for ranking association rules with multiple criteria based on dominance relation. In: *ACS/IEEE 13th International Conference of Computer Systems and Applications (AICCSA)*. [S.l.: s.n.], 2016. p. 1–7. Citado 3 vezes na(s) página(s) 22, 32 e 33.

DAHBI, A. *et al.* Selecting, sorting and ranking association rules with multiple criteria using dominance relation. *Advances in Mathematics: Scientific Journal*, v. 9, n. 11, p. 9489–9508, 2020. ISSN 18578438. Citado na página 22.

DAHBI, A. *et al.* The selection of the relevant association rules using the electre method with multiple criteria. *IAES International Journal of Artificial Intelligence (IJ-AI)*, v. 9, p. 638 645, 10 2020. Citado 5 vezes na(s) página(s) 14, 33, 50, 51 e 72.

DALL'AGNOL, M.; CARVALHO, V. O. Objective measures ensemble in associative classifiers. In: INSTICC. *Proceedings of the 22nd International Conference on Enterprise Information Systems - Volume 1: ICEIS,*. [S.l.]: SciTePress, 2020. p. 83–90. ISBN 978-989-758-423-7. Citado 13 vezes na(s) página(s) 13, 14, 33, 36, 37, 38, 40, 41, 47, 50, 68, 69 e 72.

DALL'AGNOL, M.; CARVALHO, V. O. de. Comparação entre abordagens de ranqueamento de regras de associação baseadas em dominância no contexto de classificadores associativos. IGCE, Unesp, 2020. Citado 7 vezes na(s) página(s) 13, 14, 33, 37, 40, 50 e 72.

DALL'AGNOL, M.; CARVALHO, V. O. D. Clustering the behavior of objective measures in associative classifiers. In: *2023 18th Iberian Conference on Information Systems and Technologies (CISTI)*. [S.l.: s.n.], 2023. p. 1–6. Citado 10 vezes na(s) página(s) x, xiii, 14, 41, 42, 45, 46, 47, 48 e 73.

DALL'AGNOL, M.; CARVALHO, V. O. D. Ranking rules in associative classifiers via borda's methods. In: *2023 18th Iberian Conference on Information Systems and Technologies (CISTI)*. [S.l.: s.n.], 2023. p. 1–6. Citado 6 vezes na(s) página(s) 14, 33, 38, 69, 71 e 73.

DATTA, S.; BOSE, S. Mining and ranking association rules in support, confidence, correlation, and dissociation framework. *Advances in Intelligent Systems and Computing*, v. 404, n. May 2018, p. 141–152, 2016. ISSN 21945357. Citado na página 31.

DATTA, S.; MALI, K.; ROY, P. Ranking of association rules toward smart decision for smart city. *Proceedings of the 2017 International Conference on Wireless Communications, Signal Processing and Networking, WiSPNET 2017*, v. 2018-Janua, p. 1398–1403, 2018. Citado na página 31.

DEB, K. *et al.* A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, v. 6, n. 2, p. 182–197, 2002. Citado na página 38.

DEHKORDI, M. N.; SHENASSA, M. H. Cpar: Classification based on predictive association rules. *IEEE Intelligent Systems*, p. 483–487, 2006. ISSN 15411672. Citado na página 24.

DEMSAR, J. Statistical comparisons of classifiers over multiple data sets. *J. Mach. Learn. Res.*, JMLR.org, v. 7, p. 1–30, dez. 2006. ISSN 1532-4435. Citado na página 60.

DHARINI, B.; JAYANTHI, M.; JOYCE, A. An efficient method for associative classification using jaccard measure. *International Journal of Recent Technology and Engineering*, v. 8, n. 2 Special Issue 11, p. 3448–3453, 2019. Citado na página 31.

DWORK, C.; NAOR, M.; SIVAKUMAR, D. Rank aggregation revisited. 03 2003. Citado na página 54.

FAYYAD, U. M.; IRANI, K. B. Multi-interval discretization of continuous-valued attributes for classification learning. In: *International Joint Conference on Artificial Intelligence*. [S.l.: s.n.], 1993. p. 1022–1029. Citado na página 60.

FILIP, J.; KLIEGR, T. *Classification based on Associations (CBA) - a performance analysis*. 2018. Citado 3 vezes na(s) página(s) 12, 24 e 57.

FREUND, Y.; SCHAPIRE, R. E. Experiments with a new boosting algorithm. In: *Proceedings of the Thirteenth International Conference on International Conference on Machine Learning*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1996. (Icml'96), p. 148–156. ISBN 1558604197. Citado na página 36.

GENG, L.; HAMILTON, H. J. Interestingness measures for data mining: A survey. *ACM Computing Surveys*, v. 38, n. 3, p. 3, 2006. ISSN 03600300. Citado 4 vezes na(s) página(s) x, 18, 20 e 22.

HAHSLER, M. *et al.* Associative classification in r: Arc, arulescba, and rcba. *R Journal*, v. 11, n. 2, p. 254–267, 2019. Citado na página 12.

HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. *SIGMOD Rec.*, Association for Computing Machinery, New York, NY, USA, v. 29, n. 2, p. 1–12, maio 2000. ISSN 0163-5808. Citado na página 26.

HU, L.-Y. *et al.* Building an associative classifier with multiple minimum supports. *SpringerPlus*, SpringerOpen, v. 5, n. 1, p. 1–19, 2016. Citado na página 30.

HWANG, C.-L.; YOON, K. *Methods for Multiple Attribute Decision Making*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1981. 58–191 p. ISBN 978-3-642-48318-9. Citado 2 vezes na(s) página(s) 51 e 53.

JALALI-HERAVI, M.; ZAÏANE, O. R. A study on interestingness measures for associative classifiers. In: *Proceedings of the 2010 ACM Symposium on Applied Computing*. [S.l.: s.n.], 2010. p. 1039–1046. Citado na página 31.

KLIEGR, T. QCBA: Postoptimization of quantitative attributes in classifiers based on association rules. *arXiv:1711.10166*, 2019. Citado na página 35.

LAKKARAJU, H.; BACH, S. H.; LESKOVEC, J. Interpretable decision sets: A joint framework for description and prediction. In: KRISHNAPURAM, B. *et al.* (Ed.). *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, CA, USA, August 13-17, 2016*. [S.l.]: Acm, 2016. p. 1675–1684. Citado na página 28.

LAN, Y. *et al.* Improving associative classification by incorporating novel interestingness measures. In: *IEEE International Conference on e-Business Engineering (ICEBE'05)*. [S.l.: s.n.], 2005. p. 282–287. Citado na página 31.

LE, T.-D. B.; LO, D. Beyond support and confidence: Exploring interestingness measures for rule-based specification mining. In: *2015 IEEE 22nd International Conference on Software Analysis, Evolution, and Reengineering (SANER)*. [S.l.: s.n.], 2015. p. 331–340. Citado na página 32.

LE, T. T. N.; HUYNH, H. X.; GUILLET, F. Knowledge acquisition: Approaches, algorithms and applications. In: . [S.l.: s.n.], 2009. cap. Finding the Most Interesting Association Rules by Aggregating Objective Interestingness Measures, p. 40–49. Citado 2 vezes na(s) página(s) 32 e 33.

LENCA, P. *et al.* A multicriteria decision aid for interestingness measure selection. p. 30, maio 2004. Citado na página 22.

LI, J.; ZAIANE, O. R. Exploiting statistically significant dependent rules for associative classification. *Intelligent Data Analysis*, v. 21, n. 5, p. 1155–1172, 2017. ISSN 1088-467x. Citado na página 36.

LI, W.; HAN, J.; PEI, J. CMAR: Accurate and efficient classification based on multiple class-association rules. *Proceedings - IEEE International Conference on Data Mining, ICDM*, p. 369–376, 2001. ISSN 15504786. Citado na página 24.

LI, X.; WANG, X.; XIAO, G. A comparative study of rank aggregation methods for partial and top ranked lists in genomic applications. *Briefings in Bioinformatics*, v. 20, n. 1, p. 178–189, 08 2017. ISSN 1477-4054. Citado na página 55.

LIN, S. Rank aggregation methods. *WIREs Computational Statistics*, v. 2, n. 5, p. 555–570, 2010. Citado 3 vezes na(s) página(s) 54, 55 e 56.

LIU, B.; HSU, W.; MA, Y. Integrating classification and association rule mining. In: *In Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining (KDD-98),*. [S.l.: s.n.], 1998. p. 27–31. Citado 4 vezes na(s) página(s) 12, 23, 24 e 26.

LUNA, J. M. *et al.* Optimization of quality measures in association rule mining: An empirical study. *International Journal of Computational Intelligence Systems*, v. 12, p. 59–78, 11 2018. Citado 2 vezes na(s) página(s) 20 e 42.

MARGOT, V.; LUTA, G. A new method to compare the interpretability of rule-based algorithms. *Ai*, v. 2, n. 4, p. 621–635, 2021. Citado 2 vezes na(s) página(s) 27 e 28.

MATTIEV, J.; DAVITYAN, M.; KAVSEK, B. ACMKC: A compact associative classification model using K-Modes clustering with rule representations by Coverage. *Mathematics*, v. 11, n. 18, 2023. ISSN 2227-7390. Citado 2 vezes na(s) página(s) 28 e 34.

MATTIEV, J.; KAVsEK, B. A compact and understandable associative classifier based on overall coverage. *Procedia Computer Science*, Elsevier B.V., v. 170, n. 2019, p. 1161–1167, 2020. ISSN 18770509. Citado na página 34.

MATTIEV, J.; KAVšEK, B. Distance based clustering of class association rules to build a compact, accurate and descriptive classifier. *Comput. Sci. Inf. Syst.*, v. 18, p. 791–811, 2021. Citado na página 34.

MATTIEV, J.; MEZA, C.; KAVSEK, B. The effect of "Directness" of the distance metric to produce compact and accurate associative classification models. *Applied Sciences*, v. 12, n. 18, 2022. Citado na página 28.

MAZOURI, F. Z. E.; ABOUNAIMA, M. C.; ZENKOUAR, K. A selection of useful patterns based on multi-criteria analysis approach. *ACM International Conference Proceeding Series*, p. 1–6, 2017. Citado 5 vezes na(s) página(s) 14, 33, 50, 51 e 72.

MAZOURI, F. Z. E.; ABOUNAIMA, M. C.; ZENKOUAR, K. Data mining combined to the multicriteria decision analysis for the improvement of road safety: case of France. *Journal of Big Data*, Springer International Publishing, v. 6, n. 1, 2019. ISSN 21961115. Citado 4 vezes na(s) página(s) 14, 33, 51 e 72.

MITTAL, K. An approach towards enhancement of classification accuracy rate using efficient pruning methods with associative classifiers. *International Journal of Information Technology*, 05 2021. Citado na página 30.

MOHAMMAD, R. M. A. An improved multi-class classification algorithm based on association classification approach and its application to spam emails. *IAENG International Journal of Computer Science*, v. 47, n. 2, p. 187–198, 2020. ISSN 1819656x. Citado na página 11.

MOLNAR, C. *Interpretable Machine Learning*: A guide for making black box models explainable. 2. ed. [S.l.: s.n.], 2022. Citado na página 27.

MORI, T.; UCHIHIRA, N. Balancing the trade-off between accuracy and interpretability in software defect prediction. *Empirical Software Engineering*, v. 24, n. 2, p. 779–825, Apr 2019. ISSN 1573-7616. Citado na página 12.

NGUYEN, D. *et al.* Efficient mining of class association rules with the itemset constraint. *Knowledge-Based Systems*, v. 103, p. 73–88, 2016. ISSN 0950-7051. Citado na página 30.

NGUYEN, L. T.; NGUYEN, N. T.; TRAWIŃSKI, B. A quick method for querying top-k rules from class association rule set. *Journal of Universal Computer Science*, v. 22, n. 6, p. 822–835, 2016. ISSN 09486968. Citado na página 30.

PADILLO, F.; LUNA, J. M.; VENTURA, S. LAC: Library for associative classification. *Knowledge-Based Systems*, v. 193, 2020. Citado 2 vezes na(s) página(s) 11 e 12.

QUINLAN, J. R.; CAMERON-JONES, R. M. FOIL: A midterm report. In: BRAZDIL, P. B. (Ed.). *Machine Learning: ECML-93*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1993. p. 1–20. ISBN 978-3-540-47597-2. Citado na página 27.

RAJAB, K. D. New associative classification method based on rule pruning for classification of datasets. *IEEE Access*, v. 7, p. 157783–157795, 2019. Citado na página 28.

ROGERS, M.; BRUEN, M.; MAYSTRE, L.-Y. *ELECTRE and Decision Support: Methods and Applications in Engineering and Infrastructure Investment*. Boston, MA: Springer US, 2000. 45–85 p. ISBN 978-1-4757-5057-7. Citado na página 33.

RUDIN, C. *Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead*. [S.l.]: Springer US, 2019. 206–215 p. Citado 4 vezes na(s) página(s) 11, 12, 24 e 27.

SELVARANGAM, K.; KUMAR, K. R. Selecting perfect interestingness measures by coefficient of variation based based ranking algorithm. *Journal of Computer Science*, v. 10, p. 1672–1679, 04 2014. Citado 2 vezes na(s) página(s) x e 19.

SHAO, Y. *et al.* Software defect prediction based on correlation weighted class association rule mining. *Knowledge-based Systems*, v. 196, 2020. ISSN 0950-7051. Citado na página 11.

SHARMA, R. *et al.* Expected vs. Unexpected: Selecting right measures of interestingness. In: SONG, M. *et al.* (Ed.). *Big Data Analytics and Knowledge Discovery - 22nd International Conference, DaWaK 2020, Bratislava, Slovakia, September 14-17, 2020, Proceedings*. [S.l.]: Springer, 2020. (Lecture Notes in Computer Science, v. 12393), p. 38–47. Citado 6 vezes na(s) página(s) 13, 15, 19, 20, 40 e 42.

SHUKLA, P. K.; TRIPATHI, S. P. A review on the interpretability-accuracy trade-off in evolutionary multi-objective fuzzy systems (EMOFS). *Information*, v. 3, n. 3, p. 256–277, 2012. ISSN 2078-2489. Citado na página 12.

SILVA, M. F.; CARVALHO, V. O. Aggregating interestingness measures in associative classifiers. In: *Anais do Encontro Nacional de Inteligência Artificial e Computacional (ENIAC)*. [S.l.: s.n.], 2018. p. 70–81. Citado 10 vezes na(s) página(s) 13, 14, 33, 37, 38, 40, 50, 68, 69 e 72.

SIVANANTHAM, S. *et al.* Rule precision index classifier: an associative classifier with a novel pruning measure for intrusion detection. *Personal and Ubiquitous Computing*, Jul 2021. Citado na página 34.

SOMYANONTHANAKUL, R.; THEERAMUNKONG, T. Scenario-based analysis for discovering relations among interestingness measures. *Information Sciences*, v. 590, p. 346–385, 2022. ISSN 0020-0255. Citado 6 vezes na(s) página(s) 12, 19, 40, 42, 43 e 46.

SOOD, N.; ZAIANE, O. *Building a Competitive Associative Classifier*. [S.l.]: arXiv, 2020. Citado 4 vezes na(s) página(s) 11, 28, 35 e 36.

SPAGNUOLO, N. *Associative classification on spatio-temporal sequences*. Dissertação (Mestrado) — Politecnico di Torino, Corso di laurea magistrale in Ingegneria Informatica (Computer Engineering), 2021. Citado na página 23.

TAN, P. N.; KUMAR, V.; SRIVASTAVA, J. Selecting the right interestingness measure for association patterns. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, n. April 2013, p. 32–41, 2002. Citado na página 22.

TAN, P.-N. *et al. Introduction to Data Mining*. 2. ed. [S.l.: s.n.], 2019. Citado 4 vezes na(s) página(s) 13, 19, 23 e 27.

TAYAL, D. K.; MEENA, K. A new MapReduce solution for associative classification to handle scalability and skewness in vertical data structure. *Future Generation Computer Systems*, v. 103, p. 44–57, 2020. ISSN 0167-739x. Citado na página 24.

TEW, C. *et al.* Behavior-based clustering and analysis of interestingness measures for association rule mining. *Data Mining and Knowledge Discovery*, v. 28, n. 4, p. 1004–1045, 2014. Citado 15 vezes na(s) página(s) x, xiii, 12, 19, 22, 31, 40, 42, 43, 44, 45, 46, 81, 82 e 83.

THABTAH, F. A review of associative classification mining. *Knowledge Engineering Review*, v. 22, n. 1, p. 37–65, 2007. Citado na página 23.

THABTAH, F.; COWLING, P.; PENG, Y. MCAR: multi-class classification based on association rule. In: *The 3rd ACS/IEEE International Conference onComputer Systems and Applications, 2005.* [S.l.: s.n.], 2005. p. 33–. Citado na página 24.

THANAJIRANTHORN, C.; SONGRAM, P. Efficient rule generation for associative classification. *Algorithms*, v. 13, n. 11, nov 2020. Citado na página 23.

TRIANTAPHYLLOU, E. *Multi-criteria Decision Making Methods: A Comparative Study*. Boston, MA: Springer US, 2000. 5–21 p. ISBN 978-1-4757-3157-6. Citado 3 vezes na(s) página(s) 51, 52 e 53.

VAILLANT, B.; LENCA, P.; LALLICH, S. A clustering of interestingness measures. In: SUZUKI, E.; ARIKAWA, S. (Ed.). *Discovery Science*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2004. p. 290–297. ISBN 978-3-540-30214-8. Citado na página 22.

VIGER, P. F.; WU, C.-W.; TSENG, V. Mining top-k association rules. In: . [S.l.: s.n.], 2012. p. 61–73. ISBN 978-3-642-30352-4. Citado na página 30.

WąTRóBSKI, J. *et al.* Generalised framework for multi-criteria method selection. *Omega*, v. 86, p. 107–124, 2019. ISSN 0305-0483. Citado na página 51.

YANG, G.; CUI, X. A study of interestingness measures for associative classification on imbalanced data. In: *Trends and Applications in Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2015. p. 141–151. Citado 5 vezes na(s) página(s) xiii, 42, 43, 45 e 47.

APÊNDICE A – Equações das Medidas Objetivas Selecionadas

Tabela 16: Equações das medidas objetivas utilizadas neste trabalho. Adaptado de Tew *et al.* (2014). A medida marcada com "*" foi ajustada em função do trabalho original.

No.	**Abreviação**	**Equação**
1	ACCRC	$P(AB) + P(\overline{A}\overline{B})$
2	ADD_V	$P(B\|A) - P(B)$
3	CHI_SQ	$\frac{(P(AB) - P(A)P(B))^2 N}{P(A)P(\overline{A})P(B)P(\overline{B})}$
4	CLL_STR	$\frac{P(AB) + P(\overline{A}\overline{B})}{P(A)P(B) + P(\overline{A})P(\overline{B})} \frac{1 - P(A)P(B) - P(\overline{A})P(\overline{B})}{1 - P(AB) - P(\overline{A}\overline{B})}$
5	CP_CL_SP	$\frac{P(A\overline{B})}{P(\overline{B})}$
6	CON_ENT	$-P(B\|A)\log_2 P(B\|A) - P(\overline{B}\|A)\log_2 P(\overline{B}\|A)$
7	CNFD	$P(B\|A)$
8	CN_CA	$\frac{1}{2}(P(B\|A) + P(\overline{A}\|\overline{B}))$
9	CF_CA	$P(AB) + P(\overline{A}\overline{B}) - 2P(A\overline{B})$
10	CF_DES	$P(AB) - P(A\overline{B})$
11	CF_CN_CA	$\frac{1}{2}(P(B\|A) + P(\overline{A}\|\overline{B})) - P(\overline{B}\|A)$
12	CORR_COE	$\frac{P(AB) - P(A)P(B)}{\sqrt{P(A)P(B)P(\overline{A})P(\overline{B})}}$
13	COSI	$\frac{P(AB)}{\sqrt{P(A)P(B)}}$
14	COVER	$P(A)$

Continua na próxima página.

Tabela 16: Equações das medidas objetivas utilizadas neste trabalho. Adaptado de Tew *et al.* (2014). A medida marcada com "*" foi ajustada em função do trabalho original. (Continuação)

15	DIR	$\begin{cases} -\infty & \text{se } P(B) = 1 \\ 0 & \text{se } P(B) \leq \frac{1}{2} \text{ e } P(B\|A) \leq \frac{1}{2} \\ 1 + P(B\|A)\log_2 P(B\|A) + P(\overline{B}\|A)\log_2 P(\overline{B}\|A) & \text{se } P(B) \leq \frac{1}{2} \text{ e } P(B\|A) > \frac{1}{2} \\ 1 + \frac{1}{P(B)\log_2 P(B) + P(\overline{B})\log_2 P(\overline{B})} & \text{se } P(B) > \frac{1}{2} \text{ e } P(B\|A) \leq \frac{1}{2} \\ 1 - \frac{P(B\|A)\log_2 P(B\|A) + P(\overline{B}\|A)\log_2 P(\overline{B}\|A)}{P(B)\log_2 P(B) + P(\overline{B})\log_2 P(\overline{B})} & \text{se } P(B) > \frac{1}{2} \text{ e } P(B\|A) > \frac{1}{2} \end{cases}$
16	FME	$\frac{2P(A\|B)P(B\|A)}{P(A\|B) + P(B\|A)}$
17	GIN_IN	$P(A)\left(P(B\|A)^2 + P(\overline{B}\|A)^2\right) + P(\overline{A})\left(P(B\|\overline{A})^2 + P(\overline{B}\|\overline{A})^2\right) - P(B)^2 - P(\overline{B})^2$
18	GOO_KRU	$\frac{\max\left(P(AB), P(A\overline{B})\right) + \max\left(P(\overline{A}B), P(\overline{A}\overline{B})\right) + \max\left(P(AB), P(\overline{A}B)\right)}{2 - \max(P(A), P(\overline{A})) - \max(P(B), P(\overline{B}))} + \frac{\max\left(P(A\overline{B}, P(\overline{A}\overline{B})\right) - \max(P(A), P(\overline{A})) - \max(P(B), P(\overline{B}))}{2 - \max(P(A), P(\overline{A})) - \max(P(B), P(\overline{B}))}$
19	IMP_IND	$\sqrt{N}\frac{P(A\overline{B}) - P(A)P(\overline{B})}{\sqrt{P(A)P(\overline{B})}}$
20	JME	$P(AB)\log_2 \frac{P(B\|A)}{P(B)} + P(A\overline{B})\log_2 \frac{P(\overline{B}\|A)}{P(\overline{B})}$
21	KAPP	$\frac{P(B\|A)P(A) + P(\overline{B}\|\overline{A})P(\overline{A}) - P(A)P(B) - P(\overline{A})P(\overline{B})}{1 - P(A)P(B) - P(\overline{A})P(\overline{B})}$
22	KLOS	$\sqrt{P(A)}(P(B\|A) - P(B))$
23	KME	$P(B\|A)\log_2 \frac{P(B\|A)}{P(B)} + P(\overline{B}\|\overline{A})\log_2 \frac{P(\overline{B}\|\overline{A})}{P(\overline{B})} - P(B\|A)\log_2 \frac{P(B\|A)}{P(\overline{B})} - P(\overline{B}\|\overline{A})\log_2 \frac{P(\overline{B}\|A)}{P(B)}$
24	KUL2	$\frac{P(AB)}{P(A\overline{B}) + P(\overline{A}B)}$
25	LST_CNT	$\frac{P(AB) - P(A\overline{B})}{P(B)}$
26	LEVER	$P(B\|A) - P(A)P(B)$
27	LIFT	$\frac{P(B\|A)}{P(B)}$

Continua na próxima página.

Tabela 16: Equações das medidas objetivas utilizadas neste trabalho. Adaptado de Tew *et al.* (2014). A medida marcada com "*" foi ajustada em função do trabalho original. (Continuação)

28	LOEV	$1 - \frac{P(A\overline{B})}{P(A)P(\overline{B})}$
29	LOG_NEC	$\frac{P(\overline{A}\|B)}{P(\overline{A}\|\overline{B})}$
30	MU_INF	$P(AB)\log_2\frac{P(AB)}{P(A)P(B)} + P(A\overline{B})\log_2\frac{P(A\overline{B})}{P(A)P(\overline{B})} + P(\overline{A}B)\log_2\frac{P(\overline{A}B)}{P(\overline{A})P(B)}v + P(\overline{AB})\log_2\frac{P(\overline{AB})}{P(\overline{A})P(\overline{B})}$
31	NR_MU_IN	$\frac{MU_INF}{-P(A)\log_2 P(A) - P(\overline{A})\log_2 P(\overline{A})}$
32	ODD_MUL	$\frac{P(AB)P(\overline{B})}{P(B)P(A\overline{B})}$
33	ODD_RAT	$\frac{P(AB)P(\overline{AB})}{P(A\overline{B})P(\overline{A}B)}$
34	ONE_SUP	$P(B\|A)\log_2\frac{P(B\|A)}{P(B)}$
35	PIE_SHA	$N(P(AB) - P(A)P(B))$
36	PREVA	$P(B)$
37	PT_CA_DP	$\frac{1}{2}(P(B\|A) - P(B)) + (P(\overline{A}\|\overline{B}) - P(\overline{A})) - (P(\overline{B}\|A) - P(\overline{B})) - (P(A\|\overline{B}) - P(A))$
38	RECA	$P(A\|B)$
39	REL_RIS	$\frac{P(B\|A)}{P(B\|\overline{A})}$
40	SPECT	$P(\overline{B}\|\overline{A})$
41	SUPP	$P(AB)$
42	THE_UNC	$\frac{MU_INF}{-P(B)\log_2 P(B) - P(\overline{B})\log_2 P(\overline{B})}$
43	TIC*	$\sqrt{DIR(A \Rightarrow B)\, DIR(\overline{B} \Rightarrow \overline{A})}$
44	TW_SUP	$P(AB)\log_2\frac{P(B\|A)}{P(B)}$