Relatório Científico Final
Iniciação Científica

Avaliação de Métodos de MCDA e Agregação de Rankings no Método $AC.Rank_A$

Cauan Gabriel de Souza
cauan.souza@unesp.br
Profa. Dra. Veronica Oliveira de Carvalho (Orientadora)
veronica.carvalho@unesp.br
Unesp/IGCE/DEMAC

Vigência: 01/10/2024 a 30/09/2025

Resumo. Este relatório apresenta um estudo voltado ao aprimoramento do método de ranqueamento $AC.Rank_A$, proposto originalmente por Dall'Agnol and Carvalho (2024), utilizado na indução de classificadores associativos. O trabalho teve como objetivos avaliar (i) o impacto da atribuição de pesos às medidas objetivas (MOs) empregadas nos métodos de decisão multicritério (MCDA), (ii) novos métodos de MCDA além dos *baselines* previamente testados, e (iii) métodos adicionais de agregação de rankings. As análises mostraram que a combinação do grupo de MOs **[GF]**, com o método de ponderação **[SD]** e o método MCDA **[TS]**, produziu modelos com melhor interpretabilidade sem comprometer o desempenho, superando o método original quanto ao primeiro objetivo. Além disso, verificou-se que nenhum outro método MCDA ou de agregação de rankings superou as combinações **[GF][SD][TS]** e **[GF][BL]**, respectivamente. Assim, o estudo confirma a relevância da ponderação de pesos no contexto do $AC.Rank_A$ e reforça a robustez das abordagens de agregação já utilizadas.

Agradecimentos. Agradeço à Unesp, ao IGCE e ao DEMAC pelo suporte institucional; à orientadora Profa. Dra. Veronica Oliveira de Carvalho pela orientação; e aos colegas que contribuíram com dados e discussões. Estendo meus agradecimentos a minha mãe, Silvia, e meu irmão, Allan, pelo apoio e incentivo constantes, e à minha namorada, Nayara, por todo o suporte e compreensão.

Sumário

1 Atividades Previstas **1**

2 Avaliação de Métodos de Atribuição de Pesos em Agregações via MCDA **3**

2.1 Critérios de Seleção dos Métodos de Ponderação Avaliados 3

2.2 Método de Ponderação SD 7

2.3 Configuração Experimental 8

2.4 Resultados e Discussões 10

3 Avaliação de Métodos Adicionais de MCDA **13**

3.1 Critérios de Seleção dos Métodos MCDA Avaliados 14

3.2 Configuração Experimental 15

3.3 Resultados e Discussões 16

4 Avaliação de Métodos Adicionais de Agregação de Rankings **19**

4.1 Critérios de Seleção dos Métodos de Agregação de Rankings Avaliados . . . 19

4.2 Configuração Experimental 22

4.3 Resultados e Discussões 23

5 Conclusão **25**

Referências Bibliográficas **25**

1. Atividades Previstas

Os classificadores associativos (CAs) são modelos compostos por regras de associação classificativas que visam classificar novas instâncias. Uma regra de associação classificativa (RAC) é uma regra do tipo $A \Rightarrow C$ em que a parte antecedente (A) implica em um determinado consequente (C). A contém um conjunto de pares atributo-valor e C contém uma classe de um dado problema. Uma vez que essas regras são facilmente interpretáveis por especialistas, elas podem ser avaliadas para a tomada de decisões com auxílio computacional. Por fim, tal como outras famílias de algoritmos de aprendizado de máquina, esforços têm sido realizados no sentido de popularizar ainda mais a CA por meio da implementação de pacotes, como visto em Hahsler et al. (2019), Padillo et al. (2020), e Azmi and Berrado (2020). O algoritmo que mais se destaca é o CBA (Liu et al., 1998), o qual é usado, em geral, como *baseline* para comparação com novas propostas/soluções.

A maior parte dos algoritmos de CA realizam a indução do modelo em três ou quatro etapas, a saber: [A] Extração, [B] Ranqueamento e/ou Poda e [C] Predição. A maioria dos algoritmos de classificação associativa emprega, em alguma etapa de sua construção, medidas objetivas (MOs), com destaque para o suporte e a confiança. Uma MO avalia a força estatística, ou as características, de um determinado padrão, baseando-se unicamente nos dados (Bong et al., 2014). As MOs podem ser utilizadas com diferentes propósitos, sendo um deles para ordenar, i.e., ranquear as regras pelo seu grau de importância[1]. No contexto dos CAs, em especial, no CBA, essas medidas são utilizadas na etapa [B] referente ao ranqueamento das regras. Essa ordenação influência a próxima etapa, a de poda, na qual as regras que irão compor o classificador são selecionadas. Assim, a ordenação se apresenta como uma etapa de importância no processo.

Tew et al. (2014) realizam um levantamento e apresentam mais de 50 MOs disponíveis na literatura. Assim, mesmo o suporte e a confiança sendo as medidas mais utilizadas para realizar a ordenação das regras nos CAs, nem sempre as mesmas são as melhores para todos os casos. Uma vez que a quantidade de MOs distintas dificulta a escolha do usuário, trabalhos na literatura tentam solucionar este problema realizando a agregação de MOs. A agregação de MOs visa consolidar um conjunto de medidas objetivas em um valor único, de modo a não favorecer ou excluir qualquer medida durante o processo de ordenação.

Em Dall'Agnol and Carvalho (2024)[2] os autores propõem um método de ranqueamento de regras via agregação de MOs, denominado $AC.Rank_A$, a ser incorporado em fluxos de indução de classificadores associativos, visando a obtenção de modelos que apresentam um melhor equilíbrio entre desempenho e interpretabilidade. O método foi avaliado por

[1] Ranqueamento e ordenação são utilizados como sinônimos neste trabalho.

[2] O trabalho é resultado de uma dissertação de mestrado do grupo de pesquisa da orientadora.

meio da comparação de diversos fluxos de indução: aqueles que utilizam o ranqueamento padrão do CBA *(baseline)* e os que utilizam a abordagem proposta pelos autores. Os resultados demonstram que o $AC.Rank_A$ consegue manter o desempenho dos modelos, em comparação aos *baselines* utilizados, porém com uma melhor interpretabilidade. No estudo o desempenho foi medido via F1-Macro e a interpretabilidade pelo tamanho do modelo (número de regras que compõem o modelo). A Figura 1.1 apresenta o fluxo tradicional de um CA com a incorporação do método $AC.Rank_A$ em destaque. Para que o $AC.Rank_A$ funcione, o mesmo deve ser instanciado com um conjunto de MOs e um método de agregação (parâmetros *MOs* e *Met.* da figura). No referido trabalho, os métodos de agregação possíveis são **Borda Mediana** ([**BD**]) (Lin, 2010), **Borda Média** ([**BM**]) (Lin, 2010), **Borda L2** ([**BL**]) Lin (2010), **Borda Geométrica** ([**BG**]) (Lin, 2010), **TOPSIS** ([**TS**]) (Hwang and Yoon, 1981), **WSM** ([**WS**]) (Triantaphyllou, 2000) e **WPM** ([**WP**]) (Triantaphyllou, 2000). Enquanto os quatro primeiros são métodos da área de agregação de rankings, os três últimos pertencem à área de análise de decisão multicritérios (MCDA). Em relação aos conjuntos de MOs, quatro grupos possíveis podem ser selecionados, a saber: [**TW**], [**GF**], [**C1**], [**G1**] e [**G2**]. Nos experimentos, o método de agregação que apresentou o melhor desempenho foi o [**BL**] em conjunto com o grupo de MOs [**GF**]. Com o intuito de aprimorar os resultados obtidos, este trabalho tem como objetivos:

Obj.1: em relação as agregações realizadas via métodos MCDA, avaliar o impacto de métodos de atribuição de pesos a MOs (critérios), tendo em vista que em Dall'Agnol and Carvalho (2024) todas as MOs são tratadas de maneira uniforme, i.e., supõe-se que todas contribuem igualmente na agregação (Seção 2);

Obj.2: ainda em relação as agregações realizadas via métodos MCDA, avaliar o impacto de outros métodos de MCDA, uma vez que apenas três *baselines* foram explorados em Dall'Agnol and Carvalho (2024) (Seção 3), sendo este um objetivo não previsto no plano inicial deste projeto;

Obj.3: em relação as agregações realizadas via métodos de agregação de rankings (Met_{RA}), avaliar o impacto de outros métodos mais recentes de Met_{RA}, uma vez que apenas quatro *baselines* foram explorados em Dall'Agnol and Carvalho (2024) (Seção 4).

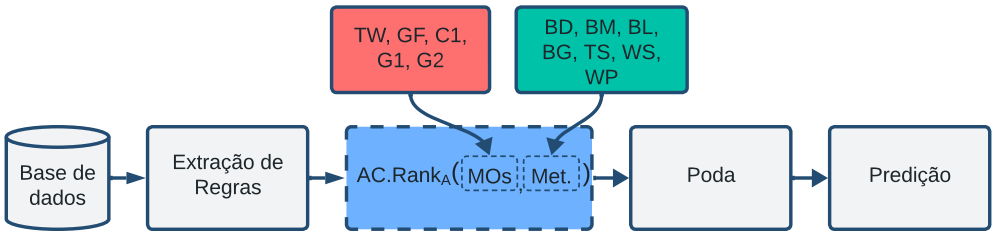


Figura 1.1: Método $AC.Rank_A$ a ser incorporado a fluxos de indução de um CA.

2. Avaliação de Métodos de Atribuição de Pesos em Agregações via MCDA

Como mencionado, um dos objetivos deste trabalho era avaliar o impacto de métodos de atribuição de pesos a MOs (critérios), tendo em vista que em Dall'Agnol and Carvalho (2024) todas as MOs são tratadas de maneira uniforme. Métodos de atribuição de pesos são utilizados visando ponderar critérios em problemas MCDA, determinando a relevância de cada um. No contexto aqui aplicado, i.e., ranquear regras com base em um conjunto simultâneo de MOs, o uso de pesos pode favorecer mais ou menos determinadas MOs e, consequente, melhorar ou piorar os resultados até então obtidos em Dall'Agnol and Carvalho (2024).

De acordo com Ayan et al. (2023), os métodos de ponderação podem ser divididos em três categorias, a saber: subjetivos, objetivos e híbridos. Nos subjetivos utiliza-se do conhecimento do especialista do domínio para se atribuir peso aos critérios. Já nos objetivos utiliza-se de algoritmos matemáticos para a atribuição de pesos. Por fim, os híbridos combinam as duas categorias anteriores. Em função do contexto da aplicação de tais métodos, apenas os objetivos são aqui explorados.

Diante do exposto, essa seção apresenta a metodologia utilizada para avaliar um conjunto de métodos de ponderação selecionados. Para tanto, na Seção 2.1 apresenta-se o processo realizado para seleção dos métodos avaliados. Na Seção 2.3 a configuração experimental. Por fim, na Seção 2.4 discuti-se os resultados obtidos.

2.1. Critérios de Seleção dos Métodos de Ponderação Avaliados

Como mencionado, optou-se pela utilização exclusiva de métodos objetivos, dada sua capacidade de definir pesos de maneira autônoma, i.e., independente de um especialista, já que a solução deve ser aplicada a qualquer conjunto de dados.

Em Ayan et al. (2023) uma análise dos métodos de ponderação mais utilizados na literatura é realizada. Ao final, os autores expõem cinco bibliotecas/pacotes onde tais

métodos encontram-se implementados, sendo três deles em Python. Visando facilitar a integração de tais implementações no projeto de Dall'Agnol and Carvalho (2024), já desenvolvido em Python, apenas as bibliotecas/pacotes em Python foram consideradas, as quais podem ser visualizadas na Tabela 2.1, a saber: PyMCDM, PyDecision e Crispyn.

Tabela 2.1: Bibliotecas selecionados que disponibilizam métodos de ponderação de pesos.

Nome	**Referência**	**GitHub**
Crispyn	Bączkiewicz and Wątróbski (2022)	Crispyn
PyDecision	Pereira et al. (2024)	PyDecision
PyMCDM	Kizielewicz et al. (2023)	PyMCDM

O PyMCDM é uma biblioteca composta por um vasto conjunto de métodos tanto de ponderação quanto de ranqueamento. Os 12 métodos de ponderação disponíveis na biblioteca encontram-se presentes na Tabela 2.2. Já o PyDecision é uma biblioteca que abrange 23 métodos de ponderação, os quais encontram-se presentes na Tabela 2.3. A biblioteca disponibiliza também diversos métodos de ranqueamento, o que o torna uma solução robusta e versátil para diferentes tipos de problemas. Por fim, o Crispyn é uma biblioteca que oferece um conjunto especializado de métodos para ponderação de critérios em problemas de MCDA, contando com 15 deles, os quais encontram-se presentes na Tabela 2.4. As tabelas apresentam tanto o nome dos métodos quanto seus acrônimos - o símbolo "−" indica que não existe acrônimo para determinado método.

Tabela 2.2: Métodos de ponderação disponíveis no PyMCDM. Os selecionados para avaliação são os que encontram-se destacados em verde.

Acrônimo	**Método**
AHP	Analytic Hierarchy Process
-	Angular/Angle weights
CILOS	Criterion Impact LOS
CRITIC	CRiteria Importance Through Intercriteria Correlation
-	Entropy weights
-	Equal/Mean weights
-	Gini Coeficient weights
IDOCRIW	Integrated Determination of Objective CRIteria Weight
MEREC	MEthod based on the Removal Effects of Criteria
RANCOM	RANking COMparison
STD	Standard Deviation weights
-	Statistical variance weights

Tabela 2.3: Métodos de ponderação disponíveis no PyDecision. Os selecionados para avaliação são os que encontram-se destacados em verde.

Acrônimo	**Método**
AHP	Analytic Hierarchy Process
BWM	Best-Worst Method
CILOS	Criterion Impact LOSs
CRITIC	CRiteria Importance Through Intercriteria Correlation
DEMATEL	Decision Making Trial and Evaluation Laboratory
-	Entropy
FUCOM	Full Consistency Method
-	Fuzzy AHP
-	Fuzzy BWM
-	Fuzzy CRITIC
-	Fuzzy DEMATEL
-	Fuzzy FUCOM
-	Fuzzy MEREC
IDOCRIW	Integrated Determination of Objective CRIteria Weights
MEREC	MEthod based on the Removal Effects of Criteria
MPSI	Modified Preference Selection Index
-	PPF AHP (Proportional Picture Fuzzy AHP)
ROC	Rank-Ordered Centroid
RRW	Rank-Reciprocal Weighting
RSW	Rank-Sum Weighting
SECA	Simultaneous Evaluation of Criteria and Alternatives
-	Simplified BWM
WINGS	Weighted Influence Non-linear Gauge System

Tabela 2.4: Métodos de ponderação disponíveis no Crispyn. Os selecionados para avaliação são os que encontram-se destacados em verde.

Acrônimo	**Método**
AHP	Analytic Hierarchy Process
-	Angular/Angle weights
CILOS	Criterion Impact LOS
-	Coeffcient of variation weighting
CRITIC	CRiteria Importance Through Intercriteria Correlation
-	Entropy weights
-	Equal/Mean weights
-	Gini Coeficient weights
IDOCRIW	Integrated Determination of Objective CRIteria Weight
LBWA	LBWA weighting
MEREC	MEthod based on the Removal Effects of Criteria
SAPEVO	SAPEVO weighting
STD	Standard Deviation weights
-	Statistical variance weights
SWARA	SWARA weighting

Assim, inicialmente, 50 métodos foram pré-selecionados (12 + 23 + 15). Na sequência, os mesmos foram avaliados a fim de selecionar, de fato, os pertinentes a este trabalho, os quais encontram-se destacados em verde nas Tabelas 2.2, 2.3 e 2.4. Os critérios adotados para se desconsiderar (excluir) alguns dos métodos de ponderação foram os seguintes:

- métodos subjetivos, os quais encontram-se destacados em azul, pois como mencionado não atendem ao propósito do trabalho;
- métodos fuzzy, os quais encontram-se destacados em roxo, pois tais métodos não se aplicam para dados de valores numéricos exatos e bem definidos;
- métodos em mais de uma biblioteca, os quais encontram-se destacados em cinza, foram mantidos em apenas uma delas. No entanto, métodos "iguais" que produziam resultados distintos, ainda que com diferenças sutis, foram mantidos para análise;
- métodos que atendiam a todos os requisitos, mas que por determinadas particularidades não puderam ser considerados, também foram desconsiderados, os quais encontram-se destacados em amarelo.

  O Equal foi desconsiderado por atribuir peso de maneira uniforme, abordagem já tratada no trabalho de Dall'Agnol and Carvalho (2024). O CILOS foi desconsiderado devido a uma inadequação estrutural à proposta do projeto. O método não foi projetado para extrair um peso para cada MO, e sim para realizar uma análise das relações entre um conjunto fechado de critérios. O IDOCRIW nas bibliotecas Crispyn e PyMCDM não foi selecionado uma vez que utiliza internamente o método CILOS. Já no PyDecision o método é implementado sem acessar o método CILOS, sendo mantido no trabalho. Por fim, o coefficient of variation foi desconsiderado uma vez que produz o mesmo valor do método standard deviation (SD); porém, enquanto o coefficient of variation normaliza a matriz de entrada, o standard deviation não. Assim, o SD foi mantido por não ser redundante com os dados já normalizados previamente (a matriz de entrada já é fornecida normalizada).

Após aplicação dos critérios acima, 13 métodos foram de fato avaliados, sendo 7 do PyMCDM, 4 do PyDecision e 2 do Crispyn, os quais encontram-se destacados em verde nas Tabelas 2.2, 2.3 e 2.4. Para melhor visualização, os métodos selecionados são apresentados na Tabela 2.5, juntamente com as siglas utilizadas para referenciar tais métodos daqui em diante. Os métodos com siglas **AW** (Angle), **CR** (Critic) e **SV** (Statistical Variance), são métodos que estão disponíveis em mais de um pacote. Assim, prefixos foram adotados para cada método com o intuito de diferenciá-los: o prefixo [**PM-**] indica um método do pacote PyMCDM, o [**PD-**] um método do pacote PyDecision, e o prefixo [**CP-**] um método do pacote Crispyn.

Tabela 2.5: Métodos de ponderação avaliados com suas respectivas siglas.

Sigla	Nome
PM-AW	PyMCDM - Angular/Angle weights
CP-AW	Crispyn - Angular/Angle weights
PM-CR	PyMCDM - CRITIC (CRiteria Importance Through Intercriteria Correlation)
PD-CR	PyDecision - CRITIC (CRiteria Importance Through Intercriteria Correlation)
PM-EW	PyMCDM - Entropy weights
PM-GW	PyMCDM - Gini Coeficient weights
PD-ID	PyDecision - IDOCRIW (Integrated Determination of Objective CRIteria Weights)
PD-MP	PyDecision - MPSI (Modified Preference Selection Index)
PM-MR	PyMCDM - MEREC (MEthod based on the Removal Effects of Criteria)
PM-SD	PyMCDM - STD (Standard Deviation weights)
PD-SE	PyDecision - SECA (Simultaneous Evaluation of Criteria and Alternatives)
PM-SV	PyMCDM - Statistical variance weights
CP-SV	Crispyn - Statistical variance weights

Como será visto na Seção 2.4, o método de ponderação que apresentou melhores resultados, melhorando inclusive os resultados obtidos no trabalho de Dall'Agnol and Carvalho (2024), foi o método standard deviation (SD), e, portanto, será descrito a seguir.

2.2. Método de Ponderação SD

O método standard deviation (SD) encontra-se apresentado no Algoritmo 1. Note que o mesmo recebe como entrada uma matriz de alternativas por critérios. Neste trabalho, assim como em Dall'Agnol and Carvalho (2024), as linhas da matriz representam as regras e as colunas as MOs. Logo, a saída será um vetor de pesos, em que cada posição está associada ao peso definido para cada uma das MOs.

Algoritmo 1 Pseudocódigo do método de ponderação SD tendo como base a implementação disponível no Crispyn.

Entrada: Uma matriz D de m alternativas e n critérios
Saída: Um vetor w de pesos associados aos critérios
1: stdv ← desvio padrão dos n critérios da matriz M
2: soma_stdv ← soma dos n valores de *stdv*
3: pesos ← *stdv* / *soma_stdv*
4: **retorne** *pesos*

A lógica do algoritmo é relativamente simples: recebe como entrada uma matriz com linhas que representam as alternativas e colunas que representam os critérios. Ele calcula o desvio padrão de cada critério (colunas) e, ao final, o normaliza dividindo pela soma de todos os desvios. Ao final, o método retorna os pesos normalizados para serem utilizados pelos métodos de MCDA. Para ilustrar o procedimento de cálculo deste método, considere o exemplo a seguir.

Exemplo. Seja D uma matriz onde cada linha i representa uma alternativa e cada

coluna j um critério. Considere D a matrix abaixo apresentada.

$$D = \begin{pmatrix} 1 & 10 & 100 \\ 2 & 20 & 105 \\ 3 & 30 & 95 \end{pmatrix}$$

Para cada coluna j, calcula-se o desvio padrão amostral (σ_j), dado por:

$$\sigma_j = \sqrt{\frac{1}{m-1}\sum_{i=1}^{m}(D_{ij} - \bar{M}_j)^2}$$

Assim, tem-se o seguinte para cada um dos critérios:

Critério 1: $\sigma_1 = \sqrt{\frac{(1-2)^2+(2-2)^2+(3-2)^2}{3-1}} = \sqrt{\frac{1+0+1}{2}} = \sqrt{1} = 1$

Critério 2: $\sigma_2 = \sqrt{\frac{(10-20)^2+(20-20)^2+(30-20)^2}{3-1}} = \sqrt{\frac{100+0+100}{2}} = \sqrt{100} = 10$

Critério 3: $\sigma_3 = \sqrt{\frac{(100-100)^2+(105-100)^2+(95-100)^2}{3-1}} = \sqrt{\frac{0+25+25}{2}} = \sqrt{25} = 5$

Os valores obtidos são armazenados em um vetor v : $v = \begin{pmatrix} 1 & 10 & 5 \end{pmatrix}$. Na sequência, realiza-se a soma dos desvios armazenados no vetor v. Tem-se $S = 1 + 10 + 5 = 16$. Calcula-se então os pesos de cada critério $w_j = \sigma_j / S$, inserindo-os no vetor de pesos w. Tem-se $w_1 = 1/16 = 0.0625$; $w_2 = 10/16 = 0.6250$; $w_3 = 5/16 = 0.3125$. Dessa maneira, obtém-se o vetor de pesos final, o qual representa a importância de cada critério com base na sua variabilidade. Nesta caso, $w = \begin{pmatrix} 0.0625 & 0.6250 & 0.3125 \end{pmatrix}$.

2.3. Configuração Experimental

Como visto na Seção 2.1, 13 métodos de ponderação foram selecionados para avaliação. Os métodos foram executados utilizando-se os seus valores *default*. A Figura 2.1 apresenta como os métodos foram integrados ao *pipeline* original, i.e., ao $AC.Rank_A$. A diferença em relação ao $AC.Rank_A$ é justamente a incorporação da ponderação na etapa de ranqueamento (destacada em cinza).

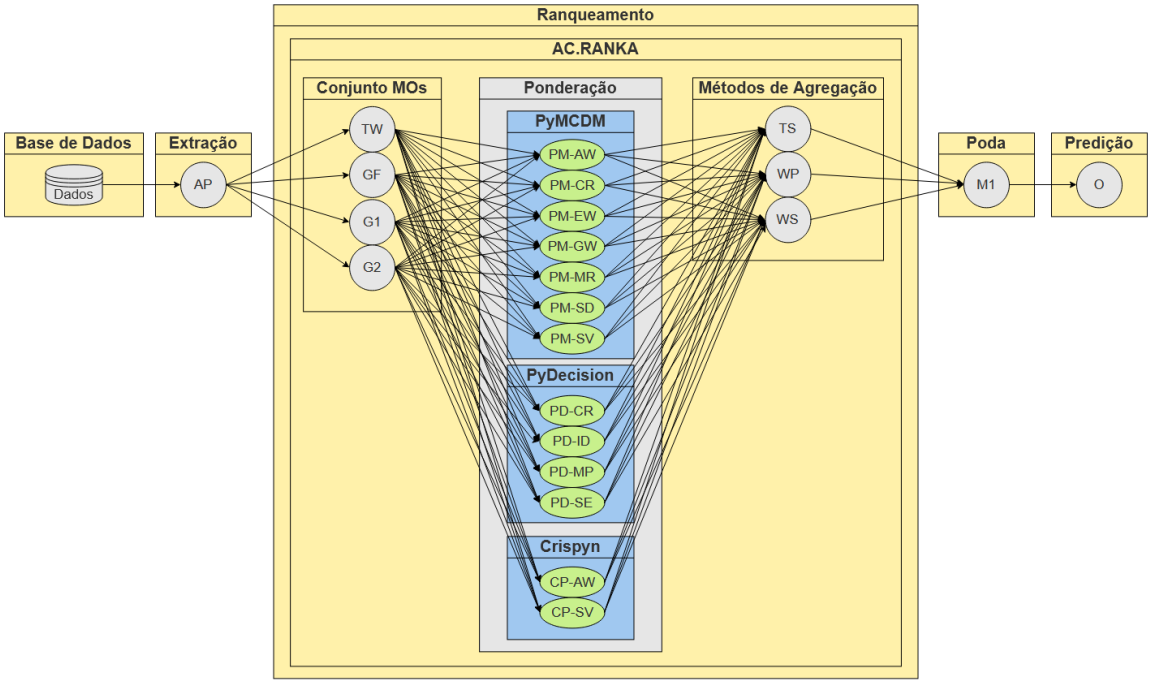


Figura 2.1: Métodos de ponderação incorporados ao pipeline do $AC.Rank_A$.

Assim como em Dall'Agnol and Carvalho (2024), para que o *pipeline* seja executado é necessário que se defina os conjuntos de dados a serem utilizados, assim como os métodos de extração de regras, poda e predição. Visando garantir compatibilidade com o trabalho de Dall'Agnol and Carvalho (2024), as mesmas escolhas foram feitas, i.e., utilizou-se os mesmos 43 conjuntos de dados por eles considerados, assim como o *Apriori* para extração de regras, e os mesmos mecanismos de poda e predição do CBA. Para maiores detalhes vide Dall'Agnol and Carvalho (2024).

Já a etapa de ranqueamento, como já visto na Figura 2.1, se refere justamente a adaptada neste trabalho. Diferentemente de Dall'Agnol and Carvalho (2024), apenas os grupos de MOs [**TW**], [**GF**], [**G1**] e [**G2**] foram utilizados. O grupo [**C1**] não foi considerado, pois trata-se de uma composição dos grupos [**G1**] e [**G2**]. Vale mencionar mais uma vez que são as MOs pertences a esses grupos que irão receber os pesos computados por um dos 13 métodos de ponderação avaliados. Em relação aos métodos de MCDA utilizados, utilizou-se os mesmos explorados por Dall'Agnol and Carvalho (2024), i.e., [**TS**], [**WP**] e [**WS**]. Assim, ao todo, 156 combinações foram avaliadas: 4 grupos de MOs x 3 métodos de MCDA x 13 métodos de ponderação (os apresentados na Tabela 2.5).

Assim como em Dall'Agnol and Carvalho (2024), para avaliar os modelos gerados utilizou-se como medida de desempenho a F1-Macro estimada via 10-fold cross-validation estratificado. Como medida de interpretabilidade utilizou-se a medida tamanho do modelo (*length*), número de regras que o compõem, também estimada via 10-fold cross-validation estratificado. O objetivo é manter o equilíbrio (*trade-off*) entre ambas as medidas. Para

comparação das combinações com o $AC.Rank_A$, utilizou-se o teste de Friedman com $\alpha = 0,05$, assim como o teste post-hoc de Nemenyi em conjunto com os gráficos de diferença crítica (CD).

2.4. Resultados e Discussões

Os resultados foram organizados e analisados de modo a verificar o impacto dos métodos de ponderação no *pipeline* do $AC.Rank_A$. Para tanto, os resultados obtidos foram comparados ao $AC.Rank_A$ (*baseline*). Como já mencionado, 156 combinações foram executadas em cada um dos 43 conjuntos de dados. Além disso, que cada combinação é avaliada por meio de meio de dois critérios, i.e., desempenho (F1-Macro (F1)) e interpretabilidade (tamanho do modelo (L)). A fim de melhor compreender como a análise foi realizada, considere as Figuras 2.2 e 2.3. Para todos os métodos de ponderação selecionados em cada uma das combinações de grupo de MOs e métodos MCDA, i.e., [**MO**][**Met. MCDA**], aplicou-se o teste de Friedman a fim de verificar a existência ou não de diferença estatística significativa entre o modelo gerado pela combinação em análise e o $AC.Rank_A$. Caso uma diferença fosse detectada, o teste post-hoc de Nemenyi era utilizado e os gráficos de diferença crítica gerados, como os apresentados nas figuras. Deste modo, ao todo, foram executados 24 testes (4 grupos de MOs x 3 métodos MCDA x 2 critérios de avaliação). Na Figura 2.2 apresenta-se o gráfico CD entre os métodos de ponderação combinados com [**GF**][**TS**] e o $AC.Rank_A$ em relação ao desempenho (F1-Macro) e na Figura 2.3 em relação a interpretabilidade (tamanho do modelo). Nota-se que em termos de desempenho, não há diferença entre o $AC.Rank_A$ e os métodos de ponderação; contudo, em relação a interpretabilidade, nota-se que existe diferença significativa em relação ao $AC.Rank_A$, apresentando, no caso dos métodos [**PM-SD**], [**PM-GW**], [**PM-AW**] e [**CP-AW**], um melhor resultado. Assim, ao se analisar simultaneamente os dois gráficos, nota-se que os métodos mencionados são aqueles que melhor se adéquam a contextos onde se visa um bom desempenho com uma boa interpretabilidade (*trade-off*).

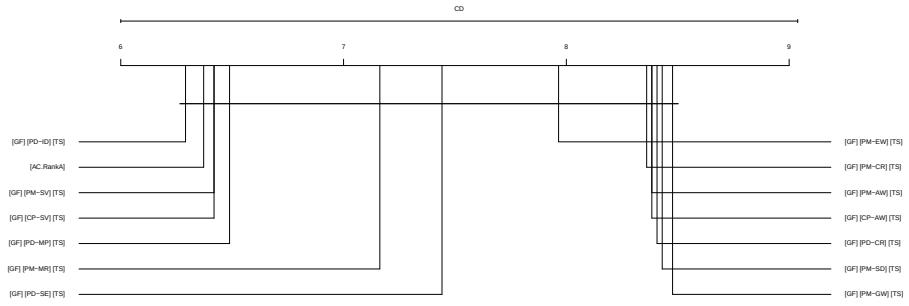


Figura 2.2: Gráfico de diferença crítica resultante da comparação entre os métodos de ponderação, agrupados pelo grupo de MOs [**GF**] e o método MCDA [**TS**], e o $AC.Rank_A$ na medida F1-Macro.

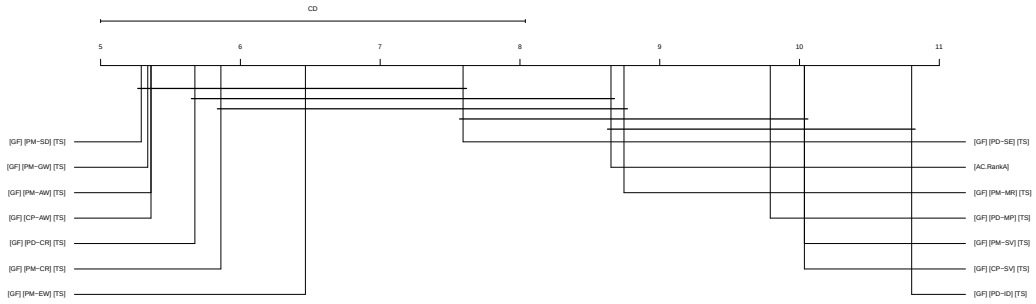


Figura 2.3: Gráfico de diferença crítica resultante da comparação entre os métodos de ponderação, agrupados pelo grupo de MOs [**GF**] e o método MCDA [**TS**], e o $AC.Rank_A$ na medida tamanho do modelo.

Devido ao alto volume de testes/gráficos (24)[1], a fim de facilitar a análise a Tabela 2.6 foi gerada da seguinte maneira: comparou-se cada um dos 13 métodos de ponderação, combinados com cada um dos grupos de MOs e com cada um dos métodos MCDA, em relação ao $AC.Rank_A$ e verificou-se se a configuração apresentava diferença ou não em relação a ele. Caso apresentasse, se a diferença era favorável a combinação ou não. Assim, cores foram geradas para as seguintes possibilidades:

- verde: células em que há diferença estatística positiva em pelo menos um dos critérios para a combinação em análise, desde que o outro não apresente diferença ((≡ e ▲) e (▲ e ≡)). Essa é uma condição desejável, já que indica um resultado favorável ao ranqueamento aqui explorado, uma vez que melhora um dos critérios, enquanto o outro se mantém, garantindo um equilíbrio entre os dois;

- vermelho: células em que há diferença estatística negativa em pelo menos um dos critérios para a combinação em análise, desde que o outro não apresente diferença ((≡ e ▼) e (▼ e ≡)). Essa é uma condição não desejável, já que indica um resultado desfavorável ao ranqueamento aqui explorado, uma vez que piora um dos critérios, enquanto o outro se mantém;

- amarelo: células em que não há diferença estatística entre a combinação em análise e o $AC.Rank_A$ (≡ e ≡). Essa é uma condição não desejável, já que indica que a proposta aqui apresentada não avançou nos resultados até então obtidos;

- azul: demais casos, aqueles que representam comportamentos inversamente proporcionais ((▲ e ▼), (▼ e ▲)). Essa é uma condição não desejável, já que indica que não houve um bom equilíbrio (*trade-off*) entre os dois critérios de análise considerados.

Nota-se em relação aos métodos [**PM-SD**], [**PM-GW**], [**PM-AW**] e [**CP-AW**] que integram o exemplo apresentado nas Figuras 2.2 e 2.3 que a mesma recai sobre a cor verde, i.e., na condição (≡ e ▲) - mantém F1-Macro e melhora tamanho do modelo.

[1]Os gráficos de CD de todas as análises encontram-se disponíveis em `https://bit.ly/4htaSCQ`.

Tabela 2.6: Comparação das combinações de grupo de MOs e métodos MCDA em relação ao $AC.Rank_A$ considerando cada um dos 13 métodos de ponderação selecionados.

MOs	Met. MCDA	PM-AW		PM-CR		PM-EW		PM-GW		PM-MR		PM-SD		PM-SV		PD-CR		PD-ID		PD-MP		PD-SE		CP-AW		CP-SV	
		F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L
GF	TS	≡	▲	≡	≡	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▲	≡	≡
	WS	≡	▲	≡	▲	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	▲	≡	≡	≡	≡	≡	≡	≡	▲	≡	≡
	WP	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
TW	TS	▼	▲	▼	▲	▼	▲	▼	▲	▼	≡	▼	▲	▼	≡	▼	▲	▼	≡	▼	≡	≡	≡	▼	▲	▼	≡
	WS	▼	▲	▼	▲	▼	▲	▼	▼	≡	≡	▼	▲	▼	≡	▼	▼	≡	≡	▼	≡	≡	≡	▼	▲	▼	≡
	WP	▼	▲	▼	▲	▼	▲	▼	▼	≡	≡	▼	▲	▼	≡	▼	▲	▼	≡	▼	≡	≡	≡	▼	▲	▼	≡
G1	TS	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡
	WS	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	≡
	WP	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	≡
G2	TS	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	≡	≡	≡	≡	▼
	WS	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	▼	≡	≡	≡	≡	≡	▼
	WP	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	≡	≡	≡	≡	▼

Observando-se os resultados da Tabela 2.6 nota-se que algumas combinações se destacaram, i.e., que alguns métodos de ponderação de fato tiveram impacto positivo, os quais encontram-se destacados em negrito (especificamente os associados as células em verde), a saber: **[PM-AW]**, **[PM-CR]**, **[PM-GW]**, **[PM-SD]**, **[PD-CR]**, **[CP-AW]**. É notável uma clara distinção entre a utilização de tais métodos de ponderação em conjunto com o grupo de MOs **[GF]**. O uso de tais métodos de ponderação com os grupos de MOs **[G1]**, **[G2]** e **[TW]** não apresentaram resultados satisfatórios.

Tendo como referência então o grupo de MOs **[GF]**, realizou-se a escolha do método de ponderação mais adequado. Para tanto, utilizou-se como base o rank médio de cada um em relação ao critério tamanho do modelo, conforme pode ser visto na Tabela 2.7, já que em relação ao desempenho não observou-se diferença estatística. Nota-se na Tabela 2.7 que o método de ponderação que se destaca é o **[PM-SD]** quando usado com o método **[TS]**, i.e., a combinação **[GF][PM-SD][GF]** é a escolhida.

Tabela 2.7: Análise comparativa dos métodos de ponderação que se destacaram no grupo de MOs **[GF]** de acordo com o critério tamanho do modelo.

Met. Ponderação	Met. MCDA	Rank Médio
[PM-AW]	[TS]	7,61628
	[WS]	10,58140
	[WP]	12,75581
[PM-CR]	[TS]	10,43023
	[WS]	11,16279
	[WP]	12,82558
[PM-GW]	[TS]	7,59302
	[WS]	10,60465
	[WP]	12,63953
[PM-SD]	**[TS]**	**7,54651**
	[WS]	10,67442
	[WP]	12,68605
[PD-CR]	[TS]	10,17442
	[WS]	10,73256
	[WP]	12,94186
[CP-AW]	[TS]	7,61628
	[WS]	10,58140
	[WP]	12,75581

Por fim, nota-se que a combinação **[GF][PM-SD][GF]** supera o $AC.Rank_A$ em termos de interpretabilidade, enquanto mantém o desempenho em relação a este *baseline*. Assim, pode-se dizer que a incorporação do método de ponderação **[PM-SD]**, quando incorporado ao *pipeline* do $AC.Rank_A$, de fato melhora os resultados até então obtidos.

3. Avaliação de Métodos Adicionais de MCDA

Como mencionado, um dos objetivos deste trabalho era avaliar o impacto de outros métodos de MCDA, tendo em vista que em Dall'Agnol and Carvalho (2024) apenas três *baselines* foram explorados, a saber: **[TS]**, **[WS]** e **[WP]**. Diante do exposto, essa seção

apresenta a metodologia utilizada para avaliar um conjunto de métodos MCDA selecionados. Para tanto, na Seção 3.1 apresenta-se o processo realizado para seleção dos métodos avaliados. Na Seção 3.2 a configuração experimental. Por fim, na Seção 3.3 discuti-se os resultados obtidos.

3.1. Critérios de Seleção dos Métodos MCDA Avaliados

O critério para busca inicial foi a identificação de bibliotecas desenvolvidos em Python que disponibilizassem métodos MCDA adicionais aos *baselines* já explorados por Dall'Agnol and Carvalho (2024). Dentre elas a biblioteca pyDecision[1] foi selecionada. A biblioteca disponibiliza 70 métodos MCDA (Pereira et al., 2025). Devido ao elevado número de métodos disponíveis, uma ferramenta[2] desenvolvida por Wątróbski et al. (2019) foi utilizada para apoiar a identificação de métodos adequados ao problema aqui tratado. Utilizou-se como configuração de busca na ferramenta métodos que não trabalham com incerteza e que trabalham com ranqueamento (os demais critérios de busca foram deixados em aberto). Os métodos identificados ao realizar tal busca encontram-se disponíveis na Tabela 3.1. Vale mencionar que apenas métodos individuais foram considerados, i.e., métodos combinados foram descartados.

Tabela 3.1: Métodos de MCDA identificados pela ferramenta de Wątróbski et al. (2019).

Sigla			
AHP	ANP	DEMATEL	ELECTRE II
EVAMIX	IDRA	MACBETH	MAPPAC
MAUT	MAVT	PACMAN	PRAGMA
QUALIFLEX	REGIME	REMBRANDT	SAW
SMART	TOPSIS	UTA	VIKOR

Após identificar os 20 métodos listados na Tabela 3.1, verificou-se qual deles encontravam-se disponíveis na biblioteca pyDecision. Os mesmos encontram-se apresentados na Tabela 3.2. Assim como na Seção 2, a tabela foi destacada em cores. Os métodos MCDA selecionados para avaliação encontram-se destacados em verde. Os critérios adotados para se desconsiderar (excluir) os demais métodos foram os seguintes:

- métodos que são mais relacionados a tarefa de ponderação de critérios, os quais encontram-se destacados em amarelo;
- métodos que necessitam da definição de hiperparâmetros direcionados especificamente para o problema. O $AC.Rank_A$ foi proposto para ser utilizado independente do domínio, i.e., de maneira a não depender de um especialista do domínio. Tais métodos encontram-se destacados em roxo;

[1] `https://github.com/Valdecy/pyDecision/`.
[2] `https://mcda.it/`.

- métodos que por determinadas particularidades não puderam ser considerados encontram-se destacados em cinza. O VIKOR possui saídas que variam de acordo com os dados, não sendo aplicável no fluxo deste trabalho, o qual espera uma saída em um formato específico. O Topsis (TS) já havia sido avaliado. Por fim, o REGIME é computacionalmente custoso, sendo inviável para aplicação em alguns conjuntos de dados.

Tabela 3.2: Métodos de MCDA disponíveis no pyDecision. Os selecionados para avaliação são os que encontram-se destacados em verde.

Sigla	
AHP	DEMATEL
ELECTRE II	MACBETH
MAUT	REGIME
SAW	SMART
TOPSIS	VIKOR

3.2. Configuração Experimental

A configuração experimental adotada nesta seção é análoga àquela descrita na Seção 2.3, desde o conjunto de dados até a maneira como a avaliação foi realizada. A diferença encontra-se na configuração do *pipeline* utilizado, como visto na Figura 3.1. As alterações encontram-se destacadas na cor vermelha, especificamente dentro da "caixa" métodos de agregação. Anteriormente, na Figura 2.1, os métodos MCA utilizados foram [**TS**], [**WP**] e [**WS**]. Aqui, manteve-se o [**TS**], uma vez que foi o que demonstrou o melhor desempenho na Seção 2.4, e adicionou-se os dois métodos adicionais selecionados.

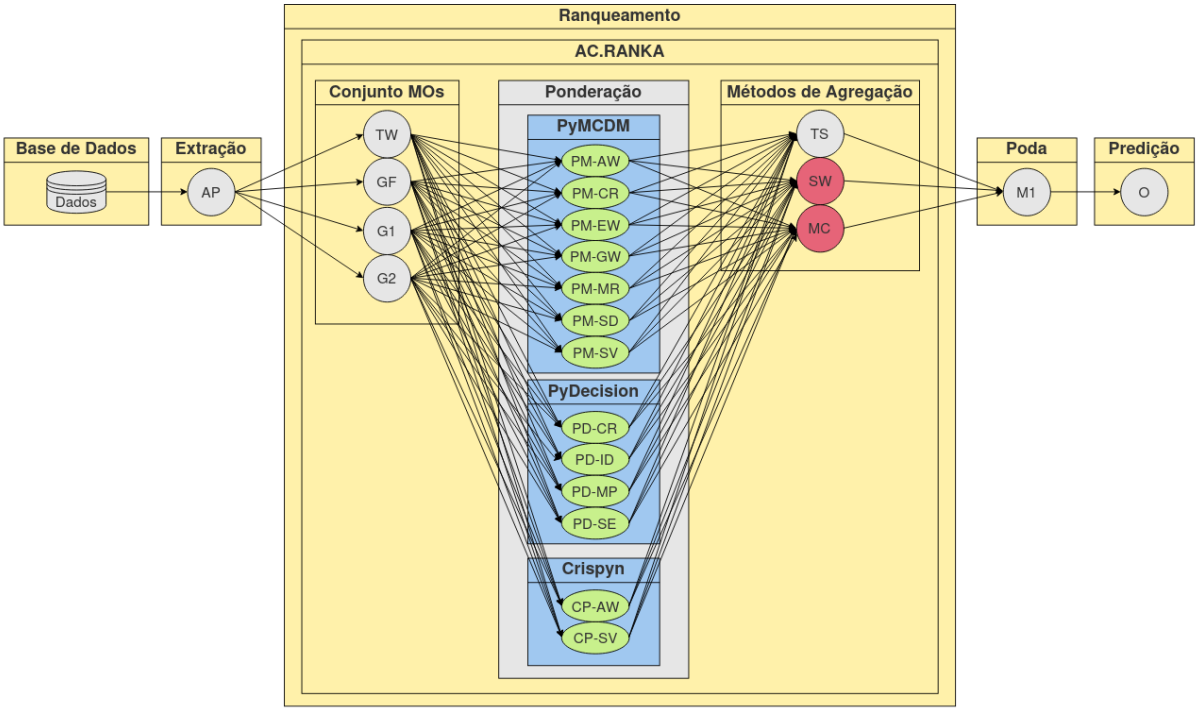


Figura 3.1: Métodos adicionais de MCDA incorporados ao pipeline já modificado do $AC.Rank_A$ (vide Figura 2.1).

3.3. Resultados e Discussões

Os resultados foram organizados e analisados de modo a verificar o impacto dos métodos de MCDA adicionais ao *pipeline* do $AC.Rank_A$ ponderado (resultados da seção anterior). Como já mencionado, 156 combinações foram executadas em cada um dos 43 conjuntos de dados. Além disso, que cada combinação é avaliada por meio de dois critérios, i.e., desempenho (F1-Macro (F1)) e interpretabilidade (tamanho do modelo (L)). Deste modo, a análise foi aqui realizada de maneira similar a descrita na Seção 2.4, i.e., para todos os métodos de ponderação selecionados em cada uma das combinações de grupo de MOs e métodos MCDA adicionais, i.e., **[MO][Met. MCDA]**, aplicou-se o teste de Friedman a fim de verificar a existência ou não de diferença estatística significativa entre o modelo gerado pela combinação em análise e o $AC.Rank_A$ ponderado (Seção 2.4), i.e., em relação a configuração **[GF][PM-SD][GF]**, já que foi a que apresentou melhores resultados em relação ao $AC.Rank_A$ sem ponderação. Caso uma diferença fosse detectada, o teste post-hoc de Nemenyi era utilizado e os gráficos de diferença crítica gerados. Deste modo, ao todo, foram executados 16 testes (4 grupos de MOs x 2 métodos MCDA adicionais x 2 critérios de avaliação). Ademais, assim como na Seção 2.4, devido ao alto volume de testes/gráficos (16), a fim de facilitar a análise a Tabela 3.3 foi gerada como a Tabela 2.6, i.e., comparou-se cada um dos 13 métodos de ponderação, combinados com cada um dos grupos de MOs e com cada um dos métodos MCDA adicionais, em relação ao $AC.Rank_A$ ponderado e verificou-se se a configuração apresentava diferença ou não em

relação a ele. É possível observar (Tabela 3.3) que nenhuma das combinações aqui exploradas superou a anteriormente adotada, i.e., [**GF**][**PM-SD**][**TS**]. Em outras palavras, o método [**TS**] se mostrou o mais adequado dentre os métodos MCDA explorados.

Tabela 3.3: Comparação das combinações de grupo de MOs e métodos MCDA adicionais em relação a combinação [**GF**][**PM-SD**][**GF**] considerando cada um dos 13 métodos de ponderação selecionados.

MOs	Met. MCDA	PM-AW		PM-CR		PM-EW		PM-GW		PM-MR		PM-SD		PM-SV		PD-CR		PD-ID		PD-MP		PD-SE		CP-AW		CP-SV	
		F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L
GF	Macbath	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼
	Saw	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲
TW	Macbath	≡	≡	▼	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	▲	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡
	Saw	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲
G1	Macbath	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡	≡
	Saw	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲
G2	Macbath	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	≡	≡	▼
	Saw	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲	▼	▲

4. Avaliação de Métodos Adicionais de Agregação de Rankings

Como mencionado, um dos objetivos deste trabalho era avaliar o impacto de outros métodos de agregação de rankings, tendo em vista que em Dall'Agnol and Carvalho (2024) apenas quatro *baselines* foram explorados, a saber: [**BD**], [**BM**], [**BL**] e [**BG**]. Diante do exposto, essa seção apresenta a metodologia utilizada para avaliar um conjunto de métodos de agregação de rankings selecionados. Para tanto, na Seção 4.1 apresenta-se o processo realizado para seleção dos métodos avaliados. Na Seção 4.2 a configuração experimental. Por fim, na Seção 4.3 discuti-se os resultados obtidos.

4.1. Critérios de Seleção dos Métodos de Agregação de Rankings Avaliados

Assim como na Seção 3.1, a seleção dos métodos partiu da análise de pacotes recentes desenvolvidos em Python, visando facilitar a integração com a estrutura do projeto já existente. Inicialmente foram selecionados 3 pacotes que continham métodos que atendiam ao requisito de não conter apenas métodos *baselines*, os quais encontram-se apresentados na Tabela 4.1.

Tabela 4.1: Pacotes em Python identificados para seleção de métodos de agregação de rankings.

Pacote	**GitHub**
PyFLAGR	PyFLAGR
RankAggregation-Lib	RankAggregation-Lib
pyRankMCDA	pyRankMCDA

O PyFLAGR é uma biblioteca que oferece um conjunto robusto de métodos de agregação de rankings. Ele se destaca por implementar tanto abordagens clássicas quanto baseadas em Cadeias de Markov. Os 17 métodos pré-selecionados encontram-se disponíveis na Tabela 4.2. Já o RankAggregation-Lib é bastante completo e abrange diversas famílias de algoritmos de agregação de rankings. Dentre seus métodos, 18 foram pré-selecionados para este estudo, conforme Tabela 4.3. Por fim, o pyRankMCDA é um biblioteca focada na implementação de algoritmos de agregação de rankings no contexto de análises multicritério. Um total de 11 métodos foram inicialmente pré-selecionados, conforme Tabela 4.4. Assim, inicialmente, 46 métodos foram pré-selecionados (17 + 18 + 11). Na sequência, os mesmos foram avaliados a fim de selecionar, de fato, os pertinentes a este trabalho, os quais encontram-se destacados em verde nas Tabelas 4.2, 4.3 e 4.4. Os critérios adotados para se desconsiderar (excluir) alguns dos métodos de ponderação foram os seguintes:

- métodos similares aos *baselines*, os quais encontram-se destacados em azul, que por sua simplicidade ou semelhança foram desconsiderados;
- métodos com alto custo computacional, os quais encontram-se destacados em roxo, cuja execução se mostrou inviável;
- métodos em mais de uma biblioteca, os quais encontram-se destacados em cinza, foram mantidos em apenas uma delas. No entanto, métodos "iguais" que produziam resultados distintos, ainda que com diferenças sutis, foram mantidos para análise;
- métodos que por determinadas particularidades não puderam ser considerados, também foram desconsiderados, os quais encontram-se destacados em amarelo.

  Tanto o Median quanto o Mean foram desconsiderados em virtude do formato de entrada não ser o mesmo utilizado no restante do projeto. Já o Plackett-Luce Model trabalha apenas com valores de rankings inteiros, não se adequando aos dados de entrada utilizados neste trabalho.

Tabela 4.2: Métodos de agregação de rankings pré-selecionados no PyFLAGR. Os selecionados para avaliação são os que encontram-se destacados em verde.

Acrônimo	**Método**
CombSUM	Combined Sum
BordaCount	Borda Count
SimpleBordaCount	Simple Borda Count
CombMNZ	Combined MNZ
CondorcetWinners	Condorcet Winners Method
CopelandWinners	Copeland Winners Method
OutrankingApproach	Outranking Approach
MC1	Markov Chains 1 Method
MC2	Markov Chains 2 Method
MC3	Markov Chains 3 Method
MC4	Markov Chains 4 Method
MCT	Markov Chains Thurstone Method
PreferenceRelationsGraph	Preference Relations Graph
Agglomerative	Agglomerative Method
DIBRA	Distance-Based Iterative
KemenyOptimal	Kemeny Optimal Aggregation
RRA	Robust Rank Aggregation

Tabela 4.3: Métodos de agregação de rankings pré-selecionados no RankAggregation-Lib. Os selecionados para avaliação são os que encontram-se destacados em verde.

Acrônimo	**Método**
CombMIN	Combined MIN
CombMAX	Combined MAX
CombSUM	Combined SUM
CombANZ	Combined ANZ
CombMNZ	Combined MNZ
MC1	Markov Chain 1
MC2	Markov Chain 2
MC3	Markov Chain 3
MC4	Markov Chain 4
-	Borda count
-	Dowdall
-	Median
RRF	Reciprocal Rank Fusion
-	Mean
Mork-H	Mork-H
CG	CG
DIBRA	DIBRA
-	Borda-Score

Tabela 4.4: Métodos de agregação de rankings pré-selecionados no pyRankMCDA. Os selecionados para avaliação são os que encontram-se destacados em verde.

Acrônimo	**Método**
-	Borda Method
-	Copeland Method
-	Footrule Rank Aggregation
Fast Footrule	Fast Footrule Rank Aggregation
-	Kemeny-Young Method
Fast Kemeny-Young	Fast Kemeny-Young Method
-	Median Rank Aggregation
PageRank	PageRank Algorithm
Plackett-Luce	Plackett-Luce Model Aggregation
RRF	Reciprocal Rank Fusion
-	Schulze Method

Após aplicação dos critérios acima, 17 métodos foram de fato avaliados, os quais encontram-se destacados em verde nas tabelas acima. Para melhor visualização, os métodos selecionados são apresentados na Tabela 4.5, juntamente com as siglas utilizadas para referenciar tais métodos, como realizado na Tabela 2.5. Vale mencionar que os métodos [**PR-RF**] e [**RA-RF**], apesar de serem o mesmo, foram mantidos uma vez que obtêm-se resultados diferentes a depender da implementação utilizada.

Tabela 4.5: Métodos de agregação de rankings avaliados com suas respectivas siglas.

Sigla	**Nome**
PF-AM	PyFLAGR - Agglomerative Method
PF-CP	PyFLAGR - Copeland Winners Method
PF-CW	PyFLAGR - Condorcet Winners Method
PF-DI	PyFLAGR - DIBRA (Distance-Based Iterative)
PF-M1	PyFLAGR - Markov Chains 1 Method
PF-M2	PyFLAGR - Markov Chains 2 Method
PF-M3	PyFLAGR - Markov Chains 3 Method
PF-M4	PyFLAGR - Markov Chains 4 Method
PF-MT	PyFLAGR - Markov Chains Thurstone Method
PF-OA	PyFLAGR - Outranking Approach
PF-PG	PyFLAGR - Preference Relations Graph
PF-RA	PyFLAGR - RRA (Robust Rank Aggregation)
PR-ME	pyRankMCDA - Median Rank Aggregation
PR-RF	pyRankMCDA - RRF (Reciprocal Rank Fusion)
RA-CG	RankAggregation-Lib - CG
RA-DO	RankAggregation-Lib - Dowdall
RA-RF	RankAggregation-Lib - RRF (Reciprocal Rank Fusion)

4.2. Configuração Experimental

A configuração experimental adotada nesta seção é análoga àquela descrita na Seção 2.3, desde o conjunto de dados até a maneira como a avaliação foi realizada. A diferença encontra-se na configuração do *pipeline* utilizado, como visto na Figura 4.1. As alterações encontram-se destacadas na cor vermelha, especificamente dentro da "caixa" métodos de agregação. Substitui-se os métodos MCDA pelos de agregação de rankings. Além disso, diferentemente dos métodos de MCDA, que necessitam da definição de um vetor de pesos, os métodos aqui explorados não. Portanto, a "caixa" ponderação, da Figura 2.1, não se faz necessária aqui.

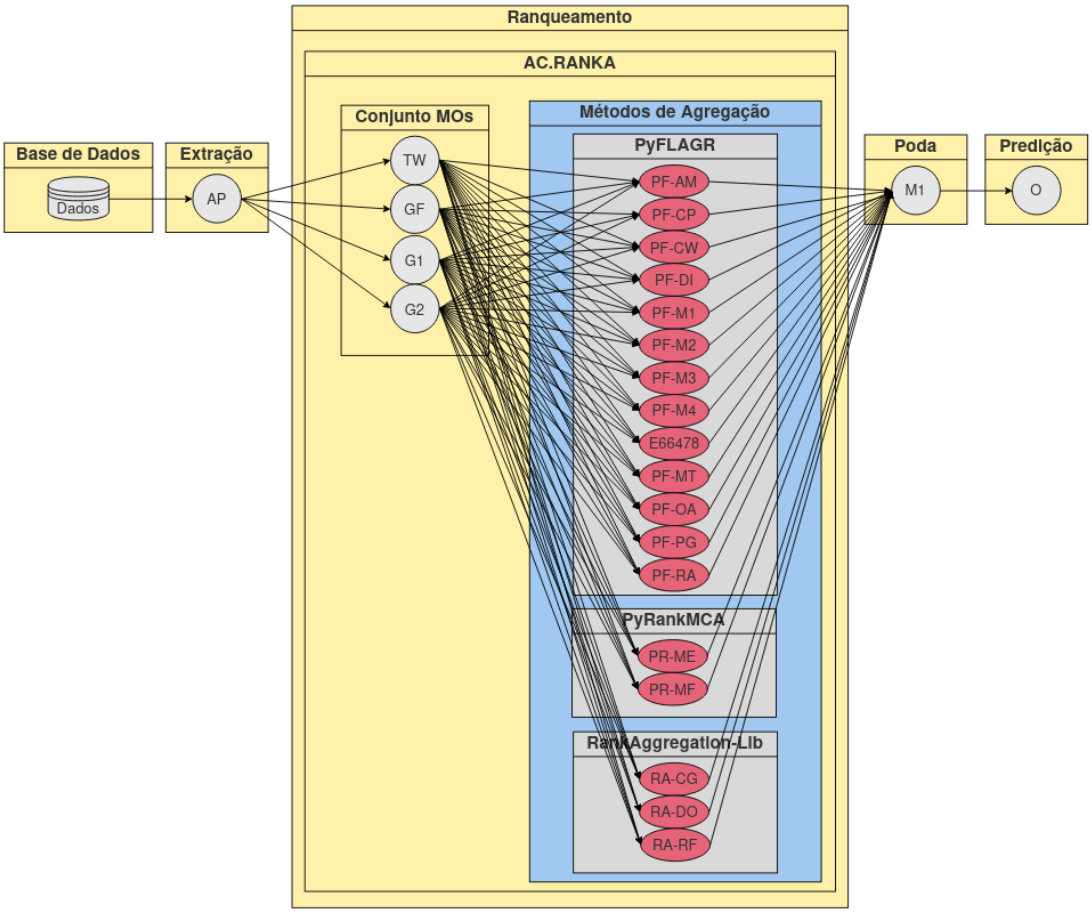


Figura 4.1: Métodos adicionais de agregação de rankings incorporados ao pipeline do $AC.Rank_A$.

4.3. Resultados e Discussões

Como na Seção 2.4, a Tabela 4.6 foi gerada da mesma maneira que a Tabela 2.6. Assim, neste caso, comparou-se todos os métodos avaliados com o $AC.Rank_A$. É possível observar que nenhuma das combinações aqui exploradas superou o $AC.Rank_A$. Nos casos mais otimistas, a melhora na interpretabilidade (tamanho do modelo (L)) ocorreu em detrimento do desempenho (F1-Score (F1)). Vale mencionar que o $AC.Rank_A$ apresenta desempenho superior em relação ao CBA. Assim, as combinações aqui exploradas não são tão adequadas quanto as usadas pelo $AC.Rank_A$.

Tabela 4.6: Resultados da análise de diferença crítica entre o $AC.Rank_A$ e os métodos avaliados em cada grupo de MOs e em ambas medidas avaliativas (F1-Score e tamanho do modelo).

MOs	PF-AM		PF-PG		PF-CP		PF-CW		PF-M1		PF-M2		PF-M3		PF-M4		PF-MT		PF-DI		PF-RA		PF-OA		PR-ME		PR-RF		RA-CG		RA-DO		RA-RF	
	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L	F1	L
GF	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	▲	≡	≡	▼	≡	▼	≡	▼	▲	▼	▲	▼	▲
TW	▼	≡	▼	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	▲	▼	▲	▼	≡	▼	▲	▼	≡	▼	≡	▼	▲	▼	▲	▼	▲	▼	≡
G1	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡
G2	≡	≡	≡	≡	≡	≡	≡	≡	▼	≡	≡	≡	▼	≡	≡	≡	≡	≡	≡	≡	▼	▲	≡	≡	▼	≡	▼	≡	▼	≡	▼	≡	▼	≡

5. Conclusão

Este trabalho se baseou no método de ranqueamento $AC.Rank_A$ proposto por Dall'Agnol and Carvalho (2024). O objetivo era explorar possíveis melhorias de tal método. Para tanto, este trabalho explorou: (i) a incorporação de métodos de ponderação de pesos ao pipeline do $AC.Rank_A$ (Obj.1); (ii) métodos de MCDA alternativos aos já avaliados (Obj.2); (iii) métodos de agregação de rankings alternativos aos já avaliados (Obj.3). Foi possível notar, ao longo das seções, tendo como base os resultados apresentados, que:

- ao se combinar o grupo de MOs [**GF**], com o método de ponderação [**SD**] e o método MCDA [**TS**], obtém-se melhores resultados em termos de interpretabilidade quando em comparação ao $AC.Rank_A$, mantendo-se, ao mesmo tempo, o mesmo desempenho. Deste modo, este trabalho conseguiu avançar o estado da arte no que se refere ao Obj.1;
- o método MCDA que obteve o melhor desempenho, em conjunto com alguns grupos de MOs e métodos de ponderação, foi o [**TS**]. Em outras palavras, nenhum outro método MCDA avaliado obteve resultados superiores a combinação [**GF**][**SD**][**TS**];
- nenhum método de agregação de rankings avaliado obteve resultados superiores a combinação [**GF**][**BL**], ou seja, ao que já é utilizado no $AC.Rank_A$.

Referências Bibliográficas

Ayan, B., S. Abacıoğlu, and M. P. Basilio (2023). A Comprehensive Review of the Novel Weighting Methods for Multi-Criteria Decision-Making. *Information 14*(5), 285.

Azmi, M. and A. Berrado (2020). RCAR Framework: Building a Regularized Class Association Rules Model in a Categorical Data Space. In *Proceedings of the 13th International Conference on Intelligent Systems: Theories and Applications*.

Bączkiewicz, A. and J. Wątróbski (2022). Crispyn-A Python library for determining criteria significance with objective weighting methods. *SoftwareX 19*, 101166.

Bong, K., M. Joest, C. Quix, T. Anwar, and S. Manickam (2014, 01). Selection and aggregation of interestingness measures: A review. *Journal of Theoretical and Applied Information Technology 59*, 146–166.

Dall'Agnol, M. and V. O. d. Carvalho (2024). AC.RankA: Rule ranking method via aggregation of objective measures for associative classifiers. *IEEE Access 12*, 88862–88882.

Hahsler, M., I. Johnson, T. Kliegr, and J. Kuchar (2019). Associative classification in R: Arc, arulesCBA, and rCBA. *R Journal 11*(2), 254–267.

Hwang, C.-L. and K. Yoon (1981). *Methods for Multiple Attribute Decision Making*. Berlin, Heidelberg: Springer Berlin Heidelberg.

Kizielewicz, B., A. Shekhovtsov, and W. Sałabun (2023). PyMCDM-The universal library for solving multi-criteria decision-making problems. *SoftwareX 22*, 101368.

Lin, S. (2010). Rank aggregation methods. *WIREs Computational Statistics 2*(5), 555–570.

Liu, B., W. Hsu, and Y. Ma (1998). Integrating classification and association rule mining. In *Proceedings of the 4th International Conference on Knowledge Discovery and Data Mining*, pp. 27–31.

Padillo, F., J. M. Luna, and S. Ventura (2020). LAC: Library for associative classification. *Knowledge-Based Systems 193*.

Pereira, V., M. P. Basilio, and C. H. T. Santos (2024). Enhancing Decision Analysis with a Large Language Model: pyDecision a Comprehensive Library of MCDA Methods in Python. *Gestão & Produção 31*, e06424.

Pereira, V., M. P. Basilio, and C. H. T. Santos (2025). Enhancing decision analysis with a large language model: pyDecision a comprehensive library of MCDA methods in Python. *Journal of Modelling in Management*.

Tew, C., C. Giraud-Carrier, K. Tanner, and S. Burton (2014). Behavior-based clustering and analysis of interestingness measures for association rule mining. *Data Mining and Knowledge Discovery 28*(4), 1004–1045.

Triantaphyllou, E. (2000). *Multi-Criteria Decision Making Methods*. Boston, MA: Springer US.

Wątróbski, J., A. Bączkiewicz, I. Bąk, Z. Ziemba, and A. Jarzębicki (2019). Generalised framework for multi-criteria method selection. *Omega 86*, 107–124.